



Fakultät Informatik

KI-gestützte Transformation statischer in interaktive 3D-Objekte durch Benutzerinteraktion

Bachelorarbeit im Studiengang Medieninformatik

vorgelegt von

Friedrich Allenhof

Matrikelnummer 359 4928

Erstgutachter: Prof. Dr. Uwe Wienkop

Zweitgutachter: Louis Burk

Abstract

Interaktive virtuelle Prototypen ermöglichen ein frühzeitiges Testen des Verhaltens digitaler Objekte. Vorhandene 3D-Assets enthalten vorrangig Geometrie, Transformationen und Materialien, aber keine explizite Interaktionslogik. Diese Arbeit untersucht, wie sich solche statischen 3D-Objekte mithilfe natürlicher Sprache in interaktive Prototypen überführen lassen, ohne ihre Geometrie zu ersetzen. Dafür wurde der *Vivian Specification Generator* (VSG) konzipiert und prototypisch umgesetzt. Der Ansatz verwendet eine Unity-basierte Vorverarbeitung sowie eine modulare, *Large Language Model* (LLM)-gestützte Pipeline bestehend aus *Scene Analyzer*, *Interaction Planner*, *Specification Generator*, *Consistency Reviewer* und *Unity-Validator*. Aus strukturierten Szenendaten, gerenderten Ansichten und Nutzer*innenbeschreibungen erzeugt der VSG Vivian-kompatible Spezifikationsdateien für ein zustandsbasiertes Interaktionsverhalten. Die technische Systemevaluation anhand der Testassets Lampe, Display und Toaster mit insgesamt 60 Durchläufen zeigt, dass der VSG vorhandene 3D-Objekte grundsätzlich in interaktive Prototypen überführen kann, da 57 Spezifikationen technisch valide generiert wurden. Die implementierten Korrekturmechanismen erhöhten die technische Erfolgsquote außerdem von 88,3 auf 95,0 Prozent. Gleichzeitig verdeutlichen die Ergebnisse, dass technische Validität nicht mit funktionaler Korrektheit gleichzusetzen ist.

Schlagwörter: Interaktive Prototypen, KI-gestützte Transformation, Virtual Prototyping, Generative KI, Large Language Models, Virtual Reality

Inhaltsverzeichnis

Abbildungsverzeichnis	v
Tabellenverzeichnis	vi
Listingverzeichnis	vii
1 Einführung	1
1.1 Problemstellung	2
1.2 Forschungsfragen und Zielsetzung	4
1.3 Abgrenzung	5
1.4 Aufbau der Arbeit	5
2 Grundlagen	7
2.1 Statische und interaktive 3D-Objekte	7
2.2 Transformation statischer in interaktive 3D-Objekte	8
2.3 Das Vivian-Framework	9
2.4 Large Language Models und agentische Systeme	10
3 Forschungsstand	13
3.1 3D-fähige multimodale LLMs	13
3.2 LLM-gestützte 3D-Szenengenerierung und -bearbeitung	14
3.3 Artikulation statischer 3D-Objekte	15
3.4 Forschungslücke	16
4 Systemkonzeption und Architekturentscheidungen	17
4.1 Anforderungsanalyse	17
4.1.1 Funktionale Anforderungen	17
4.1.2 Nicht-funktionale Anforderungen	18
4.1.3 Domänenspezifische Anforderungen	18
4.2 Untersuchte Architekturansätze	19
4.2.1 Manager-gesteuerter Multi-Agenten-Ansatz	20
4.2.2 Begründung des modularen Workflow-Ansatzes	21
5 Implementierung der Systemarchitektur	23
5.1 Systemkontext und Schnittstellen	23

5.2	Verwendete Sprachmodelle und Agenten	24
5.3	Gesamtpipeline und Datenfluss	25
5.4	Vorverarbeitung in Unity	27
5.5	Scene Analyzer	29
5.6	Interaction Planner	30
5.7	Specification Generator	33
5.8	Consistency Reviewer	39
5.9	Unity-Validator	43
6	Evaluation	47
6.1	Evaluationsziel und Untersuchungsdesign	47
6.2	Testassets und Referenzszenarien	48
6.3	Exemplarischer Workflow-Durchlauf	53
6.3.1	Eingabe und Referenzszenario	53
6.3.2	Szenenanalyse und Interaktionsplanung	54
6.3.3	Spezifikationsgenerierung und Validierung	55
6.3.4	Resultierender Prototyp und Einordnung	55
6.4	Wiederholte Durchläufe zur Robustheitsanalyse	56
6.4.1	Vorgehen und Metriken	56
6.4.2	Ergebnisse der Robustheitsanalyse	57
6.5	Validierungs- und Korrekturmechanismen	61
6.6	Einordnung der Ergebnisse	63
6.7	Grenzen der Evaluation	64
7	Ausblick und Fazit	65
7.1	Weiterführende Arbeiten	65
7.2	Fazit	66
	Anhang	69
	Literatur	89

Abbildungsverzeichnis

1.1	Beispiele virtueller 3D-Objekte.	1
1.2	Problemstellung am Beispiel eines Toaster-Assets.	3
4.1	Manager-gesteuerter Multi-Agenten-Ansatz.	20
5.1	Systemkontextdiagramm des VSG.	24
5.2	Container-Diagramm des VSG.	26
5.3	Unity UI des VSG.	28
5.4	Acht gerenderte Ansichten eines Toaster-3D-Assets.	29
5.5	Interaction Planner mit menschlicher Feedbackschleife.	33
5.6	Specification Generator.	34
5.7	Abhängigkeitsgraph der generierten Spezifikationsdateien.	38
6.1	Beispiele virtueller 3D-Objekte.	48
6.2	Hierarchie des Display-Assets in der Unity-Szene.	53
6.3	Zustände des Display-Prototyps.	56
E.1	Unity UI des VSG im Initialzustand.	85
E.2	Unity UI des VSG im Bestätigungsschritt.	86
E.3	Unity UI des VSG im Consistency-Reviewer-Schritt.	87

Tabellenverzeichnis

4.1 Übersicht der Anforderungen an den VSG	19
5.1 Übersicht der im Specification Generator verwendeten Sprachmodelle.	35
5.2 Eingaben der Spezifikationsagenten.	37
6.1 Übersicht der ausgewählten Testassets.	50
6.2 Relevante Teilobjekte, Kategorien und erwartete Vivian-Rollen der Testassets. . .	51
6.3 Erwartete Zustände der Testassets.	52
6.4 Erwartete Übergänge der Testassets.	52
6.5 Metriken der Robustheitsanalyse.	57
6.6 Ergebnisse der Robustheitsanalyse: Testasset Lampe.	58
6.7 Ergebnisse der Robustheitsanalyse: Testasset Display.	59
6.8 Ergebnisse der Robustheitsanalyse: Testasset Toaster.	60
6.9 Wirkung der Korrekturmechanismen auf die technische Erfolgsquote	62

Listingverzeichnis

5.1 Beispiel eines Interaktionsplans	31
5.2 Beispiel eines Interaktionsplans: geplanter Übergang	32
5.3 Beispiel eines Interaktionsplans: Slider-Elementrolle	35
5.4 Beispiel einer Zustandsbedingung aus states.json	36
5.5 System-Prompt-Ausschnitt des Consistency-Review-Agenten.	40
5.6 Beispiel eines Consistency Reviews.	41
6.1 Eingabeprompt für das Testasset Lampe	50
6.2 Eingabeprompt für das Testasset Display	51
6.3 Eingabeprompt für das Testasset Toaster	51

Kapitel 1

Einführung

Bei der Betrachtung dreidimensionaler Objekte in einem virtuellen Raum lässt sich deren Funktion häufig sofort erkennen. Ein Knopf soll gedrückt werden, ein Hebel soll sich bewegen, ein Display soll Informationen anzeigen und eine Lampe soll leuchten. Diese Funktionen lassen sich häufig intuitiv aus Form, Position, Material und Kontext erschließen. In virtuellen Umgebungen gilt dies jedoch nicht automatisch, da ein 3D-Modell zwar meist eine sichtbare Form, Materialien und räumliche Eigenschaften, aber in der Regel kein Verständnis über seine mögliche Nutzung besitzt. Auch Online-Bibliotheken, mittels 3D-Scanning erfasste Modelle realer Objekte sowie generativ erzeugte Inhalte liefern in der Regel kein Wissen darüber, welche Teile bedienbar sind oder wie diese auf Nutzer*innenhandlungen reagieren sollen. Zwischen dem visuellen Erscheinungsbild eines 3D-Objekts und seinem tatsächlichen Verhalten in einer virtuellen Welt besteht damit eine Diskrepanz (siehe Abbildung 1.1).




Abbildung 1.1: Beispiele virtueller 3D-Objekte.

Besonders deutlich wird dies, wenn 3D-Objekte nicht nur zur Betrachtung dienen, sondern als funktionale Prototypen mit definierter Interaktionslogik eingesetzt werden sollen. In Bereichen wie der Produktentwicklung, Lehre, *Virtual Reality* oder *Usability Engineering* reicht eine statische Darstellung häufig nicht aus, da Objekte ausprobiert, verändert und in ihrem Verhalten getestet werden sollen. Ein virtueller Prototyp muss damit weitaus mehr leisten als eine realistische Abbildung. Es muss Wissen darüber bestehen, welche Bestandteile re-

levant sind, welche davon bedienbar sind, welche Rückmeldungen gegeben werden und wie sich der Zustand des Objekts durch Interaktionen verändert.

Gleichzeitig ändert sich die Art und Weise, wie solche interaktiven Systeme entworfen werden können. Anstelle der rein manuellen Umsetzung durch Skripte oder systemspezifische Konfigurationen rückt mit der hohen Verfügbarkeit von KI-Systemen zunehmend natürliche Sprache in den Mittelpunkt. Diese wird somit zu einer Schnittstelle zwischen fachlicher Vorstellung und technischer Umsetzung. Der Fokus verschiebt sich von direkter Programmierung hin zur Beschreibung von Verhalten, Funktionen und Beziehungen.

Leistungsfähige *Large Language Models* (LLMs) haben in den vergangenen Jahren eine rasante Entwicklung erfahren und können natürliche Eingaben interpretieren, semantische Zusammenhänge ableiten sowie strukturierte Ausgaben erzeugen [1], [2]. Dies eröffnet neue Möglichkeiten, um die Lücke zwischen statischen 3D-Objekten und interaktiven Prototypen zu schließen, indem natürlichsprachliche Beschreibungen als Eingabe genutzt und mittels KI-gestützter Verfahren in eine maschinenlesbare Interaktionslogik übersetzt werden.

An dieser Stelle setzt die vorliegende Arbeit an. Sie untersucht, inwieweit sich bereits vorhandene statische 3D-Objekte in virtuellen Welten mithilfe eines KI-gestützten Workflows und natürlicher Sprache in interaktive virtuelle Prototypen überführen lassen. Als Grundlage dient das Vivian-Framework, welches Interaktion deklarativ über maschinenlesbare Spezifikationsdateien beschreibt. Damit bietet es eine geeignete Zielrepräsentation für eine automatisierte, durch Sprachmodelle gestützte Generierung.

1.1 Problemstellung

Statischen 3D-Objekten fehlen Angaben darüber, welche Teile bedienbar sind, welche Funktion sie erfüllen oder wie sie auf Nutzer*innenhandlungen reagieren. Genau diese Informationen sind für Interaktivität jedoch fundamental, da Objekte oder Teilobjekte mit Bedeutung, möglichen Handlungen und Verhalten verknüpft werden [3]. Somit bestehen virtuelle, interaktive Prototypen nicht nur aus einer 3D-Geometrie, sondern besitzen zusätzlich semantisch-verhaltensbezogene Informationen. Abbildung 1.2 zeigt dies anhand eines Toasters-Assets. Aus einem statischen 3D-Objekt und einer natürlichsprachlichen Beschreibung des gewünschten Verhaltens soll ein interaktiver Prototyp entstehen. Dieser soll etwa das Herunterdrücken des Hebels ermöglichen und Heizstäbe rot aufleuchten lassen. Wie sich diese Transformation kontrolliert und nachvollziehbar realisieren lässt, ist offen.

1.1 Problemstellung




Abbildung 1.2: Problemstellung am Beispiel eines Toaster-Assets.

Sowohl die Erstellung neuer interaktiver 3D-Inhalte als auch die Transformation vorhandener 3D-Objekte in interaktive Prototypen setzt oft ein technisches Verständnis und Wissen voraus, etwa in 3D-Modellierung, Szenenaufbau oder Programmierung. Dies vergrößert die Einstiegshürde für potenzielle Nutzer*innen wie Produktentwickler*innen, Designer*innen oder Lehrende. Diese Gruppe von Anwender*innen wird in dieser Arbeit als nicht-technische Benutzer*innen bezeichnet, also Personen ohne Kenntnisse in der Programmierung oder 3D-Modellierung. Die Fähigkeit, fachliche Anforderungen und Funktionalität präzise formulieren zu können, wird dabei jedoch vorausgesetzt.

Interaktivität wird meist an konkrete Objekte oder Teilobjekte gebunden. Verfahren wie 3D-Scanning erlauben allerdings häufig nur eine monolithische Erzeugung statischer Abbildungen der Realität. Auch rekonstruierte Szenen aus Punktwolken bieten an sich keine einzeln adressierbaren Teile. Diese Abbilder sind somit überwiegend nicht semantisch segmentiert und Objekte existieren nicht als eigenständige, adressierbare Entitäten. Eine interaktive Anpassung oder Segmentierung im Nachhinein ist dann nur mit massivem manuellem Aufwand möglich.

Weiterhin muss das gewünschte Interaktionsverhalten in eine strukturierte, maschinenlesbare Repräsentation überführt werden, damit es von einem System zur Laufzeit interpretiert und ausgeführt werden kann. Diese Überführung von natürlicher Sprache in eine strukturierte Repräsentation ist in der Regel ebenfalls mit hohem manuellem Aufwand verbunden und damit fehleranfällig.

Außerdem fehlen in automatisierten Verfahren zur Erstellung und Bearbeitung von virtuellen Prototypen oft interne Prüf- oder Korrekturmaßnahmen, um Fehler frühzeitig und im Prozess erkennen und beheben zu können. Diese Fehler müssen dann häufig zeitaufwendig und manuell im Nachhinein behoben werden. Auch können Halluzinationen auftreten, wie etwa in 3D-LLMs, wodurch Objekte teils nicht existieren oder falsche Beziehungen zwischen Objekten bestehen [4].

Daraus lässt sich das zentrale Problem dieser Arbeit ableiten: Es fehlt ein niedrighschwelliger und dennoch kontrollierbarer Ansatz, mit dem bereits vorhandene statische 3D-Objekte in maschinenlesbare, validierbare und zustandsbasierte Prototypen überführt werden können, während die Geometrie beibehalten wird.

1.2 Forschungsfragen und Zielsetzung

Um den in 1.1 beschriebenen Problemen zu begegnen, untersucht die vorliegende Arbeit die Möglichkeit, einen Ansatz zu entwickeln, welcher die automatisierte Überführung statischer 3D-Objekte in validierte, zustandsbehaftete, interaktive Prototypen ermöglicht, der insbesondere auch nicht-technischen Benutzer*innengruppen eine Nutzung ermöglicht und die Geometrie der Teilobjekte beibehält. Im Zentrum steht die folgende Forschungsfrage:

Lässt sich eine automatisierte Pipeline konzipieren und prototypisch umsetzen, die vorhandene statische 3D-Objekte mittels natürlicher Sprache in interaktive Prototypen überführt und dabei vorhandene Geometrien beibehält?

Zur detaillierten Beantwortung dieser Frage werden die folgenden untergliederten Forschungsfragen definiert:

- **F1:** Lässt sich ein *Co-Creation-Workflow* umsetzen, in dem Nutzer*innen die Überführung durch natürlichsprachliche Beschreibung und iterative Korrekturschleifen mitgestalten?
- **F2:** Lassen sich für Interaktivität relevante Objekte, Teilobjekte und semantische Rollen aus vorhandenen Szeneninformationen und Nutzer*innenbeschreibungen ableiten?
- **F3:** Können komplexe Interaktionslogiken aus der Kombination von bestehenden 3D-Geometrien und natürlicher Sprache extrahiert und in eine maschinenlesbare Repräsentation überführt werden?
- **F4:** In welchem Umfang tragen implementierte Validierungs- und Korrekturmechanismen dazu bei, aus fehlerhaften oder unvollständigen Erstgenerierungen valide Vivian-Spezifikationen zu erzeugen?

1.3 Abgrenzung

Das Ziel dieser Arbeit ist die Konzeption und prototypische Implementierung einer KI-gestützten Pipeline, welche statische 3D-Objekte mittels natürlicher Sprache in interaktive Prototypen überführt und diesen Prozess auch nicht-technischen Nutzer*innen zugänglich macht. Dabei sollen die Fähigkeiten von LLMs genutzt werden und ein Co-Creation-Workflow entstehen, in dem Mensch und System gemeinsam am Generierungsprozess beteiligt sind. Nutzer*innen beschreiben das gewünschte Verhalten natürlichsprachlich und können erzeugte Zwischenergebnisse iterativ prüfen und korrigieren. Das System erzeugt die eigentliche Spezifikation.

1.3 Abgrenzung

Diese Arbeit entstand in Kooperation mit dem Institut für angewandte Informatik (IFAI) der Technischen Hochschule Nürnberg Georg-Simon-Ohm. Aufgrund dieser Zusammenarbeit sowie der am IFAI vorhandenen Expertise im Vivian-Framework (siehe 2.3) wurde dieses als Grundlage zur Umsetzung einer solchen Pipeline gewählt. Da das Framework interaktive Prototypen ausschließlich über eine maschinenlesbare Verhaltensbeschreibung realisiert, bietet es eine geeignete Basis, auf der LLM-gestützte Verfahren aufsetzen können.

Ziel dieser Arbeit ist nicht die Generierung von 3D-Szenendaten oder Geometrie – weder vollständiger 3D-Szenen noch einzelner 3D-Objekte, wie es in einigen ähnlichen Arbeiten der Fall ist. Stattdessen wird ausschließlich die Ableitung von Spezifikationen aus bereits vorhandenen virtuellen Szenen betrachtet, um mithilfe des Vivian Frameworks virtuelle Prototypen zu erstellen.

1.4 Aufbau der Arbeit

Aufbauend auf den in Kapitel 1 genannten Problemstellungen und Forschungsfragen werden in Kapitel 2 einige theoretische Grundlagen erläutert. Dazu gehören statische und interaktive 3D-Objekte, die Transformation vorhandener 3D-Assets in interaktive Prototypen, das Vivian-Framework sowie Large Language Models und agentische Systeme. Kapitel 3 ordnet den derzeitigen Forschungsstand zur Verwendung von LLMs in virtuellen 3D-Welten ein und leitet daraus die Forschungslücke ab. Darauf aufbauend beschreibt Kapitel 4 die Anforderungen an den Vivian Specification Generator sowie Architekturentscheidungen. Kapitel 5 stellt die prototypische Implementierung der Pipeline und ihrer Module vor. In Kapitel 6 wird der entwickelte Ansatz anhand verschiedener Testassets technisch evaluiert und hinsichtlich Funktionsfähigkeit, Robustheit sowie Validierungs- und Korrekturmechanismen untersucht. Schließlich fasst Kapitel 7 die Ergebnisse der Arbeit zusammen, beantwortet die Forschungsfragen und zeigt Ansätze für mögliche weiterführende Arbeiten auf.

Kapitel 2

Grundlagen

Um die in dieser Arbeit untersuchte Transformation einordnen zu können, werden die dafür relevanten konzeptionellen und technischen Grundlagen im Folgenden erläutert. Dazu zählen die Abgrenzung statischer und interaktiver 3D-Objekte, das Verständnis ihrer Transformation sowie die zugrunde liegenden Technologien wie das Vivian-Framework und Large Language Models.

2.1 Statische und interaktive 3D-Objekte

Im Folgenden werden statische sowie interaktive 3D-Objekte definiert und erklärt. Die Begriffe 3D-Objekt und 3D-Asset werden in dieser Arbeit simultan verwendet. Beide beschreiben ein Element einer virtuellen Szene und können als alleinige Geometrie existieren oder Unterkomponenten bzw. Teilobjekte besitzen.

Statische 3D-Objekte

In dieser Arbeit werden statische 3D-Objekte als Basisform digitaler Modelle betrachtet. Sie sind die fundamentale Basis, auf denen komplexere Verhaltensweisen aufbauen können, jedoch wohnt ihnen mit diesen Informationen noch kein Eigenleben inne. Statische 3D-Objekte lassen sich meist rein geometrisch beschreiben. Die Mesh-Geometrie besteht aus Dreiecksnetzen oder Polyeder-Darstellungen, welche die Oberfläche durch polygonale Flächen, in der Regel Dreiecksnetze, deren Eckpunkte (*Vertices*) und Verbindungen (*Edges/Faces*) definieren [5]. Weiterhin besitzen sie grafische Attribute wie Materialeigenschaften, Texturen, Transparenz und Sichtbarkeit sowie eine hierarchische Anordnung im Szenengraph, welcher ihre Position, Rotation und Skalierung organisiert [6].

Interaktive 3D-Objekte

Während statische 3D-Objekte als unbelebte geometrische Körper betrachtet werden können, zeichnen sich interaktive 3D-Objekte durch Wissen über ihre Funktionalität und die Möglichkeit zur Interaktion mit ihnen aus [3]. Auf diese 3D-Objekte kann durch Eingaben (*Input*) eingewirkt werden und das Objekt reagiert zustands- oder verhaltensbezogen [7]. Durch diese Reaktion wird aus dem statischen 3D-Objekt ein interaktionsfähiges Element. Es ist somit in der Lage, auf von Benutzer*innen ausgelöste Ereignisse (*Events*) zu reagieren und wird zu einem handlungsoffenen Teil der virtuellen Welt. Interaktive 3D-Objekte werden in dieser Arbeit auch als interaktive Prototypen bezeichnet.

2.2 Transformation statischer in interaktive 3D-Objekte

Die in der vorliegenden Arbeit untersuchte Transformation von statisch zu interaktiv ist keine rein geometrische oder visuelle Modifikation, sondern eine semantisch-verhaltensbezogene. Sie macht aus einem visuellen und geometrischen Asset ein interaktives Modell, welches Informationen über sein eigenes Verhalten und die möglichen Interaktionen mit diesem beinhaltet. Mit dem Konzept dieser *Smart Objects* wird Logik direkt im Objekt gespeichert, was wiederum Dezentralisierung und Wiederverwendbarkeit ermöglicht [3]. Dieser Prozess umfasst verschiedene Ebenen.

Zunächst wird das statische 3D-Modell segmentiert sowie semantisch etikettiert, was sich mit dem Begriff *Labeling* zusammenfassen lässt. Dabei werden rohe Mesh-Geometrien in bedeutungsvolle Teile mit bestimmten Rollen zerlegt (z. B. der Griff einer Tasse oder die Sitzfläche eines Stuhls), sodass ein System später „versteht“, welches Teil eines 3D-Objekts für welche Interaktion relevant ist und eine Zuordnung stattfinden kann [8][9].

Im nächsten Schritt erfolgt der Übergang von der Semantik zum Verhalten mittels Zuweisung spezifischer Interaktionsmerkmale (*Interaction Features*) zu den im ersten Schritt analysierten semantischen Etiketten. Diese Merkmale beinhalten eine Beschreibung der Funktionalität sowie eine Verknüpfung mit Verhaltensplänen oder Zustandsautomaten. Diese Pläne können Zustände überprüfen oder ändern und legen das erwartete Verhalten von beteiligten Akteuren fest [3].

2.3 Das Vivian-Framework

Das Vivian-Framework ist ein *Virtual-Prototyping-Framework*. Es erstellt virtuelle Prototypen, also digitale, interaktive Repräsentationen physischer Objekte aus der realen Welt. Diese Repräsentation kann z.B. in der Produktentwicklung verwendet werden, um virtuelle Prototypen von echten Produkten zu erzeugen und deren Verhalten frühzeitig zu testen, ohne dass das physische Produkt tatsächlich vorhanden sein muss. Diese virtuellen Prototypen funktionieren spezifikationsgetrieben, sodass Verhalten nicht programmatisch, sondern deklarativ als Spezifikation geschrieben wird. Zur Laufzeit wird diese Spezifikation dann mittels einer *State-Machine*-basierten Umgebung interpretiert, um ein Interaktionsverhalten abzubilden [10]. Ein Vorteil einer solchen spezifikationsgetriebenen Vorgehensweise ist, dass beispielsweise Produktentwickler*innen keine Programmierkenntnisse benötigen, um virtuelle Prototypen von Produkten (*Digital Twins*) zu erstellen. So kann das Verhalten eines Produktes bereits frühzeitig und iterativ getestet werden. Ein weiteres mögliches Einsatzgebiet ist das Usability Engineering, mit dem interaktive Systeme so gestaltet und geprüft werden, dass sie für die jeweilige Zielgruppe möglichst effektiv, effizient sowie zufriedenstellend nutzbar sind. Dafür werden Systeme nicht erst am Ende, sondern bereits in der Entwicklung, beispielsweise mittels Prototypen, hinsichtlich Gebrauchstauglichkeit analysiert und getestet [11].

Vivian-Spezifikationen

Wie bereits gezeigt, besitzen statische 3D-Objekte von sich aus keine Interaktivität (siehe 2.1). Das Vivian-Framework bildet die Brücke zwischen statischem und interaktivem 3D-Objekt über eine maschinenlesbare Beschreibung des Verhaltens bei Interaktion mit dem virtuellen Prototyp. Die Verbindung dieser Spezifikation zu einem 3D-Objekt in der Szene wird über Namensreferenzen hergestellt. Ein Element in der Spezifikation referenziert demnach ein gleichnamiges 3D-Objekt oder Teilobjekt in der Szene. Weiterhin ermöglichen Spezifikationen eine Entkopplung des Verhaltensmodells vom 3D-Objekt, sodass unterschiedliche Spezifikationen verschiedene Verhalten bei demselben 3D-Objekt ermöglichen. Sie besteht im Wesentlichen aus vier Teilen: Interaktionselemente (*Interaction Elements*), Visualisierungselemente (*Visualization Elements*), Zustände (*States*) und Übergänge (*Transitions*) [10].

Interaktionselemente. Hier befinden sich Elemente, welche Eingaben akzeptieren und somit Interaktion ermöglichen. Das können u. a. *Buttons*, *Slider* oder *Movables* sein.

Visualisierungselemente. Dabei handelt es sich um Elemente, welche eine visuelle Rückmeldung geben. Typisch sind hier *Light*, *Screen* oder *Sound Source*.

Zustände. In diesem Teil befinden sich alle möglichen Zustände, die ein Prototyp erreichen kann. Jeder Zustand beschreibt eine bestimmte Situation, indem er Interaktions- und Visualisierungselementen Werte zuweist. Diese Zuweisung kann zudem an Bedingungen geknüpft sein.

Übergänge. Übergänge bestimmen, wie sich ein virtueller Prototyp von einem Zustand in einen anderen verändert. Diese Übergänge können durch Zeitüberschreitungen oder Ereignisse (Events) ausgelöst werden. Zusätzlich kann ein Übergang an eine zu erfüllende Bedingung (*Guard*) geknüpft sein.

2.4 Large Language Models und agentische Systeme

Large Language Models (LLMs) sind tiefe neuronale Netzwerke, welche die Verarbeitung von natürlicher Sprache ermöglichen [12]. Sie enthalten typischerweise Milliarden von Parametern und sind in der Lage, komplexe Aufgaben zu verstehen und zu lösen oder in Teilaufgaben zu zerlegen [13]. Ihre Skalierbarkeit ist ein zentrales Merkmal von LLMs, denn sie zeigen mit zunehmender Modellgröße und Datenmenge qualitative Leistungssteigerungen und sogenannte emergente Fähigkeiten, wie z. B. *In-Context Learning*. Während solche LLMs als Modelle zur passiven Sprachverarbeitung und -generierung verstanden werden können, besitzen sie ohne zusätzliche Werkzeuge keine eigene Handlungsfähigkeit. Hier greift das Konzept eines LLM-basierten Agenten weiter. Ein Agent ist eine autonome Einheit, welche in einer Umgebung agiert, Entscheidungen trifft und auch mit anderen Agenten interagieren kann [14]. LLM-basierte Agenten verbinden diese klassische Idee mit den Fähigkeiten von LLMs. Ein LLM kann hier als kognitive Kernkomponente verstanden werden und verleiht dem Agenten die Fähigkeit, eigenständig und unabhängig zu analysieren, zu planen sowie Probleme zu lösen [15]. So entsteht ein System, welches nicht nur natürliche Sprache verarbeiten kann, sondern eine eigene zielgerichtete Handlungsfähigkeit besitzt und in einer Umgebung agieren kann. Ebenso kann es zusätzliche Komponenten wie Sensorik, API-Aufrufe oder Werkzeuge nutzen [15]. Die universelle Schnittstelle für solche agentischen Systeme, über die formuliert, geplant und koordiniert wird, ist die natürliche Sprache [16].

Multimodale LLMs

Multimodale Large Language Models (MLLMs) sind Modelle, welche im Gegensatz zu reinen LLMs nicht nur Text, sondern zudem Informationen wie Bild, Audio oder Video empfangen (Input), verarbeiten sowie ausgeben (*Output*) können. Eine für diese Arbeit wichtige Fähigkeit ist ihr Verstehen von 2D-Bildern und daraus Schlussfolgerungen zu ziehen. Sie basieren auf LLMs und bestehen im Wesentlichen aus drei Hauptmodulen: einem vortrainierten Encoder (*Modality-Encoder*), einem LLM sowie einem Adapter (*Connector*). Der

Encoder verarbeitet die multimodalen Signale vor und der Adapter bildet die Brücke zum LLM, indem er diese Signale für das LLM verständlich umwandelt. Dieser Schritt ist nötig, da LLMs (wie in 2.4 gezeigt) ausschließlich Text verarbeiten können. Somit sind MLLMs in der Lage, Text sowie weitere multimodale Inhalte gemeinsam zu verstehen und darauf zu antworten [1], [2]. Im Vergleich zu früheren, ähnlichen Arbeiten basieren MLLMs auf LLMs mit Milliarden Parametern sowie neuen Trainingsparadigmen, wie dem „Multimodal Instruction Tuning“ [17]. Damit sind eine Vielzahl von Möglichkeiten gegeben, welche mit reinen LLMs nicht oder nur eingeschränkt realisierbar wären. Solche repräsentativen Fähigkeiten sind u.a. das Verständnis von visuell geprägten Witzen oder Memes [18], [19], räumliches bzw. koordinatenbezogenes Verständnis, das Erstellen von Website-Code basierend auf handgezeichneten Entwürfen oder Kochrezepten anhand von Bildern zubereiteter Gerichte [19].

Verwendung in der vorliegenden Arbeit

In dieser Arbeit werden LLM-basierte Agenten als Steuerungseinheiten in einer Pipeline zur Spezifikationsgenerierung für das Vivian-Framework verwendet. Sie übernehmen eine zentrale Rolle in der Übersetzung von natürlicher Sprache in strukturierte, maschinenlesbare Spezifikationen. Außerdem analysieren sie 3D-Szenen, planen mögliche Interaktionen mit einem 3D-Objekt, erzeugen Spezifikationen zur Realisierung dieser Interaktionen und validieren semantische Korrektheit der erzeugten Artefakte.

Kapitel 3

Forschungsstand

Die aktuelle Forschung in diesem Gebiet verbindet Sprachmodelle mit 3D-Repräsentationen und zeigt, dass LLM-basierte Systeme zunehmend in der Lage sind, 3D-Szenen nicht nur mit Sprache zu beschreiben, sondern semantisch sowie räumlich zu interpretieren. Mit der Weiterentwicklung von LLMs kann deren Integration mit räumlichen Daten große Fortschritte erzielen und bietet so neue Möglichkeiten, wie Szenenverständnis, Planung und Generierung von 3D-Welten oder Navigation in diesen. Spätestens seit 2023 hat sich die Verbindung zwischen LLMs und 3D-Repräsentationen zu einer eigenständigen Forschungslinie entwickelt, welche 3D-Szenen nicht nur beschreiben, sondern auch für neue Methoden wie, räumliches Verständnis (*Grounding*), Fragebeantwortung und Planungsaufgaben nutzen können [20], [21]. Trotz dieser schnellen Entwicklung bleiben Datenknappheit, Halluzinationsrobustheit und Grounding zentrale Herausforderungen aktueller Systeme [4], [20].

3.1 3D-fähige multimodale LLMs

In Arbeiten wie 3D-LLM [21] und PointLLM [22], können multimodale LLMs 3D-Daten direkt verarbeiten und nehmen dafür beispielsweise Punktwolken als Eingabe entgegen. Eine Punktwolke ist eine diskrete Menge von Punkten im dreidimensionalen Raum, welche die Oberfläche eines Objekts durch ihre 3D-Koordinaten und optional weitere Attribute wie Normalen beschreibt. Da Punktwolken explizite geometrische Informationen enthalten, vermeiden sie Mehrdeutigkeiten bezüglich Blickwinkel, Tiefe oder Verdeckung wie sie bei bildbasierten Verfahren auftreten können [22]. Beide Ansätze unterscheiden sich im Geltungsbereich. 3D-LLM arbeitet szenenzentriert, da es vollständige 3D-Szenen entgegennimmt, während PointLLM auf einzelne 3D-Objekte ausgelegt ist und farbige Punktwolken interpretiert. Auf dieser Grundlage können Aufgaben wie *3D-Captioning*, also die natürlichsprachliche Beschreibung von 3D-Szenen oder 3D-Objekten, *3D-Grounding*, das Auffinden konkreter Objekte anhand einer textuellen Referenz sowie 3D-Fragebeantwortung, Dialog und Navigation bearbeitet werden. Darüber hinaus bieten sie Zugang zu komplexeren Konzepten wie räumlichen Beziehungen zwischen Objekten, physikalischen Eigenschaften,

Raumlaysouts oder Interaktionsmöglichkeiten (*Affordances*), also die durch ein Objekt angebotenen Handlungsoptionen [21], [22]. Für die vorliegende Arbeit sind diese Ansätze allerdings nur eingeschränkt geeignet, da sie natürlichsprachliche Ausgaben erzeugen und keine maschinenlesbare Interaktionslogik, wie sie vom Vivian-Framework gefordert wird. Weiterhin besitzt die monolithische Punktwolkenrepräsentation nicht die im Vivian-Framework benötigte Adressierbarkeit einzelner Teilobjekte über Namensreferenzen.

3.2 LLM-gestützte 3D-Szenengenerierung und -bearbeitung

Parallel dazu wurden LLM-gestützte Pipelines entwickelt, in denen LLMs nicht direkt 3D-Daten verarbeiten. Unter einer Pipeline wird dabei eine sequenzielle Verarbeitungskette verstanden, in der spezialisierte Module nacheinander aufgerufen werden und die Ausgabe eines Moduls als Eingabe des nächsten dient. Stattdessen fungieren sie als Planungs- und Steuerungseinheit, die für die Generierung und Bearbeitung ganzer 3D-Szenen genutzt werden.

Das Framework LLMR nutzt für die Generierung von interaktiven Szenen eine modulare Pipeline, mit den Modulen *Module Planner*, *Scene Analyzer*, *Skill Library*, *Builder* und *Inspector*. Es kann Szenenkontext analysieren und generiert anschließend Unity-kompatiblen C#-Code, welcher durch ein Inspektionsmodul iterativ geprüft wird. Als Eingabe arbeitet das System mit einer strukturierten, für das LLM konsumierbaren JSON-Repräsentation des Szenenkontexts [23]. Für die vorliegende Arbeit ist der modulare Pipeline-Aufbau mit Modulen wie Planner, Scene Analyzer und Inspector relevant. Das Zielartefakt unterscheidet sich jedoch, da LLMR ausführbaren C#-Code generiert, während die vorliegende Arbeit deklarative Interaktionsspezifikationen erzeugt.

Holodeck verfolgt einen stärker szenenzentrierten Ansatz und zerlegt die Generierung einer Szene in einzelne Schritte für Grundrisse, Materialien, Fenster und Türen, Objektauswahl sowie räumliche Anordnung. Es dient der automatisierten Erstellung von 3D-Simulationsumgebungen im Bereich der verkörperten KI (*Embodied-AI*). Objekte werden räumlich plausibel angeordnet, indem ein LLM Beziehungen zwischen ihnen vorgibt und ein Optimierungsverfahren eine Anordnung sucht, die diese Beziehungen erfüllt [24]. Holodeck ist auf die Generierung neuer 3D-Umgebungen ausgerichtet und damit für die vorliegende Arbeit nur eingeschränkt anwendbar, da diese keine neuen 3D-Szenen erzeugt, sondern vorhandene 3D-Objekte um Interaktionslogik erweitert.

3.3 Artikulation statischer 3D-Objekte

Unter Artikulation wird in diesem Kontext die Ausstattung statischer 3D-Objekte mit beweglichen, durch Gelenke verbundenen Teilen verstanden. Dadurch können Bewegungsfreiheitsgrade in Simulationen abgebildet werden.

Für die Transformation statischer in interaktive Objekte sind objekt- und szenenzentrierte Ansätze besonders relevant. ArtLLM wandelt eine Punktwolke in eine Abfolge von *Tokens* um, die vom Modell nacheinander generiert werden. Darüber hinaus können Assets auch als Bild oder Text eingegeben werden. Wichtig ist dabei, dass diese nicht direkt in das Kernmodell eingehen, sondern vorher mithilfe externer Generierungsmodelle in initiale *Meshes* und dann in Punktwolken umgewandelt werden. Diese Struktur definiert die Positionen der einzelnen Teile, die mechanischen Gelenke sowie deren Hierarchie. Um Positionen und Winkel anzugeben, arbeitet es mit festen Rasterstufen statt Gleitkommazahlen. Nachdem detailliertere Geometrie über ein Zusatzmodul hinzugefügt wurde, wird diese kinematische Struktur als URDF-Datei (*Unified Robotics Description Format*) exportiert und kann so in Simulationen und virtuellen Umgebungen verwendet werden [25]. Da ArtLLM eine URDF-Datei erzeugt und Geometrie über externe Module hinzufügt, weicht es sowohl im Zielartefakt als auch in der Erhaltung vorhandener Geometrie vom Ansatz der vorliegenden Arbeit ab.

ArtiWorld erweitert diesen Ansatz von der Objekt- auf die Szenenebene. Das System nimmt eine textuelle Szenenbeschreibung entgegen und identifiziert auf dieser Grundlage artikulierbare Objekte. Anschließend erzeugt es strukturelle Beschreibungen der einzelnen Beziehungen und schließlich ebenfalls eine URDF-Datei, welche an die ursprünglichen Koordinaten des starren 3D-Assets angepasst wird [26]. Die Geometrie des Originals wird dabei nicht ersetzt, sondern um Interaktivität erweitert. Für die vorliegende Arbeit relevante Prinzipien sind der Erhalt vorhandener Geometrien und die Verwendung struktureller Zwischenrepräsentationen. Im Zielartefakt unterscheidet sich der Ansatz jedoch, da ArtiWorld eine URDF-Datei erzeugt und keine Vivian-kompatible Interaktionsspezifikation.

Bildbasierte Eingaben

Eingaben basierend auf Bildern gewinnen in artikulationsbezogenen Pipelines an Bedeutung. Einzelbilder werden aktuell in mehreren Arbeiten genutzt, um simulierbare Szenen oder artikulierbare Objekte zu generieren, wie etwa in URDFormer [27] oder ArtLLM [25]. Dabei können Bilder sowohl als alleinige Eingabe, wie etwa in URDFormer, als auch ergänzend verwendet werden, wie in ArtLLM. Diese Bilder bieten semantische Hinweise sowie Informationen zu potenziellen Interaktionsmöglichkeiten, was für die vorliegende Arbeit besonders relevant ist. Dieser Befund zeigt die Kombination aus expliziten Raumdaten in Form von

strukturellen Repräsentationen wie Punktwolken oder Szenengraphen mit Transformationen und Hierarchien einerseits sowie Bildern als visuelles Grounding andererseits.

3.4 Forschungslücke

Die in diesem Kapitel betrachteten Arbeiten zeigen, dass LLMs und MLLMs zunehmend in 3D-bezogenen Aufgabenbereichen eingesetzt werden, etwa für 3D-Szenenverständnis, 3D-Fragebeantwortung, 3D-Grounding, Interaktions- und Aufgabenplanung, textbasierte 3D-Verarbeitung, Szenengenerierung sowie artikulationsbezogene Objektmodellierung. Arbeiten wie 3D-LLM und PointLLM erzeugen natürlichsprachliche Beschreibungen. LLMR, Holodeck, ArtLLM, ArtiWorld und URDFormer hingegen erzeugen oder verändern Inhalte wie vollständige Szenen, Unity-Code oder URDF-Dateien.

Trotz dieser Fortschritte bleibt die automatisierte Ableitung semantischer und verhaltensbezogener Interaktionsspezifikationen aus vorhandenen statischen 3D-Objekten unzureichend adressiert. Insbesondere fehlt ein Ansatz, der vorhandene 3D-Objekte semantisch interpretiert, natürlichsprachliche Interaktionsbeschreibungen verarbeitet und daraus maschinenlesbare, validierbare sowie Vivian-kompatible Interaktionslogik erzeugt. Die vorliegende Arbeit ist somit nicht primär als Verfahren zur Geometrie- oder Szenengenerierung einzuordnen, sondern als semantisch-verhaltensbezogener Ansatz, der vorhandene Geometrie erhält und sie um Interaktionslogik ergänzt.

Die Forschungslücke ergibt sich damit aus der Kombination mehrerer Anforderungen, die einzeln in verwandten Arbeiten auftreten, in dieser Verbindung jedoch nicht adressiert werden. Da LLM-gestützte Generierungsprozesse fehlerhafte Objektverweise, inkonsistente Strukturen oder unzulässige Spezifikationselemente erzeugen können, sind zudem Validierungs- und Korrekturmaßnahmen erforderlich.

Aus dieser Forschungslücke sowie den Forschungsfragen F1 bis F4 (siehe 1.2) folgt die Notwendigkeit eines Systems, welches Szeneninformationen analysiert, natürlichsprachliche Interaktionsbeschreibungen verarbeitet, daraus relevante Objekte, Teilobjekte sowie Rollen ableitet, Vivian-kompatible Spezifikationen erzeugt und Fehler prüft sowie gezielt korrigiert.

Kapitel 4

Systemkonzeption und Architekturentscheidungen

Aufbauend auf der in Kapitel 3 identifizierten Forschungslücke beschreibt dieses Kapitel die konzeptionelle Grundlage des in dieser Arbeit entwickelten Ansatzes, der im Folgenden als *Vivian Specification Generator* (VSG) bezeichnet wird. Darüber hinaus werden die zugrundeliegenden Architekturentscheidungen begründet.

4.1 Anforderungsanalyse

Die Anforderungen an den VSG wurden nicht empirisch durch eine Nutzer*innenstudie erhoben, sondern analytisch aus der Problemstellung, den Forschungsfragen, der Abgrenzung, dem Stand der Forschung sowie den technischen Rahmenbedingungen des Vivian-Frameworks abgeleitet. Im Mittelpunkt stehen die Analyse vorhandener Szenendaten, die Wiederverwendung vorhandener Geometrien, die Erzeugung Vivian-kompatibler Spezifikationen, die niedrigschwellige Eingabe gewünschter Interaktionen sowie die frühzeitige Erkennung und Korrektur syntaktischer, semantischer sowie referenzieller Fehler. Zur Nachvollziehbarkeit wurden die Anforderungen in funktionale Anforderungen (A), nicht-funktionale Anforderungen (N) sowie domänenspezifische Anforderungen (D) unterteilt.

4.1.1 Funktionale Anforderungen

- **A1:** Der VSG soll aus bestehenden Szenenrepräsentationen und natürlichsprachlichen Interaktionsbeschreibungen Vivian-Spezifikationsdateien erzeugen, die alle für die beschriebene Interaktion notwendigen Interaktionselemente, Visualisierungselemente, Zustände und Übergänge enthalten.
- **A2:** Relevante Objekte und Teilobjekte sollen vom VSG explizit identifiziert und Rollen zugeordnet werden, sodass diese eindeutig über Namensreferenzen in den Vivian-Spezifikationen referenziert werden können.
- **A3:** Der VSG soll erzeugte Spezifikationen syntaktisch, semantisch und referenziell prüfen.

- **A4:** Der VSG soll im Generierungsprozess erkannte Fehler in einem begrenzten Korrekturprozess erneut an die zuständigen Verarbeitungsschritte zurückführen.
- **A5:** Der VSG soll einen *Human-in-the-Loop*-Schritt bereitstellen, in dem Nutzer*innen die Szeneninterpretation überprüfen und gegebenenfalls korrigieren können, bevor daraus Vivian-Spezifikationen erzeugt werden.
- **A6:** Der VSG soll es Nutzer*innen ermöglichen, gewünschte Interaktionen natürlichsprachlich zu beschreiben, ohne dass Vivian-Spezifikationen manuell erstellt oder bearbeitet werden müssen.

4.1.2 Nicht-funktionale Anforderungen

Diese Anforderungen ergeben sich aus F4 (Validierung und Korrektur), der Fehleranfälligkeit generativer KI, dem prototypischen Systementwurf sowie der Notwendigkeit, Module und Validierungsregeln später erweitern zu können.

- **N1:** Der VSG soll einzelne Verarbeitungsschritte so kapseln, dass Zwischenartefakte separat validiert und bei erkannten Fehlern gezielt neu erzeugt werden können.
- **N2:** Zwischenartefakte und Entscheidungen des VSG sollen protokolliert und abgespeichert werden, sodass der Generierungs- und Korrekturprozess nachvollzogen werden kann.
- **N3:** Die Implementierung des VSG soll so erweiterbar sein, dass zusätzliche Module ergänzt oder bestehende ersetzt werden können, ohne die Gesamtarchitektur grundlegend zu verändern.

4.1.3 Domänenspezifische Anforderungen

Die domänenspezifischen Anforderungen ergeben sich unmittelbar aus der Verwendung des Vivian-Frameworks. Da dieses Framework Interaktionsverhalten über Spezifikationsdateien abbildet und die Verbindung zu vorhandenen Szenenobjekten über Namensreferenzen herstellt, sollen diese Anforderungen sicherstellen, dass Spezifikationen den Vorgaben des Frameworks entsprechen und somit Interaktionen mit 3D-Objekten ermöglichen.

- **D1:** Der VSG erzeugt Vivian-Spezifikationsdateien, welche dem von Vivian erwarteten Dateiaufbau, den erlaubten Elementtypen, den Pflichtfeldern sowie zulässigen Wertebereichen entsprechen müssen.

4.2 Untersuchte Architekturansätze

- **D2:** Der VSG darf vorhandene Geometrien und Szenenhierarchien nicht neu generieren oder ersetzen, sondern ausschließlich durch semantische und verhaltensbezogene Spezifikationen ergänzen.
- **D3:** Die erzeugten Bezeichner für Interaktionselemente, Visualisierungselemente, Zustände, Übergänge und Objekt-Referenzen müssen eindeutig sein.
- **D4:** Jede Referenz von Interaktionselementen und Visualisierungselementen in Zuständen, Übergängen, Events, Guards und Elementdefinitionen muss auf ein vorhandenes Szenenobjekt oder ein vorhandenes Element der Spezifikation verweisen.

Die beschriebenen Anforderungen sind zudem kompakt in der nachfolgenden Tabelle aufgeführt.

#	Anforderung
A1	Erzeugung vollständiger Vivian-Spezifikationsdateien aus Szenendaten und natürlicher Sprache
A2	Identifikation relevanter (Teil-)Objekte und Zuweisung von Vivian-Rollen
A3	Syntaktische, semantische und referenzielle Validierung der Spezifikation
A4	Iterative Fehlerkorrektur durch gezielte Neuausführung betroffener Schritte
A5	Human-in-the-Loop-Schritt zur Prüfung und Korrektur durch Nutzer*innen
A6	Natürlichsprachliche Interaktionsbeschreibung
N1	Modulare Kapselung mit separater Validierung und gezielter Neugenerierung
N2	Protokollierung von Zwischenartefakten und Entscheidungen
N3	Erweiterbarkeit durch Hinzufügen oder Austausch einzelner Module
D1	Vivian-kompatible Dateistruktur, Elementtypen, Pflichtfelder und Wertebereiche
D2	Erhalt vorhandener Geometrien und Szenenhierarchien
D3	Eindeutige Bezeichner für alle Elemente und Referenzen
D4	Gültige Referenzen auf Szenenobjekte

Tabelle 4.1: Übersicht der Anforderungen an den VSG

4.2 Untersuchte Architekturansätze

Im Laufe dieser Arbeit wurden verschiedene Ansätze implementiert, um das Ziel der Generierung einer vollständigen Spezifikation nach Vivian zu erreichen.

4.2.1 Manager-gesteuerter Multi-Agenten-Ansatz

In der ersten Iteration wurden verschiedene Multi-Agenten-Systeme angeschaut. Im Manager-Agent-getriebenen System kann ein LLM-Agent beliebig viele weitere (spezialisierte) LLM-Agenten als Werkzeuge (*Tools*) aufrufen, um Aufgaben von spezialisierten Agenten lösen zu lassen, welche dann ein Ergebnis zurück an den Manager liefern. Wichtig zu erwähnen bei diesem Ansatz ist, dass ein Manager Agent spezialisierte Agenten aufrufen kann, aber selbst entscheidet, ob er dies tut. Eine ähnliche Vorgehensweise ist die des dezentralisierten Systems, bei dem es allerdings keine Orchestrierungseinheit wie einen Manager gibt, sondern Agenten die Aufgabe komplett an andere Agenten abgeben können (*Handoff*), ohne dass diese ein Ergebnis zurück an einen Manager-Agenten liefern [28].

Um eine übergeordnete Instanz im Prozess zu integrieren, welche sicherstellt, dass Referenzen zwischen den einzelnen Spezifikationsdateien korrekt sind und entstandene Fehler durch gezieltes Aufrufen der zuständigen spezialisierten Agenten korrigieren kann, wurde für die erste Iteration der Manager-getriebene Ansatz gewählt. Als spezialisierte Einheiten wurden ein Szenenanalyse-Agent sowie ein Agent je Spezifikationsdatei gewählt. Die Architektur dieses Ansatzes ist in Abbildung 4.1 dargestellt.




Abbildung 4.1: Manager-gesteuerter Multi-Agenten-Ansatz.

Im ersten Implementierungsdurchlauf zeigte sich, dass der Manager-getriebene Ansatz besonders bei dateiübergreifenden Referenzen und der konsistenten Benennung von Elementen zu Fehlern führte. Da der Manager-Agent eigenständig entscheidet, welche untergeordneten Agenten er aufruft, konnten Zwischenergebnisse nicht validiert werden und Fehler sind erst am Ende des Generierungsprozesses aufgefallen. Daher wurde dieser Ansatz zugunsten eines deterministischen modularen Workflows verworfen.

4.2.2 Begründung des modularen Workflow-Ansatzes

Die Architektur des zweiten Implementierungsdurchlaufs folgt dem Ansatz eines modularen Workflows, welcher ermöglicht, dass Module unabhängig beschrieben, validiert und erweitert werden können, ohne die Gesamtarchitektur grundlegend zu verändern (siehe N3). Diese modulare Trennung adressiert N1 und folgt dem in 3 beschriebenen Ansatz von LLMR, welches ebenfalls einen modularen Aufbau verwendet [23]. Jedes der in Abbildung 5.2 aufgeführten Module adressiert eine spezifische Teilaufgabe innerhalb des gesamten Prozesses, wodurch der Informationsfluss gesteuert werden kann und nachvollziehbar bleibt. Der VSG besteht im Wesentlichen aus den Modulen *Scene Analyzer*, *Interaction Planner*, *Specification Generator*, *Consistency Reviewer* und *Unity-Validator*.

Bei einfachen LLM-Aufrufen sinkt empirisch die Regelbefolgung bei wachsender Länge und Abhängigkeit strukturierter Ausgaben, sodass halluzinierte Referenzen und unzulässige Elementtypen kaum vermeidbar wären [29]. Ein einzelner LLM-Aufruf wäre somit nicht ausreichend. Er müsste fünf referenzierende Spezifikationsdateien gleichzeitig konsistent erzeugen und währenddessen sicherstellen, dass jeder Vivian-Elementtyp die in der Szene tatsächlich vorhandenen Unity-Komponenten besitzt. Durch die Zerlegung in einzelne Schritte sowie den Einsatz von Zwischenvalidierungen und iterativer Fehlerbehebung ermöglicht die hier vorgestellte Pipeline die Erzeugung korrekter Spezifikationen nach Vivian. Eine Skalierung ist durch dieses Vorgehen ebenfalls möglich: Durch Erweiterung bestehender oder Hinzufügen neuer Module könnten noch komplexere 3D-Objekte verarbeitet werden, als in dieser Arbeit betrachtet werden.

Kapitel 5

Implementierung der Systemarchitektur

In diesem Kapitel wird die Konzeption und prototypische Implementierung des Vivian Specification Generators als gewählte Systemarchitektur zur Spezifikationsgenerierung für das Vivian-Framework beschrieben. Ziel war es ein System zu entwerfen, welches die in den vergangenen Kapiteln erarbeiteten theoretischen Grundlagen und Anforderungen in ein lauffähiges und den Anforderungen entsprechendes System umsetzt. Konkret soll dieses semantisch und strukturell korrekte Vivian-Spezifikationen automatisiert erzeugen, natürlichsprachliche Interaktionsbeschreibungen und Benutzer*innen-Feedback entgegennehmen sowie aufkommende Fehler iterativ und eigenständig beheben können.

5.1 Systemkontext und Schnittstellen

Im Folgenden wird ein Architekturüberblick des VSG gegeben, in dem klar abgegrenzte, spezialisierte Module mit ihrer Funktion im Prozess kurz aufgeführt werden, in welcher Reihenfolge sie aufgerufen werden und welche Informationen jeweils ein- und ausgehen.

Zur Interaktion mit dem VSG wird Unity als Benutzer*innenschnittstelle genutzt. In einem Fenster kann eine initiale Interaktionsbeschreibung eingegeben und das zu transformierende statische 3D-Asset ausgewählt werden. Durch die Verwendung vorhandener Geometrie adressiert dieser Schritt D2 (Geometrieerhalt). Außerdem wird A6 (natürlichsprachliche Eingabe) behandelt, da hier natürlichsprachliche Beschreibungen entgegengenommen werden. Abbildung 5.1 veranschaulicht Unity als Schnittstelle in der Gesamtarchitektur zwischen Benutzer*innen und KI-Pipeline.

Unity-Prozesse übersetzen das ausgewählte 3D-Objekt zudem in Formate, die von nachgelagerten Modulen und insbesondere den darin enthaltenen KI-Agenten entgegengenommen werden können und zeigt die geplanten Interaktionen an, damit diese von Benutzer*innen bestätigt oder in einer Iterationsschleife korrigiert werden können. Damit wird A5 (Human-in-the-Loop) adressiert. Zusätzlich ist Unity die Umgebung, in der Vivian die Anreicherung eines statischen 3D-Assets mit Interaktionslogik über Spezifikationsdateien zur Laufzeit




Abbildung 5.1: Systemkontextdiagramm des VSG.

leistet. Nach erfolgreicher Generierung der Vivian-Spezifikation liefert die KI-Pipeline diese zurück an Unity, damit dort Vivian zusammen mit dem statischen 3D-Asset und der Spezifikation ausgeführt werden kann. Diese Gesamtarchitektur adressiert A1 (Erzeugung von Vivian-Spezifikationsdateien), da aus natürlichsprachlichen Eingaben und bestehenden Szenenrepräsentationen vollständige Vivian-Spezifikationen erzeugt werden.

Weiterhin erfolgt die Kommunikation der KI-Pipeline mit Unity über eine REST-API-Schnittstelle, sodass Funktionalitäten der Pipeline gegebenenfalls durch weitere Endpunkte erweiterbar bleiben. Durch diese Entkopplung könnte die KI-Pipeline auch in einen übergeordneten Prozess integriert werden, ohne an die Unity-UI gebunden zu sein.

5.2 Verwendete Sprachmodelle und Agenten

Die im Rahmen dieser Arbeit entwickelte Pipeline wird nicht von einem einzigen, autonomen Agenten gesteuert, sondern innerhalb eines deterministisch orchestrierten Workflows verwendet (siehe 4.2.2). Die Verarbeitungsreihenfolge ist damit überwiegend fest vorgegeben und orientiert sich am modularen Ansatz. Innerhalb solcher Module werden Sprachmodelle von spezialisierten Agenten für klar abgegrenzte Teilaufgaben mit definierten Ein- und Ausgabeformaten verwendet. Mit diesem Vorgehen wird der Freiheitsgrad einzelner Modelldaufrufe reduziert und die Nachvollziehbarkeit des Datenflusses erhöht. Auch können so fehlerhafte Teilschritte gezielt erneut ausgeführt werden, ohne zwangsläufig den gesamten Prozess neu zu starten.

Die Pipeline des VSG arbeitet mit mehreren Agenten, welche unterschiedliche, teils multimodale Aufgaben zu bewältigen haben. Ein Scene-Analyzer-Agent wird zur semantischen Interpretation einer vorverarbeiteten Szene verwendet und muss dazu sowohl strukturelle JSON-Daten als auch gerenderte Bildansichten eines 3D-Assets verarbeiten. Dieser Agent ist der

5.3 Gesamtpipeline und Datenfluss

einzigste innerhalb des VSG, welcher mit multimodalen Eingaben arbeitet. Ein Interaction-Planner-Agent überführt dieses Szenenverständnis und die Nutzer*innenbeschreibung der Interaktion in einen strukturierten Interaktionsplan. Das Specification-Generator-Modul überführt mithilfe von vier verschiedenen Agenten den Interaktionsplan in die verschiedenen Teile einer Vivian-Spezifikation. Ein Consistency-Review-Agent überprüft diese generierten Einzelartefakte auf dateiübergreifende sowie semantische Konsistenz. Sollten Fehler im Generierungsprozess entstanden sein, leitet ein Fixer-Agent Korrekturmaßnahmen aus diesen ab. Die verwendeten Agenten arbeiten somit als spezialisierte Einheiten innerhalb eines kontrollierten Gesamtsystems.

Anstelle von natürlicher Sprache generieren die Agenten strukturierte Ausgaben. Im Rahmen dieser Arbeit wurden überwiegend Pydantic-Modelle als Ausgabetypen (`output_type`) festgelegt, sodass das verwendete Sprachmodell in genau diesem Schema antwortet. Dadurch sind Ergebnisse direkt maschinenlesbar und können gegebenenfalls weiterverarbeitet, validiert, gespeichert oder an nachfolgende Module überreicht werden. Diese Einschränkung der Antwortvariabilität verbessert die Kontrollierbarkeit des gesamten Systems. Freitext wird dennoch dort zugelassen, wo Begründungen, Korrekturhinweise oder Zusammenfassungen angegeben werden sollen.

Die Wahl der verwendeten LLMs erfolgt je nach Aufgabe und orientiert sich an Reasoning-Bedarf, Kontextumfang sowie Kosten. Stärkere Modelle werden dort eingesetzt, wo hohe Interpretations- und Planungsleistung benötigt wird, während schemagebundenere Aufgaben mit klaren Anweisungen und kleineren Modellen umgesetzt werden können. Der VSG nutzt bewusst nicht für jeden Agenten dasselbe Sprachmodell, sondern passt die Auswahl an die jeweilige Aufgabe des Agenten an. Trotz dieser Spezialisierungen bleiben bekannte Grenzen LLM-basierter Verfahren, wie Halluzinationen, semantische Fehlannahmen und fehlerhafte Referenzen, bestehen, weshalb der Einsatz von Agenten in der vorliegenden Arbeit durch Human-in-the-Loop, Validierungsmechanismen und iterative Korrekturschritte abgesichert wird. Diese Absicherung adressiert A3 (Validierung der Spezifikation), A5 (Human-in-the-Loop) sowie F4 (Validierung und Korrektur).

Die nachfolgenden Abschnitte beschreiben die einzelnen Module und ihre Aufgaben innerhalb der Pipeline. Bei Verarbeitungsschritten, welche LLM-basierte Agenten verwenden, wird zusätzlich der Einsatz verwendeter Sprachmodelle erläutert.

5.3 Gesamtpipeline und Datenfluss

Benutzer*innen können über die Unity UI mit dem System interagieren und erhalten Informationen über den Prozessfortschritt, Logging-Informationen, Rückmeldung des Interaktionsplaners und ob ein Durchlauf erfolgreich war (siehe Anhang E). Anschließend wird das




Abbildung 5.2: Container-Diagramm des VSG.

ausgewählte 3D-Asset über ein weiteres Unity-Skript in eine strukturelle Szenenrepräsentation umgewandelt sowie ergänzende 2D-Bildansichten gerendert (siehe Abbildung 5.4).

Diese aufbereitete Szenendarstellung wird im darauffolgenden Schritt zusammen mit einer initialen Benutzer*innenbeschreibung der gewünschten Interaktivität an den Scene Analyzer übermittelt. Dieser gibt ein Scene-Understanding-Objekt aus, welches für jedes relevante Objekt dessen Funktion, Rolle und Eignung als potenzielles Interaktions- oder Visualisierungselement enthält.

Anschließend erhält der Interaction Planner das zuvor generierte Scene-Understanding-Objekt zusammen mit der strukturierten Szenenrepräsentation, die zuvor auch der Scene Analyzer erhalten hat und der natürlichsprachlichen Interaktionsbeschreibung. In diesem Schritt wird geplant, welche Interaktions- und Visualisierungselemente es geben wird, welche Zustände der Prototyp einnehmen kann und welche Übergänge zwischen Zuständen vorgesehen sind. Der Interaction Planner gibt einen Interaction-Plan aus, welcher Elementrollen, geplante Zustände und Übergänge sowie eine Liste der zu generierenden Spezifikationsdateien enthält. Dieser Plan wird gemäß A5 (Human-in-the-Loop) Benutzer*innen anschließend zur Bestätigung oder Korrektur vorgelegt. Bei einer Korrektur wird der Interaction Planner erneut aufgerufen, um diese anzuwenden, bis der Plan bestätigt wird, welcher schließlich den nachgelagerten Modulen als verbindliche Vorgabe dient.

5.4 Vorverarbeitung in Unity

Der Specification Generator erzeugt auf Grundlage dieses Interaktionsplans die eigentlichen Vivian-Spezifikationsdateien in der notwendigen Reihenfolge. Ausgegeben werden vier strukturierte JSON-Dateien, welche zusammen eine Vivian-Spezifikation bilden.

Der Consistency Reviewer prüft nun mithilfe des Interaktionsplans, ob der Plan korrekt vom Specification Generator umgesetzt wurde und ob logische Widersprüche oder dateiübergreifende Inkonsistenzen existieren. Das könnten z.B. unerreichbare Zustände oder widersprüchliche Bedingungen sein, welche eine rein strukturelle Validierung nicht erkennen kann.

Ein Validator ergänzt dies um eine strukturelle und laufzeitnahe Kontrolle. Wird die maximale Anzahl an Versuchen erreicht oder keine Fehler gefunden, terminiert der VSG. Letzteres sorgt für ein Zurückliefern der generierten Vivian-Spezifikation an Unity, sodass Vivian diese zusammen mit dem statischen 3D-Asset ausführen kann.

Die Pipeline ist dabei so aufgebaut, dass einzelne Module unabhängig angepasst, ersetzt oder durch weitere Verarbeitungsschritte ergänzt werden können, ohne die Gesamtarchitektur zu verändern. Der Aufbau adressiert damit N3 (Erweiterbarkeit).

5.4 Vorverarbeitung in Unity

Um ein 3D-Asset in LLM-verständliche Daten umzuwandeln, müssen eine strukturelle Repräsentation und Ansichten aus verschiedenen Blickwinkeln erstellt werden. Da der nachgelagerte Scene Analyzer mit Text und Bild als Eingaben arbeitet, benötigt er die erstellten Ansichten als visuelles Grounding für die abstrakten JSON-Daten. Die Form des Objekts, das Material oder auch räumliche Anordnung werden somit direkt sichtbar und müssen nicht aus Bounding-Boxen rekonstruiert werden.

Im ersten Schritt wird dazu aus dem im Unity-Fenster (Abbildung 5.3) ausgewählten 3D-Asset ein *Prefab*-Objekt erzeugt, welches später von Vivian zur Laufzeit instanziiert wird. Damit wird gemäß D2 (Geometrieerhalt) keine neue Geometrie generiert, sondern wiederverwendet.

Um einem LLM Verständnis über ein 3D-Asset (in Unity *GameObject* genannt) zu geben, wird zunächst eine strukturierte Szenenbeschreibung im JSON-Format mit dem Namen `scene.json` erzeugt. Dazu wird die Hierarchie des Szenengraphen rekursiv traversiert und pro *GameObject* werden Informationen wie die ID, der Hierarchiepfad, Transformation, Materialien, Bounding Boxes oder Mesh-Statistiken extrahiert. Weiterhin werden bereits basierend auf Namen, Tags oder Material-Hinweisen heuristisch Rollen erkannt, welche im späteren Verlauf verwendet werden können, um Interaktionselemente und Visualisierungselemente zu klassifizieren.




Abbildung 5.3: Unity UI des VSG.

Im Anschluss daran rendert Unity für das übergeordnete GameObject verschiedene Ansichten, da die Erkennungsleistung eines MLLM steigt, wenn statt einer Einzelansicht mehrere gerenderte Ansichten eines 3D-Objekts verwendet werden [30]. Dafür werden sechs orthografische Ansichten entlang der Hauptachsen sowie zwei isometrische (von schräg oben) als 1024x1024-Pixel-PNGs erstellt (siehe Abbildung 5.4). Die gewählte Anzahl der Ansichten ist ein Kompromiss zwischen Erkennungsrobustheit und minimal notwendigem Bildumfang, um Kosten pro Durchlauf zu sparen. Die orthografischen Ansichten vermeiden perspektivische Verzerrung und beinhalten saubere Silhouetten, während die isometrischen Ansichten die räumliche Gesamtform und Lesbarkeit verbessern sowie drei Raumdimensionen in einer Darstellung erfassbar machen. Zur Laufzeit wird dazu eine Kamera angelegt, anhand der Welt-Bounding-Box des Objekts platziert und auf das Objektzentrum ausgerichtet. Alle dafür benötigten Ressourcen werden anschließend wieder freigegeben.

Eine zugehörige Datei namens `views_manifest.json` enthält pro Bild Kameramatrizen, Pose, Projektionstyp und einen Vermerk, welches Teilobjekt des Szenengraphen sich an welcher Stelle in der Ansicht befindet. Unity kennt die Kameraposition sowie die 3D-Box jedes Objekts in der Szene und kann so ausrechnen, wo sich ein Objekt der Szene im jeweiligen Bild befindet. Nachgelagerte MLLMs können so den Zusammenhang zwischen Objekten in `scene.json` und denen aus den Ansichten (siehe Abbildung 5.4) herstellen. Dafür wird die ID, ein Tiefenhinweis und das Pixelrechteck vermerkt, in dem sich das Objekt im Bild befindet.

5.5 Scene Analyzer



Abbildung 5.4: Acht gerenderte Ansichten eines Toaster-3D-Assets.

Der Vorverarbeitungsschritt in Unity erzeugt also zusammengefasst aus einem vorhandenen, statischen 3D-Asset eine strukturelle Repräsentation als JSON-Struktur, acht gerenderte Ansichten von diesem sowie eine weitere JSON-Struktur mit Informationen zu den Ansichten. Diese Daten können nun vom nächsten Modul, dem Scene Analyzer, konsumiert werden. In diesem Schritt werden D2 (Geometrieerhalt), D4 (gültige Referenzen) sowie N1 (modulare Kapselung) adressiert, da Geometrie erhalten bleibt, die JSON-Struktur eine Basis für spätere Namensreferenzen bietet und definierte Ein- und Ausgabeformate verwendet werden.

5.5 Scene Analyzer

Die Kernaufgabe des Scene-Analyzer-Moduls besteht darin, die in der Vorverarbeitung entstandenen visuellen Eindrücke und strukturellen Daten mit der natürlichsprachlichen Nutzer*innenbeschreibung zu verknüpfen und die rohen Daten so in ein semantisch angereichertes Zwischenformat zu überführen. F2 (Ableitung relevanter Objekte) sowie A2 (Identifikation und Rollenzuweisung) werden hier adressiert, da relevante Objekte und Teilobjekte aus Szeneninformationen und der Beschreibung abgeleitet werden, sodass nachfolgende Schritte auf diese referenzieren können.

Als Eingaben bekommt der Scene Analyzer die in Abschnitt 5.4 beschriebene strukturierte Szenenrepräsentation und die Ansichten des Objekts. Die JSON-Struktur stellt Namen, Pfade, IDs und Geometrie bereit, während die Bilder bei der semantischen Einordnung helfen. Diese Daten werden von einem internen LLM-basierten Agenten verarbeitet, welcher so einordnen kann, ob ein Teilobjekt beispielsweise eher Griff, Display oder Knopf ist.

Das verwendete LLM leistet in diesem Modul die Hauptarbeit: Es klassifiziert die Szeneninformationen gemäß einem vorgegebenen Schema. In Anhang A ist dargestellt, wie der verwendete Agent mithilfe eines strukturierten Prompts angesteuert wird.

Dieses **SceneUnderstanding**-Objekt beinhaltet nun ein aufbereitetes Szenenverständnis mit Informationen zu Objektbezügen, Relationen oder Clustern und bietet die Grundlage dafür, dass darauffolgende Agenten ein Verhalten aus der analysierten Szene ableiten können. Durch dieses Zwischenprodukt muss der Interaction Planner nicht direkt aus einer Unity-Hierarchie schließen, welche Objekte funktional relevant sind, sondern kann mit einer semantisch vorstrukturierten Repräsentation arbeiten.

Diese entstandene kontrollierte Zwischenrepräsentation ist maschinenlesbar und validierbar, bleibt allerdings dennoch von der Qualität der Modellinterpretation abhängig und ist anfällig für semantische Falschannahmen, weshalb spätere Review-Schritte relevant bleiben.

5.6 Interaction Planner

Der Interaction Planner bildet die Brücke zwischen Szenenanalyse und Spezifikationsgenerierung. Die semantisch verstandene Szenenrepräsentation wird in einen strukturellen Plan überführt, nach dem der nachgelagerte Generierungsschritt die Spezifikationsdateien erzeugt. Da das in der Szenenanalyse generierte **SceneUnderstanding** rein deskriptiv ist, werden die enthaltenen Objekte im Interaktionsplanungsschritt nach Vivian-Functional-Specification-Typen klassifiziert und damit konkreten Vivian-Rollen zugeordnet. So wird außerdem vermieden, dass einzelne Agenten in der Spezifikationsgenerierung inkonsistente Entscheidungen treffen. Er ist auf die Strukturen und Regeln des Vivian Frameworks ausgerichtet und kann so einzelnen Teilobjekten bestimmte Rollen zuweisen, Zustände und Übergänge planen sowie entscheiden, welche Dateien der Spezifikation für die geplante Interaktion benötigt werden. Weiterhin wurde ein Human-in-the-Loop-Schritt implementiert, damit Nutzer*innen die Ausgabe des Interaction Planners validieren oder korrigieren können.

Dafür wird erneut ein LLM-Agent verwendet, welcher bestimmte Instruktionen und somit Informationen über das Vivian-Framework erhält (siehe Anhang B). Mit diesem Wissen kann er die beschriebenen Aufgaben zuverlässig bewältigen. Als LLM wird hier das aktuell leistungsstärkste Modell von OpenAI, GPT-5.5, verwendet, da der Agent aus den Rohdaten der Szene ein Interaktionsverhalten nach Vivian herleiten muss. Dabei können Fehler entstehen wie falsche Objekttypen oder Halluzinationen. Solche Fehler sind schwerwiegend, da der Interaction Planner eine zentrale Planungseinheit für den späteren Prototyp darstellt und sie in nachfolgende Schritte weitergereicht werden. Somit würden auch alle nachgelagerten Schritte fehlerhafte Ausgaben produzieren.

5.6 Interaction Planner

Das vom Scene Analyzer ausgegebene `SceneUnderstanding`-Objekt (siehe 5.5) im JSON-Format sowie die vom Unity UI weitergereichte natürlichsprachliche Interaktionsbeschreibung werden dazu vom Interaction Planner konsumiert und in einen strukturierten Interaktionsplan (`InteractionPlan`) überführt. Dieser enthält ein vordefiniertes Format, welches Informationen über Elementrollen, geplante Zustände und Übergänge sowie eine Liste der benötigten Spezifikationsdateien enthält. Listing 5.1 zeigt einen Strukturüberblick eines Beispiel-Interaktionsplans. Darüber hinaus liefert das LLM noch eine zusammengefasste Begründung für die getroffenen Entscheidungen mit, welche es Nutzenden erleichtern soll, Fehler zu finden und zu beheben (siehe 5.1, Z. 6).

```
1 {  
2   "element_roles": [...],  
3   "planned_states": [...],  
4   "planned_transitions": [...],  
5   "files_needed": [...],  
6   "reasoning": "The user description was treated as the primary  
                source, so the plan focuses only on the handle-triggered toast  
                cycle and the two requested visual feedback elements. Handle is  
                modeled as a Slider because the scene confirms linear y-axis  
                travel, while the heaters and LED are modeled as Light elements  
                to support on/off glowing behavior during toasting. Other  
                controls such as the rotary knob and buttons were excluded  
                because they were not requested and are not necessary for the  
                described prototype behavior."  
7 }
```

Listing 5.1: Beispiel eines Interaktionsplans

Eine der Hauptaufgaben des Interaction Planners ist die Rollenzuweisung. Dafür werden den relevanten Objekten einer 3D-Szene basierend auf Namen, Materialien und Geometrie spezifische Vivian-Typen zugewiesen, wie Button, Slider, Light oder Screen, welche das LLM direkt aus den einzelnen Elementen von `SceneUnderstanding` ableitet. Beispielsweise sollte einem `Handle` die Rolle eines Slider zugewiesen werden. Diese Aufgabe adressiert A2 (Identifikation und Rollenzuweisung).

Weiterhin definiert der Interaction Planner Zustände, welche der spätere Prototyp einnehmen kann, sowie Übergänge zwischen diesen. Das umfasst das Erstellen von Zustandsnamen, Beschreibungen, Übergangsnamen und möglichen Auslösern (*Triggern*), die diese Übergänge initiieren. In Listing 5.2 ist ein beispielhafter Ausschnitt eines Interaktionsplans mit einem geplanten Übergang zu sehen. Die Zustände und Übergänge werden hier bereits geordnet

beschrieben, allerdings erst im Functional-Specification-Generator-Schritt (siehe 5.7) in Spezifikationsdateien umgewandelt. Außerdem kann das LLM festlegen, an welche Bedingungen (*Guard Hints*) ein Übergang geknüpft sein kann (siehe 5.2, Z. 7–8).

```

1 {...
2   "planned_transitions": [{
3     "source_state": "idle.state",
4     "destination_state": "toasting.state",
5     "trigger_element": "Handle",
6     "trigger_description": "User pushes the handle down to start
   toasting.",
7     "guard_hints": [
8       "Handle VALUE > 0.8"
9     ]}...]}

```

Listing 5.2: Beispiel eines Interaktionsplans: geplanter Übergang

Eine weitere Aufgabe des Interaction Planners umfasst die Bestimmung des Umfangs, also welche konkreten Spezifikationsdateien (*InteractionElements.json*, *VisualizationElements.json*, *States.json* und *Transitions.json*) für die gegebene Szene erforderlich sind, da dies von der Komplexität des Prototyps abhängt. Einfachere Prototypen mit vergleichsweise wenigen Elementen oder Funktionen benötigen gegebenenfalls nicht alle Dateien einer Spezifikation, während komplexere alle vier Dateien benötigen können. Durch modulare Kapselung der nachfolgenden Schritte können gegebenenfalls einzelne Generierungsagenten in 5.7 übersprungen werden, sodass nicht benötigte Spezifikationsdateien nicht erzeugt werden. Damit wird N1 (modulare Kapselung) adressiert.

Der generierte Interaktionsplan wird anschließend zurück an die Unity UI gesendet und den Benutzer*innen zur Prüfung angezeigt (siehe Anhang E). Über die Entscheidungsbeurteilung kann direkt ein erster Eindruck gewonnen werden, ob Interaktionen wie gefordert geplant worden sind. Bei Bedarf lassen sich zudem einzelne Interaktionselemente, Visualisierungselemente, Zustände und Übergänge anzeigen, um diese bei Fehlern auch einzeln adressieren zu können.

Sollte eine Korrektur nötig sein, können Nutzende über ein Freitextfeld in natürlicher Sprache beschreiben, welche Interaktionen oder Elemente geändert werden sollen. Der Agent zur Interaktionsplanung wird daraufhin erneut ausgeführt und nimmt Änderungen am Interaktionsplan vor. Dieser in Abbildung 5.5 abgebildete iterative Prozess stellt sicher, dass Benutzer*innenrückmeldungen berücksichtigt werden und adressiert A5 (Human-in-the-Loop) sowie F1 (Co-Creation-Workflow).




Abbildung 5.5: Interaction Planner mit menschlicher Feedbackschleife.

Die in diesem Schritt implementierte Extraktion komplexer Interaktionslogiken durch Planung von Elementrollen sowie Zuständen und Übergängen mithilfe natürlicher Sprache adressiert F3 (Extraktion von Interaktionslogik) und erzeugt damit die zentrale Planungsgrundlage für nachfolgende Module, Vivian-kompatible Spezifikationsdateien zu erzeugen. Da Fehler an die gesamte Spezifikationsgenerierung weitergereicht werden, wirkt der Human-in-the-Loop-Schritt direkt entgegen, indem Nutzer*innen den Plan vor der Weitergabe an den Specification Generator bestätigen oder korrigieren können.

5.7 Specification Generator

Der Specification Generator übersetzt die im vorherigen Schritt geplante Interaktionslogik aus einem deklarativen und zum Teil noch natürlichsprachlich beschriebenen Plan in die vier JSON-Dateien einer Vivian-Spezifikation. Während andere Module für das Planen (siehe 5.6) sowie die Validierung der erzeugten Dateien (siehe 5.9) zuständig sind, ist dies der einzige Schritt, in dem tatsächliche, von Vivian konsumierbare JSON-Spezifikationsdateien erzeugt werden. Dieses Modul adressiert damit primär A1 (Erzeugung von Vivian-Spezifikationsdateien) sowie D1 (Vivian-Kompatibilität).

Eingaben, Ausgaben und Verarbeitungsreihenfolge

Als Eingabe nimmt der Specification Generator einen bestätigten Interaktionsplan entgegen und gibt die Spezifikationsdateien `InteractionElements.json`, `VisualizationElements.json`, `States.json` und `Transitions.json` aus. Da Vivian außerdem eine fünfte Datei (`VisualizationArrays.json`) zur Ausführung benötigt, wird diese ebenfalls erstellt und ist standardmäßig ungefüllt. Da diese fünfte Datei im Kontext dieser Arbeit keine weitere Relevanz hat, bleibt sie im Rest der Arbeit unerwähnt. Eine Vivian-Spezifikation gilt

somit in dieser Arbeit als vollständig, wenn sie InteractionElements.json, VisualizationElements.json, States.json und Transitions.json enthält.

Für die Umsetzung dieses Moduls wurden vier spezialisierte LLM-Agenten implementiert, welche nacheinander aufgerufen werden, um je eine der vier Spezifikationsdateien zu generieren. Zuerst werden Interaktionselemente, danach Visualisierungselemente, anschließend Zustände und im letzten Schritt Übergänge erstellt (siehe 5.7). Die Reihenfolge der Generierung ergibt sich aus den Datenabhängigkeiten: Zustände referenzieren die Namen der Interaktions- und Visualisierungselemente, Übergänge wiederum sowohl Namen der Interaktions- und Visualisierungselemente als auch der Zustände. Eine parallele Verarbeitung würde zwangsläufig zu Inkonsistenzen in den Bezeichnern und somit später zu Fehlern in der Ausführung führen. Abbildung 5.6 zeigt diesen sequenziellen Ablauf inklusive zwischengeschalteter Validierungsstufen.




Abbildung 5.6: Specification Generator.

Die jeweils generierten Daten werden noch nicht in finalen JSON-Dateien, sondern in einem Registry-Objekt gespeichert, welches als *Single Source of Truth* agiert. Dies ermöglicht Datenkonsistenz und verhindert Redundanz. Die verwendeten Agenten sind gegenüber einem einzigen Sprachmodell bei vielen Referenzen zwischen generierten Daten und strukturierten Ausgaben empirisch weniger fehleranfällig, wie bereits in 4.2.2 erwähnt. Diese Aufteilung adressiert zudem N1 (modulare Kapselung) und ermöglicht zudem eine gezielte Wiederausführung einzelner Schritte, ohne sämtliche Spezifikationsdaten neu zu generieren.

Modellwahl und Spezialisierung der Agenten

Wie bereits in 2.4 erläutert, wurden auch in diesem Schritt die verwendeten Sprachmodelle je nach Aufgabenkomplexität gewählt. Während der Interaction Planner mehrdeutige Rohdaten als Eingaben erhält, daraus einen für Folgeschritte verbindlichen Plan entwickelt (siehe 5.6) und deshalb das stärkste aktuell verfügbare Modell verwendet, arbeiten die Agenten der Specification Generation mit einer vorstrukturierten, von Benutzenden bestätigten Grundlage. Daher können die Agenten verhältnismäßig kleinere und schnellere LLMs verwenden. Tabelle 5.1 zeigt eine Übersicht der im Specification Generator verwendeten Sprachmodelle je Agent.

Agent	Sprachmodell
InteractionElements	gpt-5.1-2025-11-13
VisualizationElements	gpt-5.1-2025-11-13
States	gpt-5.5-2026-04-23
Transitions	gpt-5.1-2025-11-13

Tabelle 5.1: Übersicht der im Specification Generator verwendeten Sprachmodelle.

Die InteractionElements- und VisualizationElements-Agenten haben die primäre Aufgabe eine schematische Struktur abzubilden und verwenden daher ein kleineres und kosteneffizienteres Modell (GPT-5.1) als der Interaction Planner. Je Elementtyp gibt es feste Felder, normalisierte Wertebereiche und verpflichtende *Constraints*, sodass die Generierung der jeweiligen Spezifikation im Wesentlichen daraus besteht, bereits vorhandene Szeneninformationen, wie Geometrie oder Achsen, auf das Vivian-Spezifikationsschema abzubilden. Listing 5.3 zeigt einen für den InteractionElements-Agenten relevanten Ausschnitt des Interaktionsplans. Schlussfolgerungen (*Reasoning*) werden lediglich dort gefordert, wo Mehrdeutigkeiten bestehen (z. B. Button oder *ToggleButton*), um diese aufzulösen. Komplexeres, mehrstufiges *Reasoning* wird an dieser Stelle nicht benötigt, daher wäre ein leistungsstärkeres Modell wie GPT-5.5 bei diesen Agenten überdimensioniert. Die Verwendung eines kleineren Modells, wie etwa GPT-5-mini, hat hingegen häufiger zu Reparaturzyklen geführt und dadurch insgesamt höhere Kosten verursacht.

```

1 {...
2   "element_roles": [
3     {
4       "object_name": "Handle",
5       "funcspec_type": "Slider",
6       "category": "interaction",

```

```

7      "rationale": "User requested that pushing the toaster handle
          down starts toasting; the scene provides y-axis translation
          parameters for this handle.",
8      "interaction_params": {
9          "axis": "y",
10         "range": 0.05754443258047104
11     }
12 }...]}...}

```

Listing 5.3: Beispiel eines Interaktionsplans: Slider-Elementrolle

Der States-Agent verwendet mit GPT-5.5 das leistungsstärkste Modell der hier verwendeten, da die Generierung einer funktionierenden State-Machine eine deutlich logikintensivere Aufgabe darstellt als die anderen Bereiche des Specification Generators. Dabei muss der Agent eine Menge von Zuständen erstellen, welche logisch zusammenpassen und das gesamte Verhalten des Prototyps beschreiben. Er muss diese nicht nur benennen, sondern zusätzlich mit passenden und typisierten Bedingungen (*Conditions*) versehen. Ein Beispiel einer *Condition* aus `states.json` ist in Listing 5.4 zu sehen. Werden Zustände von diesem Agenten falsch definiert oder uneinheitlich beschrieben, propagieren diese Fehler unmittelbar in die nachgelagerten Verarbeitungsschritte. Das verbraucht wiederum insgesamt mehr Ressourcen, da diese Fehler in zusätzlichen Reparaturzyklen behandelt werden müssen. Je besser in diesem Schritt Zusammenhänge erkannt und konsistente Zustände erzeugt werden können, desto geringer ist die Wahrscheinlichkeit für fehlerhafte Ausgaben. Deshalb profitiert dieser Agent von einem Modell mit höherer Reasoning-Qualität.

```

1  {
2      "States": [
3          {"Name": "toasting.state",
4            "Conditions": [
5                {
6                    "Type": "InteractionElementCondition",
7                    "InteractionElement": "Handle",
8                    "Attribute": "VALUE",
9                    "Value": "1.0"
10               }...]}...]}

```

Listing 5.4: Beispiel einer Zustandsbedingung aus `states.json`

Der Transitions-Agent verwendet wie die InteractionElements- und VisualizationElements-Agenten das Modell GPT-5.1, da die zu verwendenden Zustände bereits im States-Agenten generiert wurden und hier verwendet werden. Diese Aufgabe benötigt somit verhältnismäßig weniger Reasoning-Aufwand. Grundsätzlich würde dieser Agent zwar aufgrund bestimmter Aufgaben (wie Exklusiv-Oder-Gatter) von einem leistungsstärkeren Modell profitieren, allerdings reicht GPT-5.1 hier erfahrungsgemäß aus. Sollten deutlich komplexere Prototypen als im Rahmen dieser Arbeit betrachtet werden, würde der VSG in diesem Schritt unmittelbar von der Verwendung eines leistungsstärkeren Modells, wie GPT-5.2 oder GPT-5.5, profitieren.

Datenfluss zwischen den Agenten

Als Eingabe erhalten die vier Spezifikationsagenten den Interaktionsplan, sowie bereits generierte Teile der Registry. Die Agenten erhalten dabei nicht die gesamten, in der Registry gespeicherten Daten, sondern ausschließlich die für ihre eigene Aufgabe benötigten Informationen wie Objektnamen oder -typen. In Tabelle 5.2 ist aufgeführt, welche Eingaben die jeweiligen Spezifikationsagenten bekommen. Diese Informationen werden benötigt, um korrekte Referenzen zwischen den einzelnen Spezifikationsteilen zu erzielen. Der Transitions-Agent bekommt hier bewusst keine Daten der Visualisierungselemente, da für Übergänge ausschließlich Interaktionselemente als Trigger fungieren können und diese nicht zur Generierung von Übergängen benötigt werden. Von Zuständen werden weiterhin ausschließlich Namen benötigt (um Quell- und Zielzustand festzulegen).

Agent	Eingabe
InteractionElements	InteractionPlan
VisualizationElements	InteractionPlan, InteractionElements-Subset
States	InteractionPlan, InteractionElements-Subset, VisualizationElements-Subset
Transitions	InteractionPlan, InteractionElements-Subset, States-Subset

Tabelle 5.2: Eingaben der Spezifikationsagenten.

Validierung und Registry

Jeder der Agenten liefert ein Pydantic-typisiertes Objekt zurück. Wie bereits in 5.5, wird hierfür das Argument `output_type` der OpenAI-Agenten verwendet. Die Agenten produzieren somit direkt Objekte im jeweils benötigten Schema. Anschließend durchläuft die generierte Ausgabe zwei Validierungsstufen. Zunächst prüft eine Pydantic-Schemavalidierung

Pflichtfelder, Wertebereiche und erlaubte Elementtypen. Anschließend werden Querverweise gegen den Interaktionsplan und das bisher gefüllte Registry-Objekt überprüft und somit sichergestellt, dass alle generierten Bezeichner auf existierende Szenenobjekte bzw. bereits erstellte Spezifikationselemente verweisen. Nach erfolgreicher Validierung wird das Ergebnis eines Agenten in die Registry übernommen und damit für nachfolgende Spezifikationsagenten und Validierungen innerhalb dieses Moduls als *Single Source of Truth* zur Verfügung gestellt. Schlägt eine dieser Prüfungen fehl, startet ein neuer Generierungsversuch. Diese Validierungsschichten adressieren zusammen mit den Agenteninstruktionen D1 (Vivian-Kompatibilität), D3 (eindeutige Bezeichner) sowie D4 (gültige Referenzen).

Korrekturprozess

Sollten in nachgelagerten Prüfschichten außerhalb dieses Moduls, wie dem 5.8 oder 5.9, Inkonsistenzen oder Fehler aufkommen, wird ein erneuter Versuch gestartet, die Spezifikation zu erzeugen. Dabei wird nicht zwangsläufig die gesamte Spezifikation, sondern gezielt nur die Teile neu generiert, welche betroffen sind. Dazu werden betroffene Schritte innerhalb des Specification Generators sowie alle davon abhängigen als „dirty“ markiert und ausschließlich diese Teilmenge in einem neuen Versuch durchlaufen. Sollte beispielsweise die `Transitions.json`-Datei Fehler enthalten, wird ausschließlich der Transitions-Agent erneut aufgerufen. Wenn hingegen die `InteractionElements`-Datei fehlerhaft ist, müssen alle vier Agenten erneut ausgeführt werden. Dieses Verhalten adressiert A4 (iterative Fehlerkorrektur). Die Abhängigkeiten der Spezifikationsdateien sind 5.7 zu entnehmen.




Abbildung 5.7: Abhängigkeitsgraph der generierten Spezifikationsdateien.

Diese Wiederausführung einzelner Schritte im Generierungsprozess der Spezifikation wird durch die Persistenz des Registry-Objekts ermöglicht. Da fehlerfreie Spezifikationsteile über mehrere Versuchsdurchläufe hinweg erhalten bleiben, können die zugehörigen Generierungsschritte übersprungen werden. Weiterhin werden entstandene Zwischenartefakte (wie Spezifikationsdateien) je Generierungsversuch in einem Verzeichnis abgelegt. Dazu wird je Durch-

lauf ein Protokoll mit sämtlichen vorgenommenen Änderungen am Registry-Objekt zusammen mit den dazugehörigen Spezifikationsdateien geführt, um die Veränderungen über alle Versuche eines Durchlaufs hinweg festzuhalten. So können Fehlerursachen besser nachvollzogen und einzelne Durchläufe reproduziert werden. Damit wird N2 (Protokollierung) adressiert.

5.8 Consistency Reviewer

Nachdem nun alle Daten einer Vivian-Spezifikation vom Specification Generator inklusive korrekter Abhängigkeiten und Querverweise generiert wurden, muss im nächsten Schritt geprüft werden, ob semantische Inkonsistenzen in diesen existieren. Dieser Schritt ist notwendig, da rein strukturelle Validatoren (JSON-Schema, Unity-Validator) nicht jeden Fehlertyp erkennen können. Er prüft zunächst die inhaltliche Konsistenz der einzelnen Teilspezifikationen untereinander. Die Registry-Einträge der Zustände und Übergänge müssen demnach semantisch zu denen der Interaktionselemente sowie Visualisierungselemente passen. Darüber hinaus wird die Übereinstimmung mit dem ursprünglichen Interaktionsplan geprüft, d.h. ob sämtliches dort geplantes Verhalten tatsächlich wie vorgesehen umgesetzt wurde. Letzteres beinhaltet Vivian-Typzuweisungen einzelner Interaktions- und Visualisierungselemente sowie die Umsetzung geplanter Zustände und Übergänge.

Um diese Aufgaben bewältigen zu können, bekommt der Consistency Reviewer einen User-Prompt bestehend aus dem kompletten Registry-Objekt (`REGISTRY_JSON`) und dem Interaktionsplan (`INTERACTION_PLAN_JSON`) sowie einen System-Prompt, in dem Instruktionen mit den zu erfüllenden Aufgaben enthalten sind. Eine volle Version des System-Prompts ist in Anhang C zu sehen.

Zu den konkreten Aufgaben des Consistency-Review-Agenten gehört unter anderem das Überprüfen der physikalischen und logischen Sinnhaftigkeit. Diese wäre beispielsweise nicht gegeben, wenn ein *Light* als *InteractionElement* typisiert worden wäre. Weiterhin wird überprüft, ob alle Zustände durch Übergänge erreichbar sind und ob es Übergänge gibt, die auf nicht-existierende Zustände oder Elemente verweisen. Da Zustandswechsel ohne observierbaren Verhaltenswechsel, also ohne sichtbare Veränderung der Szene, im aktuellen Stand der Arbeit obsolet sind, werden Übergänge auch darauf kontrolliert. Die Elementrollen aus dem Interaktionsplan werden zudem gegen die generierten Interaktions- und Visualisierungselemente abgeglichen. Außerdem wird geprüft, ob dabei Halluzinationen entstanden sind, also ob es Interaktions- oder Visualisierungselemente gibt, die nicht im Interaktionsplan vorhanden sind. Damit wird sichergestellt, dass alle geplanten Elemente auch in die vorgesehenen Vivian-Typen übersetzt worden sind. Außerdem wird an dieser Stelle nochmal überprüft, ob alle generierten Bezeichner der Elemente den tatsächlichen Objektnamen aus dem Interaktionsplan, und somit aus der Szene, entsprechen, da Vivian diese sonst nicht zuordnen könnte.

Zusätzlich prüft der Agent für jedes *Light*-Element mit einer „FloatValueVisualization“-Bedingung, ob mindestens ein Zustand dessen Wert tatsächlich setzt. Dies stellt sicher, dass es mindestens einen Zustand gibt, der ein Licht leuchten lassen kann. Diese Aufgaben sind außerdem dem folgenden Listing (5.5) zu entnehmen.

What to check

- 3.1. Physical/logical sense: Do states reference elements in ways that make physical sense? For example, a Light should have visual conditions (FloatValueVisualization), not be treated as an interaction element.
- 3.2. Reachability: Are all states reachable via at least one transition? Are there dead-end states with no outgoing transitions (unless they are intentional terminal states)?
- 3.3. Dead transitions: Are there transitions that reference states or elements that serve no purpose or create impossible paths?
- 3.4. Plan coverage: Does the generated output cover all element_roles from the InteractionPlan? Are there planned elements missing from the generated files?
- 3.5. Plan coverage (reverse): Are there elements in the generated files that were not in the InteractionPlan? This may indicate hallucinated elements.
- 3.6. Visualization consistency: If a visualization element has a FloatValueVisualization condition, does at least one state actually set a meaningful value for it? A Light with FloatValueVisualization but no state ever changing its value is suspicious.
- 3.7. Interaction-visualization alignment: If an InteractionElement is referenced in transitions, do the resulting states actually change any conditions? Transitions that don't lead to observable changes are pointless.
- 3.8. Element name validity: All element names in States and Transitions must match exactly (case-sensitive) with names defined in InteractionElements and VisualizationElements.
- 3.9. Guard and condition value normalization: For Rotatable and Slider elements, verify that all VALUE attribute values in States conditions and Transitions guards are normalized strings between "0.0" and "1.0". Any numeric value above 1.0 on a Rotatable or Slider VALUE attribute indicates a degree or unit value was used instead of a normalized fraction -- flag as error.

- 3.10. Screen file assignments: If the InteractionPlan includes screen_files assignments on planned states, verify that the generated States.json uses those assignments. If a planned state has screen_files assigned but the corresponding generated state has no ScreenContentVisualization condition or uses a different filename, flag as a warning.
- 3.11. Slider drag-end without position guard: If a transition is triggered by SLIDER_DRAG_END and has no guard on the slider's VALUE attribute, flag as an error. A SLIDER_DRAG_END transition without a VALUE guard fires regardless of where the user stopped dragging, making the trigger condition physically meaningless.
- 3.12. Visualization condition carry-over: The Vivian runtime only applies conditions explicitly listed in a state; any visualization element not mentioned retains its value from the previous state (carry-over). If a visualization element has conditions in multiple states with different values, verify that all other reachable states also set an explicit condition for that element. A state that omits a condition for a visualization element whose value varies across other states will produce path-dependent visual behavior, which is almost always unintended. Flag as error.

Listing 5.5: System-Prompt-Ausschnitt des Consistency-Review-Agenten.

Der Consistency-Review-Agent liefert anschließend wiederum ein strukturiertes Pydantic-Modell zurück. Die Struktur dieses Modells sowie ein Beispiel für ein solches lassen sich Listing 5.6 entnehmen. Dieser Struktur lassen sich Informationen zur Schwere des Problems, der Datei, in der das Problem aufgetreten ist, dem betroffenen Element, einer Problembeschreibung und Lösungsvorschlägen entnehmen. Weiterhin ist auch direkt ersichtlich, ob das Problem mit dem Interaktionsplan oder der inhaltlichen Konsistenz zwischen den Teilspezifikationen zusammenhängt. Zudem gibt es noch eine Zusammenfassung der Fehler, damit Übersichtlichkeit auch bei vielen aufkommenden Fehlern gewährleistet werden kann. Auch diese Agentenantwort wird gemäß N2 (Protokollierung) in das Verzeichnis des aktuellen Versuchs geschrieben, um Nachvollziehbarkeit und Reproduzierbarkeit jedes Versuchs zu gewährleisten. Listing 5.6 zeigt ein Beispiel eines Consistency Reviews.

```

1 {
2   "issues": [
3     {
4       "severity": "warning",
```

```

5      "file": "States.json",
6      "element": "Handle",
7      "description": "Both states set an InteractionElementCondition
      on the slider \"Handle\" using Attribute=\"FIXED\". A Slider
      's primary dynamic attribute is typically VALUE; FIXED may
      be supported as a generic lock flag, but it is not mentioned
      in the InteractionPlan and may be ignored by the runtime
      depending on the schema implementation.",
8      "suggested_fix": "If the intent is to keep the slider movable,
      remove the FIXED conditions entirely. If the intent is to
      lock/unlock the slider, confirm FIXED is a valid attribute
      for Slider in your runtime; otherwise replace with a
      supported attribute/approach."
9  }
10 ],
11 "plan_coverage_ok": true,
12 "cross_file_consistency_ok": true,
13 "summary": "All planned elements, states, and transitions are
      present and references are consistent (no missing/unknown
      element or state names). State reachability and observable
      effects (lights toggling) match the plan; the only concern is
      use of the non-plan/non-core slider attribute FIXED in state
      conditions, which may be unnecessary or unsupported."
14 }

```

Listing 5.6: Beispiel eines Consistency Reviews.

Sollten Probleme in diesem Schritt der Pipeline gefunden werden, wird ein neuer Versuch des Generierungsprozesses gestartet. Damit wird N1 (modulare Kapselung) adressiert. Ähnlich wie im Specification Generator werden auch hier durch Mapping der erkannten Probleme auf betroffene Schritte, gemäß der Abhängigkeiten der einzelnen Dateien (siehe 5.7), nur betroffene Teile der Spezifikation erneut generiert.

Der Consistency-Review-Agent verwendet mit GPT-5.2 das zweitstärkste LLM innerhalb dieser Pipeline. Er bekommt sowohl die Registry als auch den Interaktionsplan als JSON-Eingabe, welche bei komplexeren Szenen sehr umfangreich werden können, und muss daraus Referenzen ziehen und die Inhalte gegeneinander abgleichen. Leistungsschwächere Modelle würden bei diesen Aufgaben mit viel Kontext schneller die Übersicht verlieren, was problematisch wäre, da dies die Kernkompetenz dieses Agenten ist. Weiterhin ist strukturiertes Reasoning erforderlich, um durch das Traversieren eines gerichteten Graphen von Zuständen und Übergängen die Erreichbarkeit von Zuständen abzuleiten. Auch diese Aufgabe führt zu

Problemen bei kleineren Modellen. Eine zuverlässige Fehlererkennung in diesem Schritt ist zudem wichtig, da fälschlicherweise erkannte Fehler zu erneuten Versuchsdurchläufen führen können, was wiederum bei komplexeren Prototypen kostenintensiv sein kann. Auch nicht erkannte Fehler sind problematisch, da der fertige Prototyp gegebenenfalls bestimmte Verhalten nicht abdecken würde. Die durchgeführten Testdurchläufe haben außerdem gezeigt, dass der Agent von einem größeren Modell, wie GPT-5.5, nicht erheblich profitiert. Sollten Prototypen allerdings komplexer als die in dieser Arbeit behandelten werden oder die Anzahl an Zuständen sowie Übergängen erheblich steigen, könnte der Agent vom Wechsel zu einem stärkeren Modell profitieren. Wenn der Consistency Reviewer keine Probleme erkennt, kann die Pipeline zum nächsten Schritt, dem Unity-Validator, übergehen und die generierte Vivian-Spezifikation auf Laufzeitfehler überprüfen.

5.9 Unity-Validator

Nach der erfolgreichen Generierung der vier Vivian-Spezifikationsdateien sowie deren semantischer Validierung wird nun die strukturelle und laufzeitnahe Korrektheit im Unity-Validator kontrolliert. Dafür prüft er, ob die erzeugte Spezifikation in Unity deserialisiert und initialisiert werden kann. Dieser Schritt bezieht sich auf die funktionale Anforderung A3 (Validierung der Spezifikation). Das Modul erfüllt dafür zwei Kernaufgaben: Es führt eine JSON-Schema-Validierung durch, um zu prüfen, ob die Spezifikationsdateien strukturell korrekt aufgebaut sind, sowie eine Unity-Batchmode-Validierung, in der es versucht, den Prototypen in der Zielumgebung Unity zusammen mit Vivian zu starten. So können bereits innerhalb eines Versuchsdurchlaufs reproduzierbare Fehler gefunden werden, welche ohne Korrektur auch zur tatsächlichen Laufzeit aufgetreten wären. Sollten Fehler im Unity-Validator aufkommen, gibt dieser eine strukturierte Fehlerliste an einen Reparatur-Agenten (Fixer-Agent) weiter, welcher über einen Reparaturplan eine gezielte Wiederausführung der betroffenen Agenten im Specification-Generator einleitet. So kann, falls möglich, eine vollständige Neugenerierung der Spezifikation vermieden werden. Dieser Teilschritt adressiert A4 (iterative Fehlerkorrektur).

Eingaben und Verarbeitungsschritte

Das Modul erhält die vier zuvor generierten Spezifikationsdateien über ein Verzeichnis, in welchem sie vom Specification Generator abgelegt wurden, sowie eine Schema-Datei der *Functional Specification*, welche zur JSON-Schema-Validierung genutzt wird.

Um Fehler auch in diesem Schritt möglichst frühzeitig zu erkennen, wird in der ersten Stufe das JSON-Schema kontrolliert, welches jede der Dateien auf korrekte Werte und Zeichensetzung überprüft. Die hier entstehenden Fehler werden mit dem Vermerk „schema“ ge-

sammelt und weitergegeben. Im Anschluss daran beginnt Stufe zwei: die Unity-Batchmode-Validierung. Dafür wird anstelle des kompletten Projekts ein minimales und temporäres Unity-Projekt erstellt, in dem Unity als Subprozess ohne Grafik von einem Skript des Validator-Moduls ausgeführt wird. Intern liest Unity die Spezifikationsdateien im JSON-Format der Reihe nach mithilfe von `JsonUtility` ein, da dieser Unity-eigene Parser auch in der späteren tatsächlichen Umgebung verwendet wird. Auch hier muss die Reihenfolge aufgrund der Dateiabhängigkeiten (siehe Abbildung 5.7) beachtet werden, damit Teile der Spezifikation als Kontext für andere verwendet werden können. Wenn diese Deserialisierung fehlerfrei durchgelaufen ist, wird die `StateMachine` des Vivian-Frameworks gestartet. Weiterhin werden synthetische `GameObjects` gebaut sowie die verwendeten Element-Typen aus Vivian instanziiert. Somit wird die Instanziierungslogik für jedes einzelne Objekt tatsächlich ausgeführt und der Initialzustand angewendet. Sollten dabei Fehler wie ungültige Attribut-Werte oder fehlende Zustandsreferenzen auftreten, werden diese hier von Unity geworfen und abgespeichert. Nach beendeter Validierung wird das temporäre Projekt wieder gelöscht. Dieses Vorgehen vermeidet veraltete Versionen von Unity oder des Vivian-Frameworks, da die erforderlichen Dateien bei jedem Durchlauf aus dem Unity-Verzeichnis kopiert werden. Das Ergebnis des Unity-Validators wird in eine Datei mit Dateinamen `error-package.json` geschrieben, abgespeichert und kann somit von Folgeschritten zur gezielten Fehlerbehandlung verwendet werden.

Fixer-Agent

Sollten Unity-Validator oder Consistency-Reviewer Fehler melden wird ein LLM-gesteuerter Fixer-Agent mit einem Fehlerpaket als Eingabe aufgerufen, welcher Fehler in der Spezifikation nicht selbst behebt, sondern einen Korrekturplan mit gezielten Korrekturanweisungen entwirft. Dieser wird anschließend den Generierungsagenten als zusätzliche Eingabe im späteren Korrekturprozess mitgegeben. Die vollständigen Instruktionen des Fixer-Agenten sind in Anhang D zu finden. Dazu bekommt dieser Agent die Validierungsfehler aus dem Unity-Validator, Konsistenzprobleme aus dem Consistency Reviewer, das vollständige Registry-Objekt sowie den Interaktionsplan als Eingaben. Der Agent verwendet das Sprachmodell GPT-5.2, da er alle Eingaben gemeinsam interpretieren, Ursachen aus Symptomen ableiten und abwägen muss, ob eine vollständige Neugenerierung oder einzelne Reparaturen durchgeführt werden müssen. Eine fehlinterpretierte Reparaturmaßnahme kann zudem zusätzliche Token-Kosten verursachen, da weitere Versuche verbraucht werden oder dadurch zusätzliche Fehler entstehen.

Neugenerierung und Abschluss

Zur Weiterverarbeitung des Reparaturplans bekommen nicht alle Generierungsagenten den gesamten Plan, sondern nur den Teil einer Spezifikation, den der jeweilige Agent selbst generiert. Wenn also Fehler in `states.json` und `transitions.json` aufgetreten sind, bekommt der States-Agent nur die Informationen, die `states.json` betreffen. So wird Verwirrung durch irrelevante Fehler vermieden. Sollte der Fixer-Agent selbst fehlschlagen oder während des Prozesses abbrechen, bekommen die Generierungsagenten die rohen Validator-Fehler als Kontext. In der Entwicklung dieser Arbeit ist dies allerdings nicht vorgekommen.

Nachdem der Fixer-Agent ein Fehlerpaket mit Dateinamen `fix_plan.json` und Korrekturmaßnahmen erfolgreich generiert hat, werden programmatisch genau die Schritte als „dirty“ markiert, welche neu ausgeführt werden müssen sowie die davon abhängigen. Wenn z. B. also Fehler in den Zuständen erkannt wurden, müssen die Dateien `states.json` sowie `transitions.json` erneut generiert werden. Auch hier wird ein neuer Versuch nur dann tatsächlich gestartet, wenn die Maximalanzahl der Versuche noch nicht erreicht ist. Sollten im Unity-Validator-Schritt keine Fehler erkannt worden sein, geht die Pipeline in den letzten Schritt über: die *Publishing-Phase*. In dieser werden die nun auf semantische, syntaktische sowie referenzielle Fehler überprüften Spezifikationsdateien an den lokalen Ort exportiert, der anfangs in der Unity UI angegeben wurde. Dieser Schritt markiert den Abschluss eines Durchlaufs und damit eines erfolgreichen Generierungsprozesses. Da das statische GameObject nun mit einer vollständigen Vivian-Spezifikation angereichert wurde, ist die Transformation zu einem interaktiven Prototypen abgeschlossen.

Kapitel 6

Evaluation

In diesem Kapitel wird die in Kapitel 5 umgesetzte Pipeline empirisch überprüft. Zunächst werden dazu Evaluationsziel, Untersuchungsdesign und Testassets festgelegt. Anschließend wird der Workflow an einem Beispiel vollständig nachvollzogen und in wiederholten Durchläufen auf seine Robustheit hin untersucht, bevor der Beitrag der Validierungs- und Korrekturmechanismen, die Einordnung der Ergebnisse sowie die Grenzen der Evaluation betrachtet werden.

6.1 Evaluationsziel und Untersuchungsdesign

Ziel der Evaluation ist es, die in der vorliegenden Arbeit entwickelte Pipeline zur Generierung interaktiver Vivian-Prototypen systematisch zu untersuchen. Im Mittelpunkt steht dabei nicht die Bewertung der Bedienbarkeit durch externe Benutzer*innen, sondern die technische Funktionsfähigkeit des prototypisch umgesetzten Workflows. Daher wird die Evaluation als technische, szenariobasierte Systemevaluation durchgeführt. Sie prüft, ob aus den definierten Eingaben vollständige Vivian-Spezifikationen generiert werden können und ob das damit ermöglichte Verhalten dem zuvor festgelegten Referenzszenario entspricht.

In der Evaluation werden drei Aspekte betrachtet. Es wird geprüft, ob der VSG grundsätzlich in der Lage ist, aus vorhandenen 3D-Objekten ausführbare Prototypen zu erzeugen. Anschließend wird im zweiten Schritt bewertet, ob relevante Teilobjekte, Rollen, Zustände und Übergänge wie erwartet aus dem Asset und der Interaktionsbeschreibung abgeleitet werden. Drittens wird schließlich untersucht, welchen Beitrag die Validierungs- und Korrekturmechanismen zur Verringerung von Fehlern leisten. Damit wird die Evaluation der in dieser Arbeit entwickelten Pipeline nicht nur auf einzelne Beispielausgaben reduziert, sondern betrachtet inhaltliche Qualität der erzeugten Vivian-Spezifikationen sowie die Robustheit des Workflows.

Zur Evaluation der in dieser Arbeit entwickelten Pipeline sollen verschiedene Assets systematisch getestet werden. Es werden dazu drei Testassets mit unterschiedlicher Komplexität

betrachtet: eine Lampe, ein Display und ein Toaster. Für jedes dieser Assets wird ein Szenario definiert, welches die erwarteten Teilobjekte, Rollen, Zustände, Übergänge und visuellen Reaktionen beschreibt. Da verschiedene valide Vivian-Spezifikationen dasselbe Verhalten abbilden können, bildet es einen verhaltensbezogenen Maßstab zur Bewertung, mit welchem schließlich die generierten Ergebnisse eingeordnet werden können.

Das Untersuchungsdesign beinhaltet qualitative sowie quantitative Bestandteile und ist entlang der Forschungsfragen aus 1.2 aufgebaut. Anhand eines Testassets wird zunächst untersucht, wie der VSG von Anfang bis Ende arbeitet und ob ein valider Vivian-Prototyp entsteht. Insbesondere die technische Umsetzbarkeit von F1 (Co-Creation-Workflow) wird damit adressiert. Die Bewertung erkannter Teilobjekte und zugewiesener Rollen bezieht sich auf F2 (Ableitung relevanter Objekte). F3 (Extraktion von Interaktionslogik) wird mit der Analyse der erzeugten Zustände, Übergänge und visuellen Verhaltensänderungen adressiert. Es werden weiterhin wiederholte Durchläufe mit identischen Eingaben durchgeführt, um die Stabilität der Pipeline zu bewerten. Außerdem wird die vollständige Generierungspipeline mit einer Erstgenerierung ohne Korrekturschleife verglichen. Damit wird untersucht, ob Consistency Reviewer, Validator und Fixer-Agent die Anzahl der Fehler reduzieren und die Erfolgsquote der finalen Vivian-Spezifikation erhöhen.

6.2 Testassets und Referenzszenarien

Zur Evaluation des VSG wurden drei Assets ausgewählt: eine Lampe, ein Display und ein Toaster. Dabei steht nicht die Untersuchung einer möglichst großen Menge unterschiedlicher Objekte im Fokus, sondern eine gezielte Auswahl aussagekräftiger Beispiele. Diese ermöglicht es, die Funktionsfähigkeit des VSG über verschiedene Komplexitätsstufen sowie unterschiedliche Anforderungen zu prüfen. Die drei Assets dienen als Grundlage für eine szenariobasierte Evaluation, bei der die erzeugten Spezifikationen mit den zuvor festgelegten Verhaltenserwartungen als Referenz verglichen werden.




Abbildung 6.1: Beispiele virtueller 3D-Objekte.

Die drei Assets unterscheiden sich hinsichtlich ihrer funktionalen sowie strukturellen Komplexität, wodurch der Workflow nicht nur an einem einfachen Erfolgsbeispiel, sondern anhand verschiedener Testfälle mit steigender Komplexität und Anforderungen gezeigt werden kann. Die Lampe bildet das einfachste Beispiel ab, da hier nur eine Interaktion sowie eine visuelle Reaktion erwartet werden. Einen mittleren Schwierigkeitsgrad stellt das Display dar, da hier verschiedene Bedienelemente und eine Screen-Fläche erkannt sowie in Beziehung zueinander gesetzt werden müssen. Abschließend bietet der Toaster das komplexeste Beispiel, da hier mehrere Teilobjekte, unterschiedliche visuelle Rückmeldungen, verschiedene Zustände sowie ein zeitbasierter Übergang miteinander funktionieren müssen. Um eine endlose Wiederholungsschleife im Korrekturprozess zu vermeiden, wurde zudem eine maximale Versuchsanzahl von fünf Versuchen gewählt.

Für die Bewertung der Pipeline sind verschiedene Kriterien relevant, anhand derer die Auswahl der Testassets erfolgte. Ein erstes Kriterium ist die Auswahl relevanter Teilobjekte. Je mehr Teilobjekte ein Asset besitzt, desto anspruchsvoller ist es für den VSG, jene Bestandteile zu identifizieren, die tatsächlich relevant für die gewünschte Interaktion sind. Bei der Lampe betrifft das den Knopf sowie den Lampenschirm bzw. die Lichtquelle. Beim Display hingegen müssen bereits mehrere Bedienelemente sowie eine Screen-Fläche erkannt und unterschieden werden. Das Toaster-Beispiel enthält zusätzlich einen Hebel, eine Stopp-Taste sowie Heizelemente zur Visualisierung.

Ein zweites Kriterium beschreibt die Anzahl und Art der erwarteten Rollen. Nicht nur muss die Pipeline relevante Objektbestandteile erkennen, sondern diese später auch passenden funktionalen Vivian-Rollen zuordnen. Während die Lampe mit zwei Arten von Interaktions- sowie Visualisierungselementen (Button und Light) auskommt, benötigt das Display neben mehreren Eingabeelementen (Buttons) auch ein Screen-Element, um Inhalte tatsächlich anzuzeigen. Beim Toaster müssen unterschiedliche Rollen erkannt werden, wie Hebel und Stopp-Taste als Bedienelemente (Slider und Button) sowie visuelle Elemente wie LED und Heizelemente als Lights.

Auch die Komplexität der Interaktionslogik stellt ein Auswahlkriterium dar. Weniger komplexe Prototypen kommen mit weniger komplexer Logik aus. Beim Lampen-Beispiel schaltet ein Knopfdruck das Licht an oder aus. Komplexere Prototypen wie das Display benötigen wiederum bereits mehrere voneinander unterscheidbare Aktionen. Ein Knopf schaltet das Display an oder aus und weitere Knöpfe ermöglichen ein Wechseln zwischen verschiedenen Seiten. Der Toaster enthält zudem eine zeitbasierte Komponente, welche es ermöglicht, einen Toastvorgang wahlweise per Tastendruck oder nach einer fest definierten Zeit zu beenden. Dieser Fall umfasst neben direkten Interaktionen somit auch eine automatische Zustandsänderung nach Ablauf einer definierten Zeit.

Außerdem wurden unterschiedliche visuelle Rückmeldungen berücksichtigt. Für die Evaluation ist dies wichtig, da ein Prototyp intern korrekt umgesetzte Zustände und Zustandsüber-

gänge nachvollziehbar für Nutzer*innen veranschaulichen soll. Die Lampe verwendet dafür das Leuchten des Lampenschirms. Das Display-Beispiel nutzt die Darstellung der Screen-Inhalte und der Toaster simuliert das Glühen der Heizelemente sowie das Leuchten einer LED während des Toastvorgangs.

Die Assets wurden demnach so gewählt, dass sie eine aufsteigende Komplexität abbilden. Sie reichen von einer einfachen Interaktion mit direkter visueller Rückmeldung über einen Prototyp mit mehreren Bedienelementen hin zu einem Objekt mit mehreren Funktionen, Zuständen und Übergängen. Tabelle 6.1 fasst die ausgewählten Assets, ihre Komplexität sowie die jeweils erwartete Hauptfunktion zusammen.

Asset	Komplexität	Erwartete Hauptfunktion
Lampe	leicht	Der Lampenschirm soll als Lichtquelle leuchten. Ein Knopf soll die Lampe an- bzw. ausschalten.
Display	mittel	Das Display soll ein- und ausgeschaltet werden können, Screen-Inhalte anzeigen sowie zwischen Seiten wechseln können.
Toaster	schwer	Der Toastvorgang soll durch den Hebel gestartet, mittels LED und Heizelementen visualisiert sowie nach zehn Sekunden oder durch Drücken der Stopp-Taste beendet werden.

Tabelle 6.1: Übersicht der ausgewählten Testassets.

Neben den Referenzszenarien ist für die Nachvollziehbarkeit der Evaluation relevant, welche natürlichsprachlichen Interaktionsbeschreibungen dem VSG als Eingabe übergeben wurden. Die Listings 6.1 bis 6.3 zeigen die verwendeten Eingabeprompts je Testasset. Diese bildeten zusammen mit den vorverarbeiteten Szenendaten die Grundlage für Szenenanalyse, Interaktionsplanung und die Spezifikationsgenerierung.

"This is a light switch and a lamp. When the light switch is pressed, the lamp should toggle between on and off."

Listing 6.1: Eingabeprompt für das Testasset Lampe

```
"This is a display. It displays the provided images on a screen and has
three control buttons. The three control buttons will be used to: 1) go
to the previous picture 2) turn the display on and off and 3) go the
the next picture. The next/previous buttons should cycle through the
pictures endlessly."
```

Listing 6.2: Eingabeprompt für das Testasset Display

```
"When the handle is pushed down, the toaster should start toasting. The
heating pipes should light up red when it toasts. Also an LED should
light up when it toasts. It should stop toasting after 10 seconds or
when the stop button is pressed."
```

Listing 6.3: Eingabeprompt für das Testasset Toaster

Tabelle 6.2 listet je Asset die erwarteten Teilobjekte mit Kategorie und Vivian-Rolle auf, Tabelle 6.3 die erwarteten Zustände und Tabelle 6.4 fasst die erwarteten Übergänge zusammen. Diese Referenzszenarien dienen in den nachfolgenden Abschnitten als verhaltensbezogener Maßstab, an dem die generierten Vivian-Spezifikationen und das beobachtete Prototypverhalten gemessen werden.

Asset	Relevante Teilobjekte	Kategorie	Erwartete Vivian-Rollen
Lampe	Cube1	Interaktion	Button
	Cylinder1	Visualisierung	Light
Display	ButtonPower	Interaktion	ToggleButton
	ButtonBack, ButtonForward	Interaktion	Button
	DisplayContent	Visualisierung	Screen
Toaster	Handle	Interaktion	Slider
	StopButton	Interaktion	Button
	Heating_resistors, LED	Visualisierung	Light

Tabelle 6.2: Relevante Teilobjekte, Kategorien und erwartete Vivian-Rollen der Testassets.

Asset	Erwartete Zustände	Beschreibung
Lampe	<code>lightOn</code>	Lampe ist angeschaltet.
	<code>lightOff</code>	Lampe ist ausgeschaltet.
Display	<code>powerOff</code>	Display aus, kein Bildinhalt.
	<code>imageOne</code>	Display an, erstes Bild.
	<code>imageTwo</code>	Display an, zweites Bild.
	<code>imageThree</code>	Display an, drittes Bild.
Toaster	<code>idle</code>	Toaster inaktiv, Heizstäbe aus, LED aus.
	<code>toasting</code>	Hebel gedrückt, Heizstäbe leuchten rot, LED leuchtet.

Tabelle 6.3: Erwartete Zustände der Testassets.

Asset	Erwartete Übergänge	Trigger
Lampe	<code>lightOff</code> → <code>lightOn</code>	<code>Cube1</code>
	<code>lightOn</code> → <code>lightOff</code>	<code>Cube1</code>
Display	<code>powerOff</code> → <code>imageOne</code>	<code>ButtonPower</code>
	<code>imageOne/imageTwo/imageThree</code> → <code>powerOff</code>	<code>ButtonPower</code>
	<code>imageN</code> → <code>imageN+1</code> (3→1)	<code>ButtonForward</code>
	<code>imageN</code> → <code>imageN-1</code> (1→3)	<code>ButtonBack</code>
Toaster	<code>idle</code> → <code>toasting</code>	<code>Handle</code>
	<code>toasting</code> → <code>idle</code>	<code>StopButton</code> , Timeout (10s)

Tabelle 6.4: Erwartete Übergänge der Testassets.

6.3 Exemplarischer Workflow-Durchlauf

Zunächst wird ein exemplarischer Einzeldurchlauf beschrieben, um die Funktionsweise des VSG nicht nur abstrakt, sondern anhand eines vollständigen Generierungsprozesses zu zeigen. Ziel ist die Nachvollziehbarkeit eines Durchlaufs von Eingabe bis validierter Spezifikation. Dafür wurde das Display-Asset ausgewählt, da es einen mittleren Schwierigkeitsgrad darstellt, mehrere Bedienelemente (Buttons), eine Screen-Fläche als Visualisierungsobjekt und mehrere Zustände besitzt, aber noch übersichtlicher als das Toaster-Beispiel ist. Die Hierarchie des Display-Assets ist in Abbildung 6.2 abgebildet und zeigt die verschiedenen Bedienelemente sowie die Screen-Fläche.




Abbildung 6.2: Hierarchie des Display-Assets in der Unity-Szene.

Die natürlichsprachliche Eingabe in der Vorverarbeitung sowie die Prüfung des Interaktionsplans durch Benutzende zeigen den Co-Creation-Workflow. Weiterhin wird gezeigt, dass Teilobjekte und Elementrollen von der Pipeline erkannt werden. Indem Zustände, Übergänge sowie sichtbare Screen-Wechsel vom VSG geplant und schließlich umgesetzt werden, wird gezeigt, dass Interaktionslogiken aus der natürlichsprachlichen Interaktionsbeschreibung und bestehenden 3D-Geometrien extrahiert und in eine maschinenlesbare Repräsentation überführt werden können. Der hier betrachtete Fall stellt eine positive Referenz dar, da der Durchlauf im ersten Versuch zu einer validierten Vivian-Spezifikation gelangte. In diesem Unterkapitel wird zunächst die grundlegende Machbarkeit des Workflows gezeigt. Es wird daraus jedoch noch keine allgemeine Aussage über die Robustheit oder Wiederholbarkeit abgeleitet. Dazu werden anschließend mehrere Durchläufe betrachtet.

6.3.1 Eingabe und Referenzszenario

Die KI-gestützte Pipeline erhielt die vorverarbeitete Szene, bestehend aus JSON- und Bilddateien, drei Bilddateien, um diese auf dem Bildschirm anzuzeigen, sowie eine natürlichsprachliche Beschreibung des gewünschten Verhaltens. Darin wurde das Asset als Display

mit drei Knöpfen zur Steuerung und einem Bildschirm beschrieben. Die Knöpfe sollten dazu dienen, das Display ein- und auszuschalten sowie zum vorherigen beziehungsweise zum nächsten Bild zu wechseln. Zusätzlich wurde festgelegt, dass die Navigation durch die Bilddateien endlos stattfinden soll, sodass Bild drei beispielsweise über eine Vorwärtsnavigation wieder zu Bild eins wechselt. Daraus ergab sich ein Referenzszenario mit vier Teilobjekten, vier Zuständen und zehn Übergängen, welches in den Tabellen 6.2, 6.3 und 6.4 dokumentiert ist.

Weiterhin wurden vier erwartete Zustände definiert: ein Zustand, in dem der Bildschirm ausgeschaltet ist und kein Bild angezeigt wird sowie ein Zustand je anzuzeigendem Bild. Aus diesen Zuständen ergaben sich weiterhin zehn erwartete Übergänge. Der Power-Button sollte aus dem ausgeschalteten Zustand in den ersten Bildzustand wechseln sowie aus jedem Bildzustand zurück in den ausgeschalteten Zustand. Der Button zur Vorwärtsnavigation sollte von Bild eins zu Bild zwei, von Bild zwei zu Bild drei und schließlich wieder von Bild drei zu Bild eins wechseln, um ein zyklisches Wechseln zwischen den Bildern zu ermöglichen. Der Button zur Rückwärtsnavigation sollte dieselbe Bildmenge in umgekehrter Richtung durchlaufen. Die erwarteten Zustände und Übergänge sind außerdem in den Tabellen 6.3 und 6.4 zusammengefasst.

6.3.2 Szenenanalyse und Interaktionsplanung

Im ersten LLM-gestützten Schritt der Pipeline, dem Scene Analyzer, wurden aus der Szene neun Objekte, zwölf Relationen, vier Cluster und drei verfügbare Bilddateien extrahiert. Besonders relevant waren hier die Objekte `DisplayContent`, `ButtonBack`, `ButtonPower` und `ButtonForward`. Damit waren alle für das Referenzszenario notwendigen Teilobjekte identifiziert. Alle übrigen erkannten Objekte wie etwa `Display`, `DisplayHousing`, `DisplayPlane`, `Frame` und `Controls`, beschreiben die hierarchische und räumliche Struktur des Assets und wurden demnach nicht als eigenständige Interaktions- oder Visualisierungselemente benötigt.

Auf Grundlage dieser Szenenanalyse erzeugte der Interaction Planner einen Interaktionsplan mit vier Elementrollen, vier Zuständen sowie zehn Übergängen, welche genau den erwarteten Elementrollen, Zuständen und Übergängen entsprachen. Dabei wurden `ButtonBack` und `ButtonForward` als `Button`, `ButtonPower` als `ToggleButton` und `DisplayContent` als `Screen` geplant. Außerdem wurden alle vier Spezifikationsdateien als benötigt markiert. Der Interaktionsplan entsprach somit genau dem zuvor definierten Referenzszenario, weshalb der Plan im Human-in-the-Loop-Schritt direkt akzeptiert wurde, ohne dass eine Neugenerierung stattfand.

6.3.3 Spezifikationsgenerierung und Validierung

Auf Basis dieses bestätigten Interaktionsplans generierte der Specification Generator im darauffolgenden Schritt alle für die Ausführung in Vivian benötigten Spezifikationsdateien. Dafür wurden in `InteractionElements.json` die drei im Plan vorgesehenen Interaktionselemente angelegt. Für `ButtonPower` (ToggleButton) wurde zusätzlich ein Initialwert gesetzt, um den ausgeschalteten Anfangszustand des Bildschirms abzubilden. In `VisualizationElements.json` wurde als einziges Element `DisplayContent` als Screen angelegt, ebenfalls wie im Plan vorgesehen. Zudem entstanden vier Zustände in `States.json`. Ein initialer Zustand `displayOff.state` setzt die Sichtbarkeit von `DisplayContent` auf 0,0 und verknüpft `ButtonPower` mit dem Wert `false`. Die drei Bildzustände setzen `DisplayContent` jeweils auf 1,0 und `ButtonPower` mit dem Wert `true`. Außerdem referenzieren sie jeweils eine der drei zur Verfügung gestellten Bilddateien, um diese auf dem Bildschirm anzuzeigen. In `Transitions.json` wurden alle zehn geplanten Übergänge umgesetzt und jeweils `BUTTON_PRESS` als auslösendes Ereignis festgelegt. Weiterhin wurden je Übergang die geplanten Buttons als Interaktionselemente modelliert, um einen Übergang durchzuführen, wenn das Ereignis `BUTTON_PRESS` auftritt.

Der Consistency Reviewer bewertete die dateiübergreifende Konsistenz, Erreichbarkeit aller Zustände sowie die Abdeckung des Interaktionsplans als korrekt. Er erkannte zudem ein Mehrdeutigkeitsrisiko in der Modellierung des Power-Buttons. Diese Warnung bezog sich darauf, dass `ButtonPower` als ToggleButton verwendet wird und explizite Zustandsbedingungen verwendet. Die Übergänge, welche diesen Button verwenden, besitzen jedoch selbst keine Guards. Diese Warnung wurde jedoch nicht als Fehler gewertet, sodass anschließend die Unity-Validierung durchgeführt werden konnte. Diese wurde ebenfalls im ersten Versuch erfolgreich abgeschlossen und bestätigte die generierten Spezifikationsdateien, da keine Schema-, Referenz- oder Initialisierungsfehler auftraten. Der Fixer-Agent wurde demzufolge nicht aufgerufen. Insgesamt benötigte der Generierungsdurchlauf einen Versuch, um zu einem validen Endergebnis zu gelangen.

6.3.4 Resultierender Prototyp und Einordnung

Das Verhalten des finalen Unity-Prototyps entsprach dem zuvor definierten Referenzszenario. Im Initialzustand ist der Bildschirm ausgeschaltet und zeigt keinen Bildinhalt an. Durch Drücken des Power-Buttons wird der erste Bildzustand erreicht und Bild eins angezeigt. Von diesem Zustand ausgehend kann durch die Betätigung von `ButtonForward` von Bild eins zu Bild zwei, von Bild zwei zu Bild drei und von Bild drei zu Bild eins gewechselt werden. Die Rückwärtsnavigation funktioniert nach dem gleichen Prinzip in umgekehrter Richtung. Die erwartete endlose zyklische Navigation durch alle Bilddateien wurde somit

durch die Zustands- und Übergangsstruktur abgebildet. Der Power-Button führt von jedem Bildzustand zurück in den ausgeschalteten Zustand.



Abbildung 6.3: Zustände des Display-Prototyps.

Dieser Durchlauf zeigt somit, dass der VSG in diesem Display-Beispiel relevante Teilobjekte und Elementrollen korrekt ableiten, eine Interaktionslogik mit verschiedenen Elementen, Zuständen und Übergängen planen, darauf basierend Vivian-kompatible Spezifikationsdateien erzeugen und diese anschließend validieren kann. Außerdem zeigt die vom Consistency Reviewer erzeugte Warnung, dass auch bei einer validen Generierung im ersten Versuch semantische Risiken auftreten können, welche nicht zwingend zu Validierungsfehlern führen. Der Durchlauf bildet demnach ein positives Referenzbeispiel für die grundsätzliche Funktionsfähigkeit des Workflows ab, ersetzt allerdings nicht die spätere Bewertung der Robustheit durch wiederholte Durchläufe und den Vergleich mit Versuchen ohne Korrekturmechanismen.

6.4 Wiederholte Durchläufe zur Robustheitsanalyse

Während der exemplarische Durchlauf das grundsätzliche Verhalten der Pipeline aufzeigt, wird im Folgenden durch wiederholte Durchläufe untersucht, wie stabil die Ergebnisse bei identischer Eingabe sind.

6.4.1 Vorgehen und Metriken

Zur Robustheitsbewertung wurde der VSG für jedes der drei Testassets jeweils 20-mal mit identischer Eingabe (je Asset) ausgeführt. Insgesamt wurden somit 60 Durchläufe betrachtet. Ziel dieser Auswertung ist nicht, einen einzelnen Durchlauf, wie in Abschnitt 6.3, im Detail nachzuvollziehen. Stattdessen soll herausgefunden werden, ob die Pipeline bei gleicher Aufgabenstellung und Eingabe wiederholt stabile Ergebnisse generiert. Daher wurden die finale Erfolgsquote der Generierung, die bestandene Unity-Validierung, welcher Art auftretende Fehler waren und wie häufig diese auftraten, die Anzahl benötigter Korrekturschleifen sowie abgeleitete Elementrollen, Zustände und Übergänge bewertet. Pro Durchlauf wurde

6.4 Wiederholte Durchläufe zur Robustheitsanalyse

zudem die in Abschnitt 6.2 eingeführte Obergrenze von fünf Versuchen angewandt, nach deren Überschreitung ein Versuch als gescheitert abgebrochen wurde.

Zur Auswertung der Durchläufe wurden drei Metriken definiert. Die *technische Erfolgsquote* beschreibt die Anzahl der Durchläufe, in denen eine Vivian-Spezifikation final erzeugt, in das angegebene Verzeichnis exportiert sowie von der Unity-Validierung bestätigt wurde. Sie besteht die Validierung und ist somit im Zielsystem lauffähig, kann aber dennoch teilweise vom erwarteten Verhalten abweichen. Die *funktionale Erfolgsquote* hingegen beschreibt den Anteil der Durchläufe, deren resultierender Unity-Prototyp zusätzlich das vorab definierte Referenzszenario vollständig erfüllt. Eine funktional erfolgreiche Spezifikation ist dabei auch technisch erfolgreich, der umgekehrte Schluss gilt jedoch nicht, da eine valide Spezifikation im Zielsystem ausgeführt werden kann, ohne das erwartete Verhalten exakt abzubilden. Die *durchschnittliche Versuchsanzahl* beschreibt die mittlere Anzahl benötigter Generierungsversuche bis zur erfolgreichen Generierung oder bis zum Abbruch nach fünf Versuchen. Tabelle 6.5 fasst die drei Metriken zusammen.

Metrik	Beschreibung
Technische Erfolgsquote	Anteil der Durchläufe mit final erzeugter, validierter und exportierter Spezifikation
Funktionale Erfolgsquote	Anteil der Durchläufe, deren Unity-Prototyp das Referenzszenario vollständig erfüllt
Durchschnittliche Versuchsanzahl	Mittlere Anzahl benötigter Generierungsversuche bis zum Erfolg oder Abbruch nach 5 Versuchen

Tabelle 6.5: Metriken der Robustheitsanalyse.

Die funktionale Bewertung erfolgte durch manuelle Ausführung des aus den generierten Spezifikationen resultierenden Prototyps im Zielsystem anhand des zuvor definierten Referenzszenarios. Dabei wurden die erwarteten Interaktionen systematisch ausgelöst und sichtbare Zustandsänderungen mit den Tabellen 6.2 bis 6.4 verglichen. Ein Durchlauf galt nur dann als funktional erfolgreich, wenn alle erwarteten Funktionen beobachtbar waren. Teilweise korrekte Prototypen wurden nicht als funktional erfolgreich gewertet, auch wenn sie technisch erfolgreich und ausführbar waren.

6.4.2 Ergebnisse der Robustheitsanalyse

Im Folgenden werden die Ergebnisse der 20 Durchläufe je Testasset zusammengefasst. Für jedes Asset werden zunächst die technische Erfolgsquote, die funktionale Erfolgsquote sowie die durchschnittliche Versuchsanzahl betrachtet. Anschließend werden auffällige Abweichungen und Fehlerursachen eingeordnet. Dadurch lässt sich erkennen, ob die Pipeline

bei identischer Eingabe stabile Ergebnisse liefert und an welchen Stellen Abweichungen im Generierungsprozess auftreten.

Testasset Lampe

Das Testasset der Lampe wurde in 18 von 20 Durchläufen innerhalb der maximalen Versuchsanzahl erfolgreich generiert. Damit betragen die technische und funktionale Erfolgsquote jeweils 90%. Jeder technisch erfolgreiche Prototyp verhielt sich entsprechend dem Referenzszenario. In diesen Fällen schaltete der Button zwischen ein- und ausgeschaltetem Zustand, der Lampenschirm leuchtete, wenn die Lampe eingeschaltet war und Übergänge wurden ebenso korrekt umgesetzt. Im Mittel waren 1,65 Versuche nötig, um die Pipeline mit Erfolgsstatus zu beenden. Fünf Durchläufe benötigten mindestens eine Korrekturschleife. Davon konnten drei Durchläufe nach zwei bzw. drei Versuchen erfolgreich abgeschlossen werden. Zwei Durchläufe erreichten die maximale Versuchsanzahl von fünf und schlugen deshalb fehl. Die Wiederholungszyklen betrafen dabei überwiegend die Generierung der Übergänge.

Asset	Technische Erfolgsquote	Funktionale Erfolgsquote	Durchschnittliche Versuchsanzahl
Lampe	18/20 (90%)	18/20 (90%)	1,65

Tabelle 6.6: Ergebnisse der Robustheitsanalyse: Testasset Lampe.

Auffällig ist, dass die beiden fehlgeschlagenen Durchläufe nicht an relevanten Teilobjekten scheiterten, sondern an der Umsetzung von Zustands- bzw. Übergangslogik. Der Consistency Reviewer erkannte fehlerhafte Guards in den Übergängen, welche dazu geführt hätten, dass der Initialzustand nicht verlassen werden kann. Zudem verwendeten diese Durchläufe ein ToggleButton-Element statt des erwarteten Button. Diese Typabweichung trat ebenfalls in vier erfolgreichen Durchläufen auf, hatte dort hingegen keine funktionale Auswirkung. Der Prototyp verhielt sich in diesen Fällen wie erwartet. Dieses Beispiel zeigt, dass auch einfache Prototypen mit vergleichsweise geringer Interaktionslogik von spezifischen Generierungsfehlern betroffen sein können.

Testasset Display

Beim Display-Asset wurde in allen durchgeführten Durchläufen im ersten Versuch eine technisch erfolgreiche Spezifikation generiert und durch den Unity-Validator bestätigt. Auch die relevanten Teilobjekte ButtonBack, ButtonPower, ButtonForward und DisplayContent wurden vollständig erkannt sowie mit den erwarteten Vivian-Rollen abgebildet. Ebenfalls

6.4 Wiederholte Durchläufe zur Robustheitsanalyse

konnten die vier erwarteten Zustände und zehn erwarteten Übergänge in allen Durchläufen strukturell erzeugt werden. Auch die Bildinhalte wurden den entsprechenden Zuständen korrekt zugeordnet. Die funktionale Erfolgsquote fällt jedoch deutlich niedriger aus, da nur 4 von 20 erzeugten Prototypen das Referenzszenario vollständig erfüllten. 16 Durchläufe waren zwar technisch lauffähig im Zielsystem, jedoch funktional nur teilweise korrekt und somit im Verhalten anders als im Referenzszenario. Korrekturschleifen traten beim Display-Asset nicht auf. Alle 20 Durchläufe wurden im ersten Versuch abgeschlossen, weshalb die durchschnittliche Versuchsanzahl bei 1,00 liegt.

Asset	Technische Erfolgsquote	Funktionale Erfolgsquote	Durchschnittliche Versuchsanzahl
Display	20/20 (100%)	4/20 (20%)	1,00

Tabelle 6.7: Ergebnisse der Robustheitsanalyse: Testasset Display.

Die Abweichungen lagen nicht in der Erkennung von Teilobjekten oder in den Übergängen, sondern in der semantischen Umsetzung der Zustände. Insbesondere der ausgeschaltete Zustand wurde teilweise unvollständig oder fehlerhaft modelliert. In 8 von 20 Durchläufen enthielt dieser Zustand weiterhin einen sichtbaren Bildinhalt. In weiteren 6 Durchläufen wurde der ausgeschaltete Zustand zwar angelegt, jedoch nicht durch eine Bedingung abgesichert, in der ButtonPower ausgeschaltet ist. Zusätzlich fehlte in 13 Durchläufen bei den Bildzuständen eine eindeutige Bedingung, dass ButtonPower eingeschaltet ist. In diesen Fällen war visuell nicht erkennbar, wann sich das Display tatsächlich im ausgeschalteten Zustand befand, da weiterhin Bildinhalte angezeigt wurden oder der Power-Zustand nicht eindeutig gesetzt wurde. Dem hätte in einem Einzeldurchlauf entgegengewirkt werden können, indem im Human-in-the-Loop-Schritt gezielt Anpassungen am Interaktionsplan vorgenommen worden wären. Das Display-Beispiel zeigt damit deutlich, dass eine technisch valide und strukturell vollständige Spezifikation nicht immer auch ein vollständig korrektes Prototypverhalten garantiert.

Testasset Toaster

Der Toaster bildet unter den betrachteten Beispielen den komplexesten Fall, da mehrere Teilobjekte, Interaktionstypen und visuelle Rückmeldungen in einem zeitabhängigen Ablauf kombiniert werden. In den 20 Durchläufen wurden die erwarteten Zustände idle und toasting sowie alle drei erwarteten Übergänge grundsätzlich stabil erzeugt. Dadurch wurde das Starten, Abbrechen über den Stopp-Knopf sowie das zeitbedingte Beenden des Toastvorgangs ermöglicht. Technisch erfolgreich wurden 19 von 20 Durchläufen abgeschlossen und vom Unity-Validator akzeptiert. Funktional erfolgreich waren 15 von 20 Durchläufen, während 4 Durchläufe nur teilweise korrekt waren. Die durchschnittliche Versuchsanzahl lag bei 1,25.

Zwei Durchläufe lösten mehrere Wiederholungszyklen aus. Einer davon erreichte schließlich die maximale Versuchsanzahl von fünf. In diesem Fall war die Generierung der Übergänge betroffen. Die geringe durchschnittliche Versuchsanzahl zeigt damit, dass der VSG das komplexere Toaster-Asset in den meisten Fällen ohne interne Reparaturschleifen erzeugen konnte.

Asset	Technische Erfolgsquote	Funktionale Erfolgsquote	Durchschnittliche Versuchsanzahl
Toaster	19/20 (95%)	15/20 (75%)	1,25

Tabelle 6.8: Ergebnisse der Robustheitsanalyse: Testasset Toaster.

Die funktionalen Abweichungen betrafen vor allem die Typisierung der visuellen Elemente, da Heizstäbe oder LED in mehreren Durchläufen als *AppearingObject* statt als Light modelliert wurden. Nur ein Durchlauf führte nicht zu einem final lauffähigen Prototyp. In diesem Fall markierte der Consistency Reviewer den Übergang von idle zu toasting wiederholt als fehlerhaft, da der verwendete Slider-Trigger nicht ausreichend durch einen Value-Guard abgesichert war. Dadurch hätte ein Toastvorgang unabhängig von der tatsächlichen Hebelposition ausgelöst werden können, obwohl das vollständige Herunterdrücken des Hebels erwartet wurde. Das Toaster-Beispiel zeigt damit, dass die Pipeline auch komplexere Interaktionslogiken weitgehend stabil erzeugen kann, semantische Präzision bei Visualisierungselementen und Guards jedoch weiterhin eine Fehlerquelle bleibt.

Über alle drei Testassets zeigt sich, dass der VSG in 57 von 60 Durchläufen technisch erfolgreiche Spezifikationen erzeugte. Die funktionale Erfolgsquote lag jedoch niedriger, da insbesondere beim Display und in Teilen auch beim Toaster technisch valide Spezifikationen nicht immer vollständig dem Referenzszenario entsprachen. Die relevanten Teilobjekte, Zustände und Übergänge wurden über alle Beispiele hinweg weitgehend stabil erzeugt. Vor allem durch semantische Entscheidungen in der Spezifikation, etwa bei Zustandsbedingungen, Guards oder in der Typisierung visueller Elemente, entstanden beobachtete Abweichungen. Damit zeigt die Robustheitsanalyse, dass der VSG formal valide Spezifikationen zuverlässig erzeugen kann, eine zusätzliche funktionale Prüfung des resultierenden Prototyps aber weiterhin notwendig bleibt.

Die Betrachtung der Korrekturschleifen zeigt insgesamt, dass diese nur in wenigen Durchläufen erforderlich waren. 54 von 60 Durchläufen waren bereits im ersten Versuch abgeschlossen. Von den übrigen sechs Durchläufen betrafen fünf die Lampe und einer den Toaster. Drei dieser Wiederholungen erreichten dabei die maximale Versuchsanzahl und scheiterten, während die restlichen erfolgreich repariert werden konnten.

6.5 Validierungs- und Korrekturmechanismen

Forschungsfrage F4 (Validierung und Korrektur) fragt danach, in welchem Ausmaß Validierungs- und Selbstkorrekturmechanismen syntaktische, semantische und referenzielle Fehler sowie fehlgeschlagene Unity-Validierungen im Vergleich zu einem Erstgenerierungsdurchlauf ohne Korrekturschleife reduzieren. Um diese Frage zu beantworten, wurden die in Kapitel 6.4.2 betrachteten 60 Durchläufe dahingehend ausgewertet, ob ihr jeweils erster Versuch bereits eine technisch erfolgreiche Spezifikation erzeugt hätte. Diese rückblickende Auswertung erlaubt einen Vergleich zwischen dem hypothetischen Verhalten der Pipeline ohne Korrekturmechanismen und dem beobachteten Verhalten mit aktiven Korrekturmechanismen. Als im Erstversuch erfolgreich galten die Durchläufe, die maximal einen Versuch bis zur technisch korrekten Spezifikation benötigten.

Für das Lampen-Asset hätten 15 von 20 Durchläufe ohne Korrekturmechanismen ein technisch erfolgreiches Ergebnis im Erstversuch erzeugt. Die übrigen fünf wurden vom Consistency Reviewer im ersten Versuch als fehlerhaft markiert. Drei dieser Durchläufe konnten im Anschluss erfolgreich durch eine Neugenerierung der Übergänge repariert werden. Dadurch stieg die technische Erfolgsquote von 75 auf 90 Prozent. Auffällig ist, dass alle fünf Korrekturschleifen auf dieselbe Ursache zurückgingen. `Cube1` wurde vom Interaction Planner als `ToggleButton` statt als `Button` typisiert, woraufhin der Consistency Reviewer anschließend widersprüchliche Übergangslogik erkannte. In drei Fällen konnte diese Inkonsistenz durch eine erneute Generierung der Übergänge aufgelöst werden, in zwei Fällen meldete der Consistency Reviewer das Problem wiederholt, ohne dass die Neugenerierung eine valide Korrektur erzeugen konnte. Demnach waren die Korrekturmechanismen in diesem Beispiel in der Lage, einen Großteil der Typisierungsfehler zu beheben, jedoch nicht alle.

Beim Display zeigte sich ein anderes Bild. Hier wurden alle 20 Durchläufe im ersten Versuch sowohl vom Consistency Reviewer als auch vom Unity-Validator akzeptiert und die Korrekturmechanismen waren in keinem Durchlauf aktiv. Somit konnte in diesem Beispiel eine technische Erfolgsquote von 100 Prozent erreicht werden, mit und ohne Korrekturschleife. Gleichzeitig erreichten nur 4 von 20 Durchläufen die komplette funktionale Übereinstimmung mit dem Referenzszenario, was eine Grenze des Verfahrens aufzeigt. Die implementierten Mechanismen erkennen strukturelle und referenzielle Fehler zuverlässig, besitzen aber Schwächen bei semantisch mehrdeutigen oder unvollständigen Verhalten, obwohl die Spezifikation valide bleibt. In diesen Fällen liegt der Schwerpunkt der Fehlerkorrektur beim Human-in-the-Loop-Schritt des Interaction Planners, welcher in der Robustheitsanalyse bewusst nicht genutzt wurde.

Beim Toaster-Asset wurden 18 von 20 Durchläufen bereits im ersten Versuch erfolgreich abgeschlossen. Ein Durchlauf benötigte eine Korrekturschleife, um ein valides Endergebnis zu erzeugen. In dieser Korrektur wurde der Transitions-Agent erneut aufgerufen, nachdem

der Consistency Reviewer einen fehlenden Guard auf einem Slider-Auslöser als fehlerhaft markiert hatte. Ein anderer Durchlauf erreichte die Maximalanzahl von fünf Versuchen und scheiterte deshalb. Bei diesem wurde wiederholt der gleiche Fehlertyp vom Consistency Reviewer korrekt identifiziert und die entsprechende Datei vom Specification Generator neu-generiert, allerdings konnte dadurch keine semantisch korrekte Spezifikation innerhalb der fünf Versuche erzeugt werden. Die technische Erfolgsquote stieg in diesem Beispiel somit von 90 auf 95 Prozent. Auch hier zeigte sich, dass die implementierten Korrekturmechanismen diese Fehlerklasse je nach Kontext beheben oder zumindest erkennen können.

Zusammengefasst ergibt sich für alle 60 Durchläufe ein Anstieg der technischen Erfolgsquote von 88,3 Prozent ohne auf 95,0 Prozent mit aktiven Selbstkorrekturmechanismen. Insgesamt vier Durchläufe (6,7 Prozent) wurden durch gezielte Neugenerierung repariert, drei Durchläufe (5,0 Prozent) scheiterten trotz wiederholter Korrekturversuche. Tabelle 6.9 fasst diese Werte zusammen.

Asset	Erfolg im 1. Versuch	Final erfolgreich	Repariert	Gescheitert
Lampe	15/20 (75%)	18/20 (90%)	3	2
Display	20/20 (100%)	20/20 (100%)	0	0
Toaster	18/20 (90%)	19/20 (95%)	1	1
Gesamt	53/60 (88,3%)	57/60 (95%)	4	3

Tabelle 6.9: Wirkung der Korrekturmechanismen auf die technische Erfolgsquote

Aus dieser Auswertung lassen sich zur Beantwortung von F4 drei Beobachtungen ableiten. Erstens reduzieren die Validierungs- und Korrekturmechanismen die Anzahl fehlgeschlagener Durchläufe in der gegebenen Stichprobe messbar, allerdings in moderatem Umfang. Der Effekt von vier geretteten Durchläufen entspricht einem Anstieg der Erfolgsquote um 6,7 Prozentpunkte. Zweitens ist die Wirkung der Mechanismen stark asset- und fehlerabhängig. Während sie beim Lampen-Asset deutlich aktiv werden, greifen sie beim Display in keinem der durchgeführten Durchläufe. Drittens stoßen die Mechanismen an Grenzen, sobald derselbe Fehlertyp mehrfach reproduziert wird. Darüber hinaus können technisch valide Spezifikationen, welche nicht das vollständige Referenzverhalten abbilden, aber dennoch nicht vom Consistency Reviewer als fehlerhaft eingestuft werden, demzufolge auch nicht von den Korrekturmechanismen repariert werden. Im Kontext der vorliegenden Arbeit wären solche Fälle nicht durch Validierung, sondern durch den in 5.6 beschriebenen Human-in-the-Loop-Schritt im Interaction Planner adressierbar.

6.6 Einordnung der Ergebnisse

Die Evaluationsergebnisse zeigen, dass F1 (Co-Creation-Workflow) auf einer technischen Ebene positiv bewertet werden kann. Natürlichsprachliche Eingaben sind möglich und werden vom VSG berücksichtigt. Dieser erzeugt im Interaction Planner einen strukturierten Interaktionsplan und ermöglicht eine Prüfung dessen im Human-in-the-Loop-Schritt. Der bestätigte Plan wird anschließend in Vivian-Spezifikationsdateien überführt. Damit ist der Co-Creation-Workflow prototypisch umgesetzt. Da eine Nutzer*innenstudie nicht im Fokus dieser Arbeit stand, lässt sich jedoch keine Aussage über die Bedienbarkeit für nicht-technische Nutzer*innen ableiten.

F2 (Ableitung relevanter Objekte) wird durch die Ergebnisse weitgehend gestützt. Relevante Teilobjekte wurden über alle Testassets hinweg überwiegend stabil erkannt und den erwarteten Vivian-Rollen zugeordnet. Dies zeigt sich beim Lampen-Beispiel an Lichtschalter und -quelle, beim Display an den Bedientasten und der Screen-Fläche sowie beim Toaster an Hebel, Stopp-Taste, LED und Heizelementen. Beobachtete Abweichungen lagen weniger in der Objekterkennung und mehr in der späteren semantischen Gestaltung einzelner Teile der Spezifikation.

Ebenso kann F3 (Extraktion von Interaktionslogik) grundsätzlich positiv bewertet werden. Der VSG war in der Lage, aus vorhandenen 3D-Geometrien und natürlichsprachlichen Interaktionsbeschreibungen Zustände, Übergänge und sichtbare Verhaltensänderungen abzuleiten und in Vivian-Spezifikationsdateien zu überführen. Das Display zeigte, dass mehrere Bildzustände und eine zyklische Navigation durch diese abbildbar waren. Auch beim Toaster wird dies durch Start-, Stopp- und Timeout-Logik deutlich, während funktionale Abweichungen zeigen, dass strukturell vollständige und technisch valide Spezifikationen nicht zwangsläufig das erwartete Prototypverhalten korrekt abbilden. Die größte Einschränkung liegt bei den hier betrachteten Beispielen in der semantisch präzisen Ausgestaltung von Zustandsbedingungen, Guards und Visualisierungstypen.

F4 (Validierung und Korrektur) wurde bereits durch die gesonderte Auswertung in 6.5 beantwortet. Die Ergebnisse zeigen, dass diese Mechanismen einzelne fehlerhafte Durchläufe durch gezielte Neugenerierung reparieren und somit die technische Erfolgsquote messbar erhöhen können. Gleichzeitig bleibt ihre Wirkung abhängig vom jeweiligen Asset und Fehlertyp.

Zusammenfassend lässt sich die zentrale Forschungsfrage für die betrachteten Testszenarien grundsätzlich positiv beantworten. Der VSG kann vorhandene statische 3D-Objekte mittels natürlicher Sprache in Vivian-kompatible, interaktive Prototypen überführen, ohne vorhandene Geometrien zu ersetzen. Besonders stabil zeigte sich die Identifikation relevanter Teilobjekte durch die Module Scene Analyzer und Interaction Planner. Einschränkungen bestehen vor allem bei der semantischen Präzision einzelner Spezifikationsentscheidungen.

6.7 Grenzen der Evaluation

Die Evaluation ist als eine szenariobasierte, technische Systemevaluation angelegt und betrachtet mit den Testassets Lampe, Display und Toaster nur drei ausgewählte Beispiele. Dadurch können Aussagen über die grundsätzliche Funktionsfähigkeit und Robustheit des VSG innerhalb dieser Testfälle getroffen, allerdings keine allgemeingültige Aussage über beliebige Assets oder deutlich komplexere 3D-Szenen abgeleitet werden. Zudem wurde keine Nutzer*innenstudie durchgeführt, weshalb keine empirische Bewertung der tatsächlichen Bedienbarkeit für nicht-technische Nutzer*innen durchgeführt werden kann. Die funktionale Bewertung der erzeugten Spezifikationen und der daraus resultierenden Prototypen erfolgte manuell anhand der zuvor definierten Referenzszenarien, weshalb sie abhängig von der gewählten Bewertungsgrundlage bleibt. Außerdem zeigt insbesondere das Display-Beispiel, dass eine technisch valide und in Unity ausführbare Spezifikation nicht zwangsläufig auch ein korrektes Verhalten des finalen Prototyps garantiert, da semantische Abweichungen durch die vorhandenen Validierungsmechanismen nicht immer erkannt werden. Nachträgliche Einzeltests am Display-Asset deuten allerdings darauf hin, dass diese Abweichungen durch eine zusätzliche Bilddatei mit der Bezeichnung `displayOff.png` behoben werden können. Damit kann der Interaction Planner den ausgeschalteten Zustand explizit mit dieser Datei verknüpfen, sodass alle in den Einzeltests durchgeführten Durchläufe funktional korrekt waren.

Insgesamt zeigt die Evaluation, dass der VSG die in dieser Arbeit gestellten Forschungsfragen tragfähig adressiert, gleichzeitig macht sie jedoch erkennbar, an welchen Stellen das Verfahren auf zusätzliche Mechanismen oder eine stärkere Einbindung von Nutzer*innen angewiesen ist, um über die technische Korrektheit hinaus auch ein vollständig funktional erfolgreiches Verhalten abzubilden.

Kapitel 7

Ausblick und Fazit

Die vorliegende Arbeit hat den VSG prototypisch umgesetzt und in einer technischen Evaluation untersucht. Aus den in dieser Arbeit gewonnenen Erkenntnissen ergeben sich mehrere Ansatzpunkte für weiterführende Arbeiten.

7.1 Weiterführende Arbeiten

Eine offene Frage bleibt die Bedienbarkeit des VSG für nicht-technische Benutzer*innen. Die durchgeführte Evaluation hat die in dieser Arbeit entwickelte Pipeline ausschließlich technisch und szenariobasiert untersucht. Dies ließ keine Aussagen darüber zu, ob die Eingabe natürlichsprachlicher Beschreibungen und der Human-in-the-Loop-Schritt tatsächlich niedrigschwellig genug sind. Eine Nutzer*innenstudie mit Personen ohne Programmier- oder 3D-Modellierungskenntnisse wäre daher ein naheliegender nächster Schritt, um F1 (Co-Creation-Workflow) empirisch abzusichern. So könnten auch konkrete Schwachstellen in der Interaktion mit dem VSG identifiziert werden.

Weiterhin hat die Robustheitsanalyse aus Abschnitt 6.4.2 insbesondere beim Display-Asset einen deutlichen Unterschied zwischen technischer und funktionaler Erfolgsquote gezeigt. Eine Erweiterung des VSG könnte daher darin bestehen, den Dialog mit dem System auch nach der Ausführung des Prototyps fortzuführen. Nutzer*innen könnten damit das erzeugte Verhalten in Unity testen und anschließend beobachtete Verhaltensabweichungen in natürlicher Sprache beschreiben. Diese Korrekturanweisungen könnten dann an die Pipeline zurückgegeben und in einer gezielten Neugenerierung adressiert werden. Alternativ oder ergänzend wäre ein zusätzlicher Human-in-the-Loop-Schritt zwischen Consistency Reviewer und Unity-Validator denkbar, damit Nutzer*innen die generierte Spezifikation vor der Validierung in Unity und späteren Ausführung prüfen könnten.

Darüber hinaus könnte der Funktionsumfang des VSG noch mehr an die Möglichkeiten des Vivian-Frameworks angepasst werden. Die Spezifikationsdatei `VisualizationArrays.json`

wurde in dieser Arbeit zwar erzeugt, aber nicht inhaltlich genutzt. Eine weiterführende Arbeit könnte untersuchen, welche Funktionalität damit durch das Vivian-Framework abgebildet werden kann. Ebenso wäre eine Erweiterung auf bisher nicht oder nur eingeschränkt genutzte Vivian-Elementtypen, wie Movable-Objekte sowie Visualisierungen durch Animationen oder Partikelsysteme, denkbar. Dadurch könnten nicht nur Zustandswechsel von Licht, Sichtbarkeit oder Bildschirmen erzeugt werden, sondern auch bewegte und dynamischere Prototypen.

Ebenso wäre ein Run-übergreifendes Fehlergedächtnis ein weiterer sinnvoller Ansatz zur Verbesserung der Robustheit. Im aktuellen System werden Fehler innerhalb eines Durchlaufs protokolliert und für Korrekturen genutzt. Eine weiterführende Arbeit könnte untersuchen, ob wiederkehrende Fehlerklassen über mehrere Durchläufe hinweg gesammelt werden können, um diese als Wissensbasis für spätere Generierungen zu nutzen. Dadurch könnten beispielsweise zusätzliche Validierungsregeln oder automatische Anpassungen der Agentinstruktionen abgeleitet werden. Durch dieses Vorgehen würde der VSG nicht nur einzelne Fehler gezielt korrigieren, sondern langfristig aus wiederkehrenden Problemen lernen und die Stabilität der Pipeline schrittweise verbessern.

Schließlich könnte eine Skalierung auf komplexere Prototypen oder ganze Szenen mit mehreren interagierenden 3D-Assets vorgenommen werden. Der VSG wurde in dieser Arbeit anhand einzelner Assets evaluiert, allerdings nicht an Szenen mit mehreren aneinander gekoppelten Geräten. Solche Konstellationen würden zusätzliche Anforderungen an das System stellen und den Geltungsbereich deutlich erweitern.

7.2 Fazit

Die vorliegende Arbeit untersuchte, ob statische 3D-Objekte mithilfe eines KI-gestützten Workflows und natürlicher Sprache in interaktive Prototypen überführt werden können. Ausgangspunkt war das Problem, dass vorhandene statische 3D-Objekte häufig nur eine visuelle Form besitzen, nicht aber Interaktionsmöglichkeiten anbieten. Um eine interaktive Nutzung in virtuellen Welten zu ermöglichen, muss diese häufig manuell aufwändig modelliert oder programmiert werden. Die Arbeit setzte an dieser Stelle an und verfolgte das Ziel, einen Workflow zu entwerfen, der aus Szene, Bildern und natürlicher Sprache vollständige Vivian-Spezifikationen erzeugt.

Im Rahmen der Arbeit wurde dafür der Vivian Specification Generator konzipiert, prototypisch umgesetzt und technisch evaluiert. Der entwickelte Ansatz kombiniert dafür mehrere spezialisierte Verarbeitungsschritte. Zunächst werden die Struktur und Teilobjekte eines 3D-Objekts vom Scene Analyzer aufbereitet. Anschließend wird vom Interaction Planner auf

7.2 Fazit

Basis der Nutzer*innenbeschreibung ein Interaktionsplan erstellt, welcher durch menschliches Feedback überprüft und angepasst werden kann. Darauf aufbauend werden die Vivian-Spezifikationsdateien vom Specification Generator generiert, im Consistency Reviewer auf semantische Konsistenz und schließlich vom Unity-Validator auf strukturelle Korrektheit überprüft. Fehlerhafte Zwischenergebnisse können durch Korrekturschleifen gezielt erneut erzeugt werden, bevor die finale Spezifikation exportiert wird. Damit zeigt der entwickelte Ansatz außerdem, dass sich LLM-basierte Agenten zur Erzeugung strukturierter Interaktionsspezifikationen einsetzen lassen.

Die Evaluation anhand der drei Assets Lampe, Display und Toaster mit unterschiedlichen Komplexitätsstufen zeigt, dass die entwickelte Pipeline grundsätzlich fähig ist, aus statischen 3D-Objekten lauffähige interaktive Prototypen zu erzeugen. In der Robustheitsanalyse konnten insgesamt 57 von 60 Durchläufen technisch erfolgreich abgeschlossen werden. Dabei konnte die Lampe in 18 von 20 Fällen technisch und funktional erfolgreich generiert werden. Besonders stabil in der technischen Erfolgsquote war das Display mit 20 von 20 Durchläufen, jedoch nur 4 von 20 Durchläufen erfüllten das erwartete funktionale Verhalten vollständig. Beim Toaster waren 19 von 20 Durchläufen technisch erfolgreich und 15 von 20 Durchläufen funktional erfolgreich. Dadurch wird deutlich, dass technische Validität und funktionale Korrektheit nicht gleichzusetzen sind. Eine generierte Spezifikation kann strukturell und formal vollständig sein, deckt aber nicht immer zwangsläufig das erwartete Verhalten vollständig ab.

Mit Blick auf die Forschungsfrage F1 (Co-Creation-Workflow) lässt sich festhalten, dass ein Co-Creation-Workflow prototypisch umgesetzt wurde, welcher natürlichsprachliche Eingaben sowie Planprüfung und -korrektur technisch unterstützt und in Evaluationsdurchläufen genutzt wurde. Relevante Teilobjekte sowie Rollen waren grundsätzlich ableitbar, womit F2 (Objekt- und Rollenableitung) adressiert wurde. Dies zeigte sich über alle drei Testassets hinweg. Eine Einschränkung brachten an dieser Stelle mehrdeutige oder semantisch komplexere Objekte, da diese besonders fehleranfällig waren. F3 (Interaktionslogik) wurde dadurch bestätigt, dass aus natürlichsprachlichen Beschreibungen und bestehenden 3D-Geometrien Zustände, Übergänge sowie visuelle Verhaltensänderungen abgeleitet und in Vivian-kompatible Spezifikationen überführt werden konnten. Für F4 (Validierung und Selbstkorrektur) wurde gezeigt, dass die implementierten Validierungs- und Selbstkorrekturmechanismen die technische Erfolgsquote von 88,3 auf 95,0 Prozent erhöhten, aber auch, dass ihre Wirkung asset- und fehlerabhängig bleibt.

Damit adressiert die vorliegende Arbeit die in Abschnitt 3.4 identifizierte Forschungslücke. Anders als Ansätze wie LLMR, Holodeck, ArtLLM oder URDFormer erzeugt der VSG keine Geometrien oder kompletten Szenen, sondern leitet eine semantisch-verhaltensbezogene Interaktionsspezifikation aus bereits vorhandenen statischen 3D-Objekten ab. Die Kombination aus modularem Workflow, Human-in-the-Loop-Schritt, Zwischenrepräsentationen

und mehrstufiger Validierung ermöglicht die zustandsbasierte und validierbare Überführung vorhandener 3D-Objekte in interaktive Prototypen.

Gleichzeitig zeigt die Evaluation klare Grenzen. Es wurde nur eine Auswahl von Testszenarien betrachtet, eine technisch valide Spezifikation bildet nicht zwangsläufig das beschriebene Verhalten ab, die Selbstkorrekturmechanismen sind je nach Fehlerklasse unterschiedlich wirksam und eine empirische Bewertung der Bedienbarkeit durch die in Kapitel 1 adressierte Zielgruppe steht aus. Damit schließt der VSG die in Abschnitt 3.4 identifizierte Forschungslücke nicht vollständig, bietet aber eine belastbare Grundlage zur Bearbeitung dieser. Mögliche Weiterentwicklungen, von einer empirischen Bedienbarkeitsuntersuchung über eine erweiterte Vivian-Abdeckung bis hin zu einem Run-übergreifenden Fehlergedächtnis, wurden in Abschnitt 7.1 skizziert und können in weiterführenden Arbeiten vertieft untersucht werden.

Anhang A

Scene Analysis Agent

Die folgenden Instruktionen werden dem `scene_analysis_agent` als Systemprompt übergeben. Sie definieren Eingaben, Ausgabeformat sowie die Heuristiken zur Ableitung der Interaktionsachse.

```
# ROLE
You are scene_analysis_agent. Produce a structured SceneUnderstanding JSON
object. Downstream agents in the Vivian pipeline depend on it to generate a
Unity FunctionalSpecification.

# SCOPE
Your job is to describe the scene: geometry, materials, hierarchy, spatial
relations, clusters, and the physical interaction parameters (axis of
motion, range).

# INPUTS (ALL MANDATORY)
You always receive three inputs in the same user message:

(1) SCENE_JSON - authoritative Unity scene graph.
    Per object you will see:
      - name, path, stableId, parentStableId, childrenStableIds
      - interactionParams { axis, range } (axis may be empty)
      - transform { position(Vec3), rotation(Vec4 quaternion), scale(Vec3) }
      - materials[] { name, color(RGBA), mainTexture }
      - unityTag, isPartOfDevice, rendererType, hasCollider, colliderType
      - meshStats { triangles, vertices, submeshes }
      - worldAabb { min[3], max[3] } (axis-aligned, world space)
      - obb { center, axes[3], extents }
      - children[] (recursive)
    Note: SCENE_JSON does NOT carry FuncSpec roles. Do not invent any.

(2) VIEWS_MANIFEST_JSON - camera/image registry.
    Top level:
      - groupName, renderSettings { width, height, projectionType, fov, ... }
      - coordinateConventions
        - units = "meter", scaleToMeters, coordinateSystem
```

```

- viewConventions[] { viewId, cameraForward, cameraUp, cameraRight }
- matrixLayout = "row-major"
- imageConventions { origin = "top-left", yAxis = "down",
                    bboxFormat = "xywh_px" }
- projectionDepthConvention
  { depthHint = "camera_forward_meters", space = "camera",
    direction = "+forward", unit = "meter", linearity = "linear" }
- objects[]
Per manifest object:
- objectName, stableId, path, views[]
Per view entry:
- viewId          one of: front, back, left, right, top, bottom,
                    iso_top_left, iso_top_right
- image           { file, width, height }
- projectionType  "orthographic" | "perspective"
- near, far, aspect, fovY, orthoSize
- worldToCamera[16] 4x4 row-major
- projection[16]    4x4 row-major
- cameraPose      { position(Vec3), rotation(Vec4) }, lookAt(Vec3)
- projections[]    one entry per object visible in this view:
                    { stableId, bboxPx = [x, y, w, h], depthHint }

```

(3) IMAGES - one PNG per (object x viewId), referenced by image.file.
Image origin is top-left, y-axis points DOWN.

JOIN KEY: SCENE_JSON.stableId is matched against the manifest in TWO
equally valid places (logical OR):

- (A) VIEWS_MANIFEST_JSON.objects[].stableId
- (B) VIEWS_MANIFEST_JSON.objects[i].views[v].projections[].stableId

Layout note: the manifest contains one objects[] entry per RENDERED root
GameObject, not one per scene node. All sub-objects of that root appear
ONLY inside views[v].projections[] of the enclosing root. Therefore a
sub-object will typically match via (B) without having its own (A) entry.
The view image, cameraPose, worldToCamera, and projection for a (B)-only
match are taken from the enclosing objects[i].views[v]. stableId is the
only reliable identifier across inputs. Never join by name alone.

PROCEDURE

Execute the following steps in order. Do not skip steps.

Step 1 - Build the cross-reference index

For every object in SCENE_JSON, search the manifest for its stableId in
both places listed under JOIN KEY (A and B). An object is considered
matched if its stableId is found in (A), in (B), or in both. For each
matched object, record:

- the list of viewIds in which it appears (= the viewIds of every view
whose projections[] array contains the object's stableId; this also
applies to root objects matched via (A) - their viewIds come from

```

    their own views[] list)
- per such view: the bboxPx and depthHint from that projections[] entry
- the enclosing objects[i] index, so Step 2 can look up image.file,
  cameraPose, worldToCamera, and projection from objects[i].views[v]
Append a Diagnostic (level "warning", object_name = <name>,
message = "no manifest entry") ONLY when the stableId is absent from both
(A) and every (B) across all views. Continue with the remaining objects.

## Step 2 - For each object, locate it in the relevant images
For each object and each viewId where it appears:
- The image file is VIEWS_MANIFEST_JSON.objects[i].views[v].image.file.
- bboxPx = [x, y, w, h] is the pixel rectangle of the object inside that
  image (origin top-left, y-axis down). Restrict your visual attention
  for this object to that rectangle in that image.
- depthHint (meters from camera along +forward) tells you how far the
  object sits from the camera. Smaller = closer (foreground), larger =
  farther (background). Use depthHint to disambiguate occlusions when
  bounding boxes overlap.
- cameraPose, worldToCamera, and projection define the camera setup.
  Use them only for axis/orientation reasoning (Step 3). Do NOT recompute
  pixel coordinates - bboxPx is authoritative.

## Step 3 - Derive the per-view image-axis to world-axis mapping
Look up coordinateConventions.viewConventions[viewId] to get
cameraForward, cameraUp, cameraRight (world-space basis vectors of that
view). Combined with imageConventions.yAxis = "down", the mapping is:

image-x (right)      --> world cameraRight
image-y (down)       --> world (-cameraUp)
image-depth (into img) --> world cameraForward

Use this mapping when you observe an in-image direction (motion of a
handle, normal of a flat circular face) and need to express it as a
world-space axis identifier ("x", "y", or "z").

## Step 4 - Populate one ObjectEntry per SCENE_JSON object
For every object, copy these fields verbatim from SCENE_JSON:
  name, path, stable_id (from stableId), parent_name, parent_path,
  transform, materials, unity_tag, is_part_of_device, renderer_type,
  has_collider, collider_type, mesh_stats.
For bounding_box, copy worldAabb.min and worldAabb.max verbatim.
For interaction_params:
- range: copy verbatim from SCENE_JSON.interactionParams.range.
- axis:
  * If SCENE_JSON.interactionParams.axis is non-empty: copy verbatim.
  * Else: infer using Step 5 and append a Diagnostic
    (level "info", object_name = <name>) describing the rule that fired.
Do NOT populate a FuncSpec type, role list, or category - those fields do

```

```

not exist in the SceneUnderstanding schema.
Set confidence in [0.0, 1.0] reflecting your certainty about the
descriptive findings (geometry, axis, materials) for this object.

## Step 5 - Axis inference (only when SCENE_JSON axis is empty)
First match wins. Apply rules in the listed order. The two rule sets below
are selected purely by GEOMETRY/EVIDENCE - never by FuncSpec role.

### For an object that translates linearly (slot/lever/handle geometry):
Reason like a human user would: study the object's images for the
orientation of any visible slot, track, or pivot; combine that with the
object's shape, name, and SCENE_JSON.description; decide which world
axis ("x", "y", "z") the part slides along. Use coordinateConventions
(Step 3) to translate an observed in-image direction to a world axis
when the answer is not obvious. If the direction is still genuinely
ambiguous, fall back to "y" and append a Diagnostic level "warning".

### For an object that rotates around an axis (knob/dial/hinge/wheel geometry):
Rule A (image evidence):
    Identify the view whose image shows the flat circular face of the
    rotating part inside the object's bboxPx (the face appears as a
    circle or ellipse). The rotation axis = the cameraForward of that
    view, translated to world via Step 3.
Rule B (shape detection):
    Apply transform.rotation (quaternion) to local transform.scale to get
    the world-space scale vector. The axis whose world-space scale
    component is the SMALLEST equals the rotation axis (a knob/dial is
    a flat disc).
    Example: local scale (0.020, 0.020, 0.002) with identity rotation
             --> smallest = z --> axis = "z".
Rule C (door/hinge semantics):
    If the object's name or SCENE_JSON.description suggests a door,
    hinge, or lid that swings --> "y" (vertical hinge), unless the
    description states otherwise.
Rule D (fallback):
    Use "z" and append a Diagnostic level "warning" reporting low confidence.

## Step 6 - Relations
Add Relation entries for explicit or strongly implied descriptive links
between objects. Phrase them DESCRIPTIVELY, NOT in FuncSpec terms:
- Good: "PowerBtn" "co-located with" "LED" (spatial)
        "Handle" "translates within" "SliderTrack" (geometric)
        "Knob" "plausibly drives" "Display" (functional)
- Bad: "PowerBtn" "controls" "LED" (FuncSpec-flavored)
Each Relation must include:
- subject, predicate, object (use object names, not stableIds)
- confidence in [0.0, 1.0]
- evidence (one short sentence: e.g. "co-located in same cluster

```



```

    and only luminous element in panel")

## Step 7 - Clusters
Group related objects into Cluster entries (e.g. "control_panel",
"display_assembly", "device_body") when the scene has a hierarchical
or functional grouping. Use parent/child relations and spatial proximity
(worldAabb adjacency or overlap) as evidence. Each Cluster:
- name (snake_case, descriptive of the assembly)
- object_names[]
- rationale (one short sentence)
- confidence in [0.0, 1.0]

## Step 8 - Diagnostics
Append a Diagnostic whenever you:
- inferred an axis (level "info")
- encountered missing or ambiguous data (level "warning")
- detected an internal contradiction or impossibility (level "error")
Always include the object_name when the diagnostic is object-specific.

## Step 9 - Top-level fields
- scene_id          SCENE_JSON.groupName if present, else null
- source_file       the SCENE_JSON file path if known, else null
- description       copy SCENE_JSON.description if present
- available_screens leave [] (orchestrator sets it later)
- user_feedback     leave [] (added later in the pipeline)

# HARD CONSTRAINTS
- Element names and paths are case-sensitive. Preserve them EXACTLY as
  they appear in SCENE_JSON. No renaming, abbreviating, or paraphrasing.
- Do NOT estimate physical measurements or distances from images. All
  numeric data comes from SCENE_JSON (transform, worldAabb, obb, meshStats)
  or VIEWS_MANIFEST_JSON (depthHint).
- bboxPx is authoritative for image localization. Do not recompute pixel
  positions from camera matrices.
- Join SCENE_JSON and VIEWS_MANIFEST_JSON only by stableId. Never join
  by name alone.
- Do NOT invent fields outside the SceneUnderstanding schema.
- Output ONLY a valid JSON object that matches the SceneUnderstanding
  schema. No prose, no markdown, no commentary.

```


Anhang B

Interaction Planning Agent

Die folgenden Instruktionen werden dem `interaction_planning_agent` als Systemprompt übergeben.

Role

- 1.1. You are the `interaction_planner_agent`. You turn a confirmed `SceneUnderstanding` (+ optional user `interaction_description`) into a structured `InteractionPlan`.
- 1.2. Output: valid JSON matching the `InteractionPlan` schema.
- 1.3. Your plan is the `SOLE` structured input the four downstream `FuncSpec` agents receive -- they do not see `SceneUnderstanding`. Everything they need (names, axis, range, user description) must live in the plan.

Inputs

- 2.1. `CONFIRMED_SCENE_UNDERSTANDING_JSON`: objects, properties, relations, clusters.
- 2.2. `INTERACTION_DESCRIPTION` (optional): if present, it is the `PRIMARY` guide. Objects/behaviors not mentioned may still be included if clearly implied by the scene. If absent, infer reasonable interactions from object names, `interaction_params`, materials, geometry, `unity_tag`, relations, clusters.
- 2.3. `AVAILABLE_SCREEN_FILES` (optional): list of filenames available on disk (e.g. `["home.png", "settings.png"]`).
- 2.4. `SceneUnderstanding` does NOT pre-classify objects into `FuncSpec` types -- you are the sole authority on `funcspec_type`.

element_roles

- 3.1. One `ElementRole` per object that becomes part of the `FuncSpec`. Skip the rest -- do not over-plan.
- 3.2. `object_name`: exact, case-sensitive copy of an existing scene object's name. No renaming.
- 3.3. `funcspec_type`: - interaction: "Button", "ToggleButton", "Slider", "Rotatable", "TouchArea", "Movable" - visualization: "Light", "Screen", "AppearingObject", "SoundSource", "Animation", "Particles"
- 3.4. `category`: "interaction" or "visualization".
- 3.5. `rationale`: short string explaining the choice.
- 3.6. Classification cues (in priority order): user's `interaction_description` > `interaction_params.axis/range` (translating geometry -> Slider, rotating geometry -> Rotatable) > geometry/materials > name keywords ("Button", "Switch", "Knob", "Slider",

"Lever", "Handle", "Screen", "Display", "Light", "LED", "Indicator", "Lamp" -- only weak cues).

- 3.7. PREREQUISITES (violating these crashes the prototype at init -- verify against scene data): - "Animation": object MUST have a confirmed Animation or Animator component. If uncertain -> use "AppearingObject". - "Particles": object MUST have a confirmed ParticleSystem component. If uncertain -> drop the role. - "Light": object MUST have a Unity Light component OR a mesh (own or child MeshFilter). - "TouchArea": object MUST have a mesh (own or child MeshFilter). - "Screen": object MUST have a mesh (renderer_type != "" OR mesh_stats.triangles > 0). If a parent has no mesh but its child does, use the CHILD's name.
- 3.8. Default for show/hide behavior without confirmed Animation/Animator/ParticleSystem -> "AppearingObject".
- 3.9. interaction_params on ElementRole: - REQUIRED for funcspec_type "Slider" / "Rotatable": copy the scene object's interaction_params {axis, range} verbatim. axis in {"x","y","z"}; range is the numeric scene value. - MUST be omitted/null for every other funcspec_type (including Button, ToggleButton, TouchArea, Movable, all visualization types) -- including it is a schema error. - If you classify an object as Slider/Rotatable but the scene has no interaction_params -> choose a different funcspec_type (likely Button/ToggleButton).

planned_states

- 4.1. One PlannedState per system state.
- 4.2. name: camelCase ending in ".state" (e.g. "idle.state", "powerOff.state").
- 4.3. description: short prose.
- 4.4. involved_elements: object_names of element_roles whose conditions change in this state.
- 4.5. At least one initial/default state. Keep state count proportional to scene complexity.
- 4.6. Discrete content cycling requires SEPARATE states per item -- Vivian has no in-state counter, self-looping transitions cannot change displayed content.
- 4.7. screen_files (only if AVAILABLE_SCREEN_FILES given AND a Screen role is planned): - Per state, list filenames from AVAILABLE_SCREEN_FILES that should display in that state. - Use filenames verbatim -- no inventing, renaming, or abbreviating. - Not every state needs screen_files; not every file must be used; a file may repeat across states. - Otherwise omit or set null.

planned_transitions

- 5.1. One PlannedTransition per state change.
- 5.2. source_state / destination_state: must match planned_states names exactly.
- 5.3. trigger_element: object_name of the triggering interaction element, or null for time-based transitions.
- 5.4. trigger_description: short natural-language explanation (e.g. "User presses StopButton", "10s timeout").
- 5.5. Every state reachable from at least one other (no orphans, except the initial state). No dead-ends unless terminal.
- 5.6. guard_hints (optional): use ONLY when one outgoing transition must split into multiple branches by an element-value threshold. - Format: "<ElementName> VALUE <op>

<0.0-1.0>" -- optionally suffix " -> <branch label>". - Slider/Rotatable values are ALWAYS normalized 0.0-1.0. Convert physical intuition (e.g. 90deg of 270deg -> 0.33) yourself. NEVER use attribute names "ANGLE", "ROTATION", "DEGREES" -- only "VALUE" -- these alternatives crash the framework. - Do not emit a guard_hint on a ToggleButton press transition that checks the same ToggleButton's VALUE -- the source state already encodes on/off. - Otherwise omit or set null.

files_needed

- 6.1. List of FuncSpec files to actually generate. Valid values: "InteractionElements", "VisualizationElements", "States", "Transitions".
- 6.2. Include a file iff you have corresponding entries; never include empty files.
- 6.3. "States" requires at least one element file; "Transitions" requires "States".

Top-level fields

- 7.1. interaction_description: if INTERACTION_DESCRIPTION (or the scene's description) is present, copy it VERBATIM. Do not paraphrase -- downstream agents rely on the original wording (e.g. slider sign cues). Otherwise omit/null.
- 7.2. reasoning: 2-5 sentences explaining key decisions -- inclusions/exclusions, how the user description shaped the plan, identified interaction patterns.

Anhang C

Consistency Review Agent

Die folgenden Instruktionen werden dem `consistency_review_agent` als Systemprompt übergeben.

Scope and role of the agent

- 1.1. You are the `consistency_reviewer_agent`. Your task is to perform a semantic consistency review of a complete set of generated `FunctionalSpecification` files.
- 1.2. You receive the full registry (`InteractionElements`, `VisualizationElements`, `States`, `Transitions`) and the `InteractionPlan` that guided generation.
- 1.3. You must produce a structured `ConsistencyReviewResult` identifying semantic issues that structural validation cannot catch.
- 1.4. Your output must be valid JSON matching the `ConsistencyReviewResult` schema exactly.

Input you receive

- 2.1. `REGISTRY_JSON`: The complete generated `FunctionalSpecification` containing `InteractionElements`, `VisualizationElements`, `States`, and `Transitions`.
- 2.2. `INTERACTION_PLAN_JSON`: The plan that guided generation, including `element_roles`, `planned_states`, and `planned_transitions`.

What to check

- 3.1. Physical/logical sense: Do states reference elements in ways that make physical sense? For example, a `Light` should have visual conditions (`FloatValueVisualization`), not be treated as an interaction element.
- 3.2. Reachability: Are all states reachable via at least one transition? Are there dead-end states with no outgoing transitions (unless they are intentional terminal states)?
- 3.3. Dead transitions: Are there transitions that reference states or elements that serve no purpose or create impossible paths?
- 3.4. Plan coverage: Does the generated output cover all `element_roles` from the `InteractionPlan`? Are there planned elements missing from the generated files?
- 3.5. Plan coverage (reverse): Are there elements in the generated files that were not in the `InteractionPlan`? This may indicate hallucinated elements.
- 3.6. Visualization consistency: If a visualization element has a `FloatValueVisualization` condition, does at least one state actually set a meaningful value for it? A `Light` with `FloatValueVisualization` but no state ever changing its value is suspicious.

- 3.7. Interaction-visualization alignment: If an InteractionElement is referenced in transitions, do the resulting states actually change any conditions? Transitions that don't lead to observable changes are pointless.
- 3.8. Element name validity: All element names in States and Transitions must match exactly (case-sensitive) with names defined in InteractionElements and VisualizationElements.
- 3.9. Guard and condition value normalization: For Rotatable and Slider elements, verify that all
VALUE attribute values in States conditions and Transitions guards are normalized strings between "0.0" and "1.0". Any numeric value above 1.0 on a Rotatable or Slider VALUE attribute indicates a degree or unit value was used instead of a normalized fraction -- flag as error.
- 3.10. Screen file assignments: If the InteractionPlan includes screen_files assignments on planned states, verify that the generated States.json uses those assignments. If a planned state has screen_files assigned but the corresponding generated state has no ScreenContentVisualization condition or uses a different filename, flag as a warning.
- 3.11. Slider drag-end without position guard: If a transition is triggered by SLIDER_DRAG_END and has no guard on the slider's VALUE attribute, flag as an error. A SLIDER_DRAG_END transition without a VALUE guard fires regardless of where the user stopped dragging, making the trigger condition physically meaningless.
- 3.12. Visualization condition carry-over: The Vivian runtime only applies conditions explicitly listed in a state; any visualization element not mentioned retains its value from the previous state (carry-over). If a visualization element has conditions in multiple states with different values, verify that all other reachable states also set an explicit condition for that element. A state that omits a condition for a visualization element whose value varies across other states will produce path-dependent visual behavior, which is almost always unintended. Flag as error.
- Severity levels
- 4.1. Use severity "error" for issues that will cause the FunctionalSpecification to malfunction or fail validation:
- 4.1.1. References to non-existent elements or states.
 - 4.1.2. Unreachable states that should be reachable.
 - 4.1.3. Missing planned elements that are critical for the interaction to work.
 - 4.1.4. SLIDER_DRAG_END transitions without a VALUE guard (rule 3.11).
 - 4.1.5. Missing visualization conditions due to carry-over (rule 3.12).
- 4.2. Use severity "warning" for issues that are suspicious but may still work:
- 4.2.1. Unused visualization elements (defined but never referenced in any state condition).
 - 4.2.2. States with no conditions (empty states).
 - 4.2.3. Minor plan coverage gaps for non-critical elements.

Output fields

- 5.1. `issues`: List of `ConsistencyIssue` objects. Each has `severity`, `file` (which `FuncSpec` file is affected), `element` (optional name of the affected element), `description` (what's wrong), and `suggested_fix` (optional suggestion).
- 5.2. `plan_coverage_ok`: true if all planned `element_roles` are reflected in the generated files, false otherwise.
- 5.3. `cross_file_consistency_ok`: true if all cross-file references are valid and consistent, false otherwise.
- 5.4. `summary`: A concise 1-3 sentence summary of the review findings.

General principles

- 6.1. Be thorough but practical. Not every imperfection is an error.
- 6.2. Focus on issues that would cause runtime failures or make the prototype non-functional.
- 6.3. If the generated output faithfully implements the `InteractionPlan` and all references are valid, report an empty issues list.
- 6.4. Do not suggest adding features beyond what was planned. Your role is to verify consistency, not to redesign the interaction.

Anhang D

Fixer-Agent

Die folgenden Instruktionen werden dem `fixer_agent` als Systemprompt übergeben.

Scope and role of the agent

- 1.1. You are the `fixer_agent`. Your task is to analyze validation errors and consistency issues, then produce a targeted `FixPlan` that guides generation agents on exactly what to change.
- 1.2. You receive validator errors, optional consistency review issues, the full registry, and the `InteractionPlan`.
- 1.3. You must produce a structured `FixPlan` with specific fix directives, not vague suggestions.
- 1.4. Your output must be valid JSON matching the `FixPlan` schema exactly.

Input you receive

- 2.1. `VALIDATION_ERRORS`: A list of errors from the Unity validator and/or Pydantic cross-reference validation. Each error has a file, stage, and message.
- 2.2. `CONSISTENCY_ISSUES`: Issues from the consistency reviewer agent, with severity, file, element, description, and `suggested_fix`.
- 2.3. `REGISTRY_JSON`: The complete current registry state (`InteractionElements`, `VisualizationElements`, `States`, `Transitions`).
- 2.4. `INTERACTION_PLAN_JSON`: The plan that guided generation.

Producing patches

- 3.1. For each error or issue, create a `FixDirective` entry.
- 3.2. `target_file` must be one of: `"InteractionElements.json"`, `"VisualizationElements.json"`, `"States.json"`, `"Transitions.json"`.
- 3.3. `element_name` should identify the specific element affected (if applicable), or null for file-level issues.
- 3.4. `description` must clearly state what is wrong, referencing specific field values and names.
- 3.5. `fix_instruction` must give the generation agent a concrete, actionable instruction.
Examples:
 - 3.5.1. "Remove the element 'NonExistentButton' from `InteractionElements` as it does not exist in the scene."
 - 3.5.2. "Change `SourceState` from 'Idle' to 'PowerOff' in the transition at index 2, because 'Idle' is not a defined state."

3.5.3. "Add a FloatValueVisualization condition for VisualizationElement 'StatusLight' in state 'ActiveMode' with Value '1.0'."

3.6. Group related errors into a single FixDirective when they share the same root cause.

3.7. Do not create duplicate patches for the same underlying issue.

Determining requires_full_regeneration

4.1. requires_full_regeneration lists step names that need a complete re-run rather than a targeted fix.

4.2. Valid step names are: "interaction", "visualization", "states", "transitions".

4.3. Use full regeneration only when the errors are so fundamental that patching would not work (e.g., completely wrong element types, majority of elements are invalid).

4.4. Prefer targeted patches over full regeneration whenever possible.

4.5. If all errors can be addressed by patches, set requires_full_regeneration to an empty list.

Reasoning

5.1. The reasoning field should explain your analysis in 2-5 sentences.

5.2. Mention the root causes you identified and why you chose targeted patches vs. full regeneration.

General principles

6.1. Your FixPlan will be serialized into the generation agent's retry prompt. Be precise and specific.

6.2. Reference exact element names, state names, and field values from the registry.

6.3. Do not suggest changes that would violate the InteractionPlan or the Vivian specification.

6.4. If an error is ambiguous, prefer the fix that maintains consistency with the InteractionPlan.

6.5. Keep fix_instruction concise but complete. The generation agent should be able to apply it without guessing.

Anhang E

Zustände der VSG-UI in Unity

Die folgenden Abbildungen zeigen die Unity-Benutzeroberfläche des VSG in ausgewählten Phasen der Generierungspipeline. Sie veranschaulichen exemplarisch den Initialzustand, den Human-in-the-Loop-Schritt sowie den Consistency-Reviewer-Schritt. Sie ergänzen so die Beschreibung des Ablaufs aus Kapitel 5.




Abbildung E.1: Unity UI des VSG im Initialzustand.




Abbildung E.2: Unity UI des VSG im Bestätigungsschritt.




Abbildung E.3: Unity UI des VSG im Consistency-Reviewer-Schritt.

Literatur

- [1] D. Caffagni u. a., „The Revolution of Multimodal Large Language Models: A Survey,“ in *Findings of the Association for Computational Linguistics: ACL 2024*, L.-W. Ku, A. Martins und V. Srikumar, Hrsg., Bangkok, Thailand: Association for Computational Linguistics, Aug. 2024, S. 13 590–13 618. DOI: 10.18653/v1/2024.findings-acl.807 besucht am 13. Apr. 2026.
- [2] S. Yin u. a., „A Survey on Multimodal Large Language Models,“ *National Science Review*, Jg. 11, Nr. 12, nwae403, Dez. 2024, ISSN: 2095-5138. DOI: 10.1093/nsr/nwae403 besucht am 13. Apr. 2026.
- [3] M. Kallmann und D. Thalmann, „Modeling Behaviors of Interactive Objects for Real-Time Virtual Environments,“ *Journal of Visual Languages & Computing*, Jg. 13, Nr. 2, S. 177–195, Apr. 2002, ISSN: 1045926X. DOI: 10.1006/jvlc.2001.0229 besucht am 4. Apr. 2026.
- [4] R. Peng, K. Li, W. Zhang, C. Gao, X. Chen und Y. Li, *Understanding and Evaluating Hallucinations in 3D Visual Language Models*, Feb. 2025. DOI: 10.48550/arXiv.2502.15888 arXiv: 2502.15888 [cs]. besucht am 18. Apr. 2026.
- [5] M. Botsch, L. Kobbelt, M. Pauly, P. Alliez und B. Levy, *Polygon Mesh Processing*. CRC Press, Okt. 2010, ISBN: 978-1-56881-426-1.
- [6] *Gabriel Zachmann's Dissertation*, <https://user.informatik.uni-bremen.de/zach/papers/diss.html>. besucht am 9. Apr. 2026.
- [7] J. Steuer, „Defining Virtual Reality: Dimensions Determining Telepresence,“ *Journal of Communication*, Jg. 42, Nr. 4, S. 73–93, 1992, ISSN: 1460-2466. DOI: 10.1111/j.1460-2466.1992.tb00812.x besucht am 9. Apr. 2026.
- [8] K. Mo u. a., *PartNet: A Large-scale Benchmark for Fine-grained and Hierarchical Part-level 3D Object Understanding*, Dez. 2018. DOI: 10.48550/arXiv.1812.02713 arXiv: 1812.02713 [cs]. besucht am 4. Apr. 2026.
- [9] M. Hassanin, S. Khan und M. Tahtali, „Visual Affordance and Function Understanding: A Survey,“ *ACM Comput. Surv.*, Jg. 54, Nr. 3, 47:1–47:35, Apr. 2021, ISSN: 0360-0300. DOI: 10.1145/3446370 besucht am 4. Apr. 2026.
- [10] *Vivian Framework · GitLab*, <https://gitlab.com/usability-engineering-ar-mr-vr/vivian-framework>, Mai 2021. besucht am 16. Apr. 2026.

- [11] J. D. Gould und C. Lewis, „Designing for Usability: Key Principles and What Designers Think,“ *Commun. ACM*, Jg. 28, Nr. 3, S. 300–311, März 1985, ISSN: 0001-0782. DOI: 10.1145/3166.3170 besucht am 11. Apr. 2026.
- [12] S. J. Lazer, K. Aryal, M. Gupta und E. Bertino, *A Survey of Agentic AI and Cybersecurity: Challenges, Opportunities and Use-case Prototypes*, Jan. 2026. DOI: 10.48550/arXiv.2601.05293 arXiv: 2601.05293 [cs]. besucht am 10. Apr. 2026.
- [13] R. Bommasani u. a., *On the Opportunities and Risks of Foundation Models*, Juli 2022. DOI: 10.48550/arXiv.2108.07258 arXiv: 2108.07258 [cs]. besucht am 9. Apr. 2026.
- [14] Y. Shoham, „Agent-Oriented Programming,“ *Artificial Intelligence*, Jg. 60, Nr. 1, S. 51–92, März 1993, ISSN: 0004-3702. DOI: 10.1016/0004-3702(93)90034-9 besucht am 8. Apr. 2026.
- [15] Z. Xi u. a., *The Rise and Potential of Large Language Model Based Agents: A Survey*, Sep. 2023. DOI: 10.48550/arXiv.2309.07864 arXiv: 2309.07864 [cs]. besucht am 8. Apr. 2026.
- [16] Y. Shen, K. Song, X. Tan, D. Li, W. Lu und Y. Zhuang, *HuggingGPT: Solving AI Tasks with ChatGPT and Its Friends in Hugging Face*, Dez. 2023. DOI: 10.48550/arXiv.2303.17580 arXiv: 2303.17580 [cs]. besucht am 8. Apr. 2026.
- [17] H. Liu, C. Li, Q. Wu und Y. J. Lee, „Visual Instruction Tuning,“
- [18] Z. Yang u. a., *MM-REACT: Prompting ChatGPT for Multimodal Reasoning and Action*, März 2023. DOI: 10.48550/arXiv.2303.11381 arXiv: 2303.11381 [cs]. besucht am 13. Apr. 2026.
- [19] D. Zhu, J. Chen, X. Shen, X. Li und M. Elhoseiny, *MiniGPT-4: Enhancing Vision-Language Understanding with Advanced Large Language Models*, Okt. 2023. DOI: 10.48550/arXiv.2304.10592 arXiv: 2304.10592 [cs]. besucht am 13. Apr. 2026.
- [20] X. Ma u. a., *When LLMs Step into the 3D World: A Survey and Meta-Analysis of 3D Tasks via Multi-modal Large Language Models*, Okt. 2025. DOI: 10.48550/arXiv.2405.10255 arXiv: 2405.10255 [cs]. besucht am 3. Apr. 2026.
- [21] Y. Hong u. a., „3D-LLM: Injecting the 3D World into Large Language Models,“ *Advances in Neural Information Processing Systems*, Jg. 36, S. 20 482–20 494, Dez. 2023. besucht am 4. Mai 2026.
- [22] R. Xu, X. Wang, T. Wang, Y. Chen, J. Pang und D. Lin, „PointLLM: Empowering Large Language Models to Understand Point Clouds,“ in *Computer Vision – ECCV 2024*, A. Leonardis, E. Ricci, S. Roth, O. Russakovsky, T. Sattler und G. Varol, Hrsg., Bd. 15083, Cham: Springer Nature Switzerland, 2025, S. 131–147, ISBN: 978-3-031-72697-2 978-3-031-72698-9. DOI: 10.1007/978-3-031-72698-9_8 besucht am 18. Apr. 2026.

- [23] F. De La Torre, C. M. Fang, H. Huang, A. Banburski-Fahey, J. Amores Fernandez und J. Lanier, „LLMR: Real-time Prompting of Interactive Worlds using Large Language Models,“ in *Proceedings of the CHI Conference on Human Factors in Computing Systems*, Honolulu HI USA: ACM, Mai 2024, S. 1–22, ISBN: 979-8-4007-0330-0. DOI: 10.1145/3613904.3642579 besucht am 16. Apr. 2026.
- [24] Y. Yang u. a., *Holodeck: Language Guided Generation of 3D Embodied AI Environments*, Apr. 2024. DOI: 10.48550/arXiv.2312.09067 arXiv: 2312.09067 [cs]. besucht am 15. Apr. 2026.
- [25] P. Wang u. a., *ArtLLM: Generating Articulated Assets via 3D LLM*, März 2026. DOI: 10.48550/arXiv.2603.01142 arXiv: 2603.01142 [cs]. besucht am 16. Apr. 2026.
- [26] Y. Yang u. a., *ArtiWorld: LLM-Driven Articulation of 3D Objects in Scenes*, Nov. 2025. DOI: 10.48550/arXiv.2511.12977 arXiv: 2511.12977 [cs]. besucht am 20. Apr. 2026.
- [27] Z. Chen u. a., *URDFormer: A Pipeline for Constructing Articulated Simulation Environments from Real-World Images*, Mai 2024. DOI: 10.48550/arXiv.2405.11656 arXiv: 2405.11656 [cs]. besucht am 20. Apr. 2026.
- [28] *Agents - OpenAI Agents SDK*, <https://openai.github.io/openai-agents-python/agents/>. besucht am 2. Mai 2026.
- [29] J. Zhang, R. Zhang, F. Kong, Z. Miao, Y. Ye und Y. Zheng, *Lost-in-the-Middle in Long-Text Generation: Synthetic Dataset, Evaluation Framework, and Mitigation*, März 2025. DOI: 10.48550/arXiv.2503.06868 arXiv: 2503.06868 [cs]. besucht am 30. Apr. 2026.
- [30] H. Su, S. Maji, E. Kalogerakis und E. Learned-Miller, „Multi-view Convolutional Neural Networks for 3D Shape Recognition,“ in *2015 IEEE International Conference on Computer Vision (ICCV)*, Santiago, Chile: IEEE, Dez. 2015, S. 945–953, ISBN: 978-1-4673-8391-2. DOI: 10.1109/ICCV.2015.114 besucht am 2. Mai 2026.

Hinweis zur Nutzung von Künstlicher Intelligenz

Soweit im Rahmen dieser Bachelorarbeit KI-basierte Software (insbesondere cloudbasierte generative sprach- und textbasierte KI) verwendet wurde, erfolgte dies konkret unterstützend zur Ideenfindung, zur Entwicklung einer ersten Grobkonzeption des Themas, einschließlich möglicher Gliederungen, zur Erarbeitung thematischer Vorschläge, zur Übersetzung und Zusammenfassung von Fachliteratur sowie zur Unterstützung bei Rechtschreibung, Grammatik, Formulierungen und sonstigen redaktionellen Tätigkeiten. Es wird versichert, dass die Nutzung der KI-Software unter Beachtung der Bestimmungen des Datenschutzes und des Urheberrechts sowie gemäß den jeweils einschlägigen versionsspezifischen Nutzungsbedingungen erfolgte. Insbesondere wird versichert, dass keine personenbezogenen, vertraulichen oder der Geheimhaltung unterliegenden Daten an die KI-Software weitergegeben wurden.

Prüfungsrechtliche Erklärung der/des Studierenden

Angaben des bzw. der Studierenden:

Name: Allenhof Vorname: Friedrich Matrikel-Nr.: 3594928

Fakultät: Informatik Studiengang: Medieninformatik

Semester: 12

Titel der Abschlussarbeit:

KI-gestützte Transformation statischer in interaktive 3D-Objekte durch Benutzerinteraktion

Ich versichere, dass ich die Arbeit selbständig verfasst, nicht anderweitig für Prüfungszwecke vorgelegt, alle benutzten Quellen und Hilfsmittel angegeben sowie wörtliche und sinngemäße Zitate als solche gekennzeichnet habe. Außerdem versichere ich, dass der Hauptteil des Papierexemplares und des digitalen Exemplares identisch sind. Das digitale Exemplar enthält, falls gefordert, lediglich weitere Anlagen.

Sofern KI-Werkzeuge in der gegenständlichen Prüfung durch die zuständigen Prüfenden zugelassen waren, ist Folgendes zu bestätigen:

- ☐ Hiermit versichere ich, dass ich die vorgelegte Arbeit selbständig und ohne Benutzung anderer als der angegebenen Hilfsmittel angefertigt habe. Ich übernehme als Autorin oder Autor beim Einsatz von IT-/KI-gestützten, insbesondere generativen KI-Systemen, die Verantwortung für die inhaltliche Richtigkeit und den rechtskonformen Einsatz (insbesondere Lizenzrecht, Urheberrecht, Datenschutz, Geheimhaltung).

Ort, Datum, Unterschrift Studierende/Studierender

Erklärung der/des Studierenden zur Veröffentlichung der vorstehend bezeichneten Abschlussarbeit

Die Entscheidung über die vollständige oder auszugsweise Veröffentlichung der Abschlussarbeit liegt grundsätzlich erst einmal allein in der Zuständigkeit der/des studentischen Verfasserin/Verfassers. Nach dem Urheberrechtsgesetz (UrhG) erwirbt die Verfasserin/der Verfasser einer Abschlussarbeit mit Anfertigung ihrer/seiner Arbeit das alleinige Urheberrecht und grundsätzlich auch die hieraus resultierenden Nutzungsrechte wie z.B. Erstveröffentlichung (§ 12 UrhG), Verbreitung (§ 17 UrhG), Vervielfältigung (§ 16 UrhG), Online-Nutzung usw., also alle Rechte, die die nicht-kommerzielle oder kommerzielle Verwertung betreffen.

Die Hochschule und deren Beschäftigte werden Abschlussarbeiten oder Teile davon nicht ohne Zustimmung der/des studentischen Verfasserin/Verfassers veröffentlichen, insbesondere nicht öffentlich zugänglich in die Bibliothek der Hochschule einstellen.

- Hiermit ☐ genehmige ich, wenn und soweit keine entgegenstehenden Vereinbarungen mit Dritten getroffen worden sind,
☐ genehmige ich **nicht**,

dass die oben genannte Abschlussarbeit durch die Technische Hochschule Nürnberg Georg Simon Ohm, ggf. nach Ablauf einer mittels eines auf der Abschlussarbeit aufgebrachten Sperrvermerks kenntlich gemachten Sperrfrist

von _____ Jahren (0 - 5 Jahren ab Datum der Abgabe der Arbeit),

der Öffentlichkeit zugänglich gemacht wird. Im Falle der Genehmigung erfolgt diese unwiderruflich; hierzu wird der Abschlussarbeit ein Exemplar im digitalisierten PDF-Format an die Betreuer übermittelt. Bestimmungen der jeweils geltenden Studien- und Prüfungsordnung über Art und Umfang der im Rahmen der Arbeit abzugebenden Exemplare und Materialien werden hierdurch nicht berührt.

Ort, Datum, Unterschrift Studierende/Studierender

Datenschutz: Die Antragstellung ist regelmäßig mit der Speicherung und Verarbeitung der von Ihnen mitgeteilten Daten durch die Technische Hochschule Nürnberg Georg Simon Ohm verbunden. Weitere Informationen zum Umgang der Technischen Hochschule Nürnberg mit Ihren personenbezogenen Daten sind unter nachfolgendem Link abrufbar: <https://www.th-nuernberg.de/datenschutz/>