Technische Hochschule Nürnberg

Fakultät Informatik

KI-gestützte Transformation statischer in interaktive 3D-Objekte durch Benutzerinteraktion

Bachelorarbeit im Studiengang Medieninformatik

vorgelegt von

Friedrich Allenhof

Matrikelnummer 359 4928

Erstgutachter: Prof. Dr. Uwe Wienkop

Zweitgutachter: Louis Burk

© 2026

Dieses Werk einschließlich seiner Teile ist **urheberrechtlich geschützt**. Jede Verwertung außerhalb der engen Grenzen des Urheberrechtgesetzes ist ohne Zustimmung des Autors unzulässig und strafbar. Das gilt insbesondere für Vervielfältigungen, Übersetzungen, Mikroverfilmungen sowie die Einspeicherung und Verarbeitung in elektronischen Systemen.

Abstract

Dies hier ist ein Blindtext zum Testen von Textausgaben. Wer diesen Text liest, ist selbst schuld. Der Text gibt lediglich den Grauwert der Schrift an. Ist das wirklich so? Ist es gleichgültig, ob ich schreibe: „Dies ist ein Blindtext“ oder „Huardest gefburn“? Kjift – mitnichten! Ein Blindtext bietet mir wichtige Informationen. An ihm messe ich die Lesbarkeit einer Schrift, ihre Anmutung, wie harmonisch die Figuren zueinander stehen und prüfe, wie breit oder schmal sie läuft. Ein Blindtext sollte möglichst viele verschiedene Buchstaben enthalten und in der Originalsprache gesetzt sein. Er muss keinen Sinn ergeben, sollte aber lesbar sein. Fremdsprachige Texte wie „Lorem ipsum“ dienen nicht dem eigentlichen Zweck, da sie eine falsche Anmutung vermitteln.

Inhaltsverzeichnis

1. Einführung **1**
1.1. Problemstellung 1
1.2. Forschungsfragen (?) und Zielsetzung 1
1.3. Aufbau der Arbeit 1

2. Grundlagen **3**
2.1. Statische und interative 3D-Objekte 3
2.2. Transformation statischer in interaktive 3D-Objekte 4
2.3. Das Vivian Framework 4
2.3.1. Spezifikationen 5
2.4. Large Language Models und Agentische Systeme 6
2.4.1. Definition 6
2.4.2. Multimodale LLMs 6
2.4.3. Verwendung in der vorliegenden Arbeit 7

3. Stand der Forschung **9**
3.1. LLM-gestützte 3D-Objektmanipulation 9
3.2. Einordnung der vorliegenden Arbeit 9

4. Methodik **11**

5. Implementierung **13**

6. Evaluation **15**

7. Ausblick **17**

8. Fazit **19**

A. Supplemental Information **21**

Abbildungsverzeichnis **23**

Tabellenverzeichnis **25**

Listingverzeichnis **27**

Literatur **29**

Kapitel 1.

Einführung

You may have read about similar things in [1] and [2]. You can also write footnotes.[1] It is possible to reference glossary entries as library as an example.

Dies hier ist ein Blindtext zum Testen von Textausgaben. Wer diesen Text liest, ist selbst schuld. Der Text gibt lediglich den Grauwert der Schrift an. Ist das wirklich so? Ist es gleichgültig, ob ich schreibe: „Dies ist ein Blindtext“ oder „Huardest gefburn“? Kjift – mitnichten! Ein Blindtext bietet mir wichtige Informationen. An ihm messe ich die Lesbarkeit einer Schrift, ihre Anmutung, wie harmonisch die Figuren zueinander stehen und prüfe, wie breit oder schmal sie läuft. Ein Blindtext sollte möglichst viele verschiedene Buchstaben enthalten und in der Originalsprache gesetzt sein. Er muss keinen Sinn ergeben, sollte aber lesbar sein. Fremdsprachige Texte wie „Lorem ipsum“ dienen nicht dem eigentlichen Zweck, da sie eine falsche Anmutung vermitteln.

1.1. Problemstellung

1.2. Forschungsfragen (?) und Zielsetzung

1.3. Aufbau der Arbeit

[1] Footnotes will be positioned automatically.

Kapitel 2.

Grundlagen

2.1. Statische und interative 3D-Objekte

Im Folgenden werden statische sowie interaktive 3D-Objekte definiert und erklärt.

Statische 3D-Objekte

In dieser Arbeit werden statische 3D-Objekte als Basisform digitaler Modelle betrachtet. Sie sind die fundamentale Basis, auf denen komplexere Verhaltensweisen aufbauen können, jedoch wohnt ihnen mit diesen Informationen noch kein Eigenleben inne. Statische 3D-Objekt lassen sich meist rein geometrisch beschreiben. Die Mesh-Geometrie besteht aus Dreiecksnetzen oder Polyeder-Darstellungen, welche die Oberfläche durch Eckpunkte (Vertices) und deren Verbindungen definieren [3]. Weiterhin besitzen sie grafische Attribute wie Materialeigenschaften, Texturen, Transparenz und Sichtbarkeit sowie eine hierarchische Anordnung im Szenengraph, welcher ihre Position, Rotation und Skalierung organisiert [4].

Interaktive 3D-Objekte

Während statische 3D-Objekte als unbelebte geometrische Körper betrachtet werden können, zeichnen sich interaktive 3D-Objekte durch Wissen über ihre Funktionalität und die Möglichkeit zur Interaktion mit ihnen aus [5]. Auf diese 3D-Objekte kann durch Eingaben (Input) eingewirkt werden und das Objekt reagiert zustands- oder verhaltensbezogen [6]. Diese Reaktion verleiht der unbelebten Hülle ein “Leben“. Es ist somit in der Lage, auf durch Benutzereingaben ausgelöste Ereignisse (Events) zu reagieren und wird zu einem handlungsoffenen Teil der virtuellen Welt.

2.2. Transformation statischer in interaktive 3D-Objekte

Die in der vorliegenden Arbeit untersuchte Transformation von statisch zu interaktiv ist keine rein geometrische oder visuelle Modifikation, sondern eine semantisch-verhaltensbezogene. Sie macht aus einem visuellen und geometrischen Asset ein interaktives Modell, welches Informationen über sein eigenes Verhalten und die möglichen Interaktionen mit diesem beinhaltet. Mit dem Konzept dieser "Smart Objects" wird Logik direkt im Objekt gespeichert, was wiederum Dezantralisierung und Wiederverwendbarkeit ermöglicht [5]. Dieser Prozess umfasst verschiedene Ebenen.

Zunächst wird das statische 3D-Modell segmentiert sowie semantisch etikettiert, was sich mit dem Begriff "Labeling" zusammenfassen lässt. Dabei werden rohe Mesh-Geometrien in bedeutungsvolle Teile mit bestimmten Rollen zerlegt (z. B. "Griff" einer Tasse oder "Sitzfläche" eines Stuhls), sodass ein System später "versteht", welches Teil eines 3D-Objekts für welche Interaktion relevant ist und eine Zuordnung stattfinden kann [7][8].

Im nächsten Schritt erfolgt der Übergang von der Semnatik zum Verhalten mittels Zuweisung spezifischer Interaktionsmerkmale (Interaction Features) zu den im ersten Schritt analysierten semantischen Etiketten. Diese Merkmale beinhalten eine Beschreibung der Funktionalität sowie eine Verknüpfung mit Verhaltensplänen oder Zustandsautomaten. Diese Pläne können Zustände überprüfen oder ändern und legen das erwartete Verhalten von beteiligten Akteuren fest [5].

2.3. Das Vivian Framework

Das Vivian Framework ist ein virtual prototyping framework. Es erstellt virtuelle Prototypen, also eine digitale, interaktive Repräsentation physischer Objekte aus der realen Welt. Diese Repräsentation kann z. B. in der Produktentwicklung verwendet werden, um virtuelle Prototypen von echten Produkten zu erzeugen und deren Verhalten frühzeitig zu testen, ohne dass das physische Produkt vorhanden sein muss. Diese virtuellen Prototypen funktionieren spezifikations-getrieben, sodass Verhalten nicht programmatisch, sondern deklarativ als Spezifikation geschrieben wird. Zur Laufzeit wird diese Spezifikation dann mittels einer State-Machine-basierten Umgebung interpretiert um ein Interaktionsverhalten abzubilden. Ein Vorteil einer solchen spezifikations-getriebenen Vorgehensweise ist, dass beispielsweise Produktentwickler*innen keine Programmierkenntnisse benötigen, um virtuelle Prototypen von Produkten (Digital Twins) zu erstellen. So kann das Verhalten eines Produktes bereits frühzeitig und iterativ getestet werden. Ein weiteres mögliches Einsatzgebiet ist das Usability Engineering, mit dem interaktive Systeme so gestaltet und geprüft werden, dass sie für

die jeweilige Zielgruppe möglichst effektiv, effizient sowie zufriedenstellend nutzbar sind. Dafür werden Systeme nicht erst am Ende, sondern bereits in der Entwicklung, beispielsweise mittels Prototypen, auf Gebrauchstauglichkeit analysiert und getestet [9].

2.3.1. Spezifikationen

Wie bereits gezeigt, besitzen statische 3D-Objekte von sich aus keine Interaktivität (siehe 2.1). Das Vivian Framework bildet die Brücke zwischen statischem und interaktivem 3D-Objekt über eine maschinenlesbare Beschreibung des Verhaltens bei Interaktion mit dem virtuellen Prototyp. Die Verbindung dieser Spezifikation zu einem 3D-Objekt in der Szene wird über Namensreferenzen hergestellt. Ein Element in der Spezifikation referenziert demnach ein gleichnamiges 3D-Objekt oder Teilobjekt in der Szene. Weiterhin ermöglichen Spezifikationen eine Entkopplung des Verhaltensmodells vom 3D-Objekt, sodass unterschiedliche Spezifikationen verschiedene Verhalten bei demselben 3D-Objekt ermöglichen. Sie besteht im Wesentlichen aus 4 Teilen: Interaktionselemente (Interaction Elements), Visualisierungselemente (Visualization Elements), Zustände (States) und Übergänge (Transitions).

Interaktionselemente. Hier befinden sich Elemente, welche Eingaben akzeptieren und somit Interaktion ermöglichen. Das können u. a. Buttons, Slider oder Movables sein.

Visualisierungselemente. Dabei handelt es sich Elemente, welche eine visuelle Rückmeldung geben. Typisch sind hier Light, Screen oder Sound Source.

Zustände. In diesem Teil befinden sich alle möglichen Zustände, die ein Prototyp erreichen kann. Jeder Zustand beschreibt eine bestimmte Situation, indem er Interaktions- und Visualisierungselementen Werte zuweist. Diese Zuweisung kann zudem an Bedingungen geknüpft sein.

Übergänge. Übergänge bestimmen, wie sich ein virtueller Prototyp von einem Zustand in einen anderen verändert. Diese Übergänge können durch Zeitüberschreitungen oder Ereignisse (Events) ausgelöst werden. Zusätzlich kann ein Übergang an eine zu erfüllende Bedingung (Guard) geknüpft sein.

2.4. Large Language Models und Agentische Systeme

2.4.1. Definition

Large Language Models (LLMs) sind tiefe neuronale Netzwerke, welche die Verarbeitung von natürlicher Sprache ermöglichen [10]. Sie enthalten typischerweise Milliarden von Parametern und sind in der Lage komplexe Aufgaben zu verstehen und zu lösen oder in Teilaufgaben zu zerlegen [11]. Ihre Skalierbarkeit ist ein zentrales Merkmal von LLM's, denn sie zeigen mit zunehmender Modellgröße und Datenmenge qualitative Leistungssteigerungen und sogenannte emergente Fähigkeiten, wie z. B. *In-Context Learning*. Während solche LLMs als Modelle zur passiven Sprachverarbeitung und -generierung verstanden werden können, besitzen sie ohne zusätzliche Werkzeuge keine eigene Handlungsfähigkeit. Hier greift das Konzept eines LLM-basierten Agenten weiter. Ein Agent ist eine autonome Einheit, welche in einer Umgebung agiert, Entscheidungen trifft und auch mit anderen Agenten interagieren kann[12]. LLM-basierte Agenten verbinden diese klassische Idee mit den Fähigkeiten von LLMs. Ein LLM kann hier als kognitive Kernkomponente verstanden werden und verleiht dem Agent die Fähigkeit eigenständig und unabhängig zu analysieren, zu planen sowie Probleme zu lösen [13]. So entsteht ein System, welches nicht nur natürliche Sprache verarbeiten kann, sondern eine eigene zielgerichtete Handlungsfähigkeit besitzt und in einer Umgebung agieren kann. Ebenso kann es zusätzliche Komponenten wie Sensorik, API-Aufrufe oder Werkzeuge nutzen[13]. Die universelle Schnittstelle für solche agentischen Systeme, über die formuliert, geplant und koordiniert wird, ist die natürliche Sprache[14]

2.4.2. Multimodale LLMs

Multimodale Large Language Models (MLLMs) sind Modelle, welche im Gegensatz zu LLMs nicht nur Text, sondern zudem Informationen wie Bild, Audio oder Video empfangen (Input), verarbeiten sowie ausgeben (Output) können. Sie basieren auf LLMs und bestehen im Wesentlichen aus 3 Hauptmodulen: einem vortrainierten Encoder (Modality-Encoder), einem LLM sowie einem Adapter (Connector). Der Encoder verarbeitet die multimodalen Signale vor und der Adapter bildet die Brücke zum LLM, indem er diese Signale für das LLM verständlich umwandelt. Dieser Schritt ist nötig, da LLMs (wie in 2.4 gezeigt) ausschließlich Text verarbeiten können. Somit sind MLLMs in der Lage, Text sowie weitere multimodale Inhalte gemeinsam zu verstehen und darauf zu antworten. Im Vergleich zu früheren, ähnlichen Arbeiten basieren MLLMs auf LLMs mit Milliarden Parametern sowie neuen Trainingsparadigmen [15], [16]. Damit sind eine Vielzahl von Möglichkeiten gegeben, welche mit reinen LLMs nicht oder nur eingeschränkt realisierbar wären. Solche repräsentativen Fähigkeiten sind u. a. das Verständnis von visuell geprägten Witzen/Memes [17],

[18], räumliches/koordinatenbezogenes Verständnis, das Erstellen von Website-Code basierend auf handgezeichneten Entwürfen oder Kochrezepte anhand von Bildern zubereiteter Gerichte [18].

2.4.3. Verwendung in der vorliegenden Arbeit

In dieser Arbeit werden LLM-basierte Agenten als Steuerungseinheiten in einer Pipeline zur Spezifikationsgenerierung für das Vivian Framework verwendet. Sie übernehmen eine zentrale Rolle in der Übersetzung von natürlicher Sprache in strukturierte, maschinenlesbare Spezifikationen. Sie analysieren 3D-Szenen, planen mögliche Interaktionen mit einem 3D-Objekt, Erzeugen Spezifikationen zur Realisierung dieser Interaktionen und validieren semantische Korrektheit der erzeugten Artefakte.

Kapitel 3.

Stand der Forschung

3.1. LLM-gestützte 3D-Objektmanipulation

3.2. Einordnung der vorliegenden Arbeit

Kapitel 4.

Methodik

Kapitel 5.

Implementierung

Kapitel 6.

Evaluation

Kapitel 7.

Ausblick

Kapitel 8.

Fazit

Anhang A.

Supplemental Information

Dies hier ist ein Blindtext zum Testen von Textausgaben. Wer diesen Text liest, ist selbst schuld. Der Text gibt lediglich den Grauwert der Schrift an. Ist das wirklich so? Ist es gleichgültig, ob ich schreibe: „Dies ist ein Blindtext“ oder „Huardest gefburn“? Kjift – mitnichten! Ein Blindtext bietet mir wichtige Informationen. An ihm messe ich die Lesbarkeit einer Schrift, ihre Anmutung, wie harmonisch die Figuren zueinander stehen und prüfe, wie breit oder schmal sie läuft. Ein Blindtext sollte möglichst viele verschiedene Buchstaben enthalten und in der Originalsprache gesetzt sein. Er muss keinen Sinn ergeben, sollte aber lesbar sein. Fremdsprachige Texte wie „Lorem ipsum“ dienen nicht dem eigentlichen Zweck, da sie eine falsche Anmutung vermitteln.

Das hier ist der zweite Absatz. Dies hier ist ein Blindtext zum Testen von Textausgaben. Wer diesen Text liest, ist selbst schuld. Der Text gibt lediglich den Grauwert der Schrift an. Ist das wirklich so? Ist es gleichgültig, ob ich schreibe: „Dies ist ein Blindtext“ oder „Huardest gefburn“? Kjift – mitnichten! Ein Blindtext bietet mir wichtige Informationen. An ihm messe ich die Lesbarkeit einer Schrift, ihre Anmutung, wie harmonisch die Figuren zueinander stehen und prüfe, wie breit oder schmal sie läuft. Ein Blindtext sollte möglichst viele verschiedene Buchstaben enthalten und in der Originalsprache gesetzt sein. Er muss keinen Sinn ergeben, sollte aber lesbar sein. Fremdsprachige Texte wie „Lorem ipsum“ dienen nicht dem eigentlichen Zweck, da sie eine falsche Anmutung vermitteln.

Und nun folgt – ob man es glaubt oder nicht – der dritte Absatz. Dies hier ist ein Blindtext zum Testen von Textausgaben. Wer diesen Text liest, ist selbst schuld. Der Text gibt lediglich den Grauwert der Schrift an. Ist das wirklich so? Ist es gleichgültig, ob ich schreibe: „Dies ist ein Blindtext“ oder „Huardest gefburn“? Kjift – mitnichten! Ein Blindtext bietet mir wichtige Informationen. An ihm messe ich die Lesbarkeit einer Schrift, ihre Anmutung, wie harmonisch die Figuren zueinander stehen und prüfe, wie breit oder schmal sie läuft. Ein Blindtext sollte möglichst viele verschiedene Buchstaben enthalten und in der Originalsprache gesetzt sein. Er muss keinen Sinn ergeben, sollte aber lesbar sein. Fremdsprachige Texte wie „Lorem ipsum“ dienen nicht dem eigentlichen Zweck, da sie eine falsche Anmutung vermitteln.

Nach diesem vierten Absatz beginnen wir eine neue Zählung. Dies hier ist ein Blindtext zum Testen von Textausgaben. Wer diesen Text liest, ist selbst schuld. Der Text gibt lediglich den Grauwert der Schrift an. Ist das wirklich so? Ist es gleichgültig, ob ich schreibe: „Dies ist ein Blindtext“ oder „Huardest gefburn“? Kjift – mitnichten! Ein Blindtext bietet mir wichtige Informationen. An ihm messe ich die Lesbarkeit einer Schrift, ihre Anmutung, wie harmonisch die Figuren zueinander stehen und prüfe, wie breit oder schmal sie läuft. Ein Blindtext sollte möglichst viele verschiedene Buchstaben enthalten und in der Originalsprache gesetzt sein. Er muss keinen Sinn ergeben, sollte aber lesbar sein. Fremdsprachige Texte wie „Lorem ipsum“ dienen nicht dem eigentlichen Zweck, da sie eine falsche Anmutung vermitteln.

Dies hier ist ein Blindtext zum Testen von Textausgaben. Wer diesen Text liest, ist selbst schuld. Der Text gibt lediglich den Grauwert der Schrift an. Ist das wirklich so? Ist es gleichgültig, ob ich schreibe: „Dies ist ein Blindtext“ oder „Huardest gefburn“? Kjift – mitnichten! Ein Blindtext bietet mir wichtige Informationen. An ihm messe ich die Lesbarkeit einer Schrift, ihre Anmutung, wie harmonisch die Figuren zueinander stehen und prüfe, wie breit oder schmal sie läuft. Ein Blindtext sollte möglichst viele verschiedene Buchstaben enthalten und in der Originalsprache gesetzt sein. Er muss keinen Sinn ergeben, sollte aber lesbar sein. Fremdsprachige Texte wie „Lorem ipsum“ dienen nicht dem eigentlichen Zweck, da sie eine falsche Anmutung vermitteln.

Abbildungsverzeichnis

Tabellenverzeichnis

Listingverzeichnis

Literatur

[1] M.-X. Chen, H. Hu, R. Yao, L. Qiu und D. Li, „A Survey on the Design of Virtual Reality Interaction Interfaces,“ *Sensors*, Jg. 24, Nr. 19, S. 6204, Jan. 2024, ISSN: 1424-8220. DOI: 10.3390/s24196204 besucht am 4. Apr. 2026.

[2] X. Ma u. a., *When LLMs Step into the 3D World: A Survey and Meta-Analysis of 3D Tasks via Multi-modal Large Language Models*, Okt. 2025. DOI: 10.48550/arXiv.2405.10255 arXiv: 2405.10255 [cs]. besucht am 3. Apr. 2026.

[3] I. Baran und J. Popović, „Automatic Rigging and Animation of 3D Characters,“ *ACM Trans. Graph.*, Jg. 26, Nr. 3, 72–es, Juli 2007, ISSN: 0730-0301. DOI: 10.1145/1276377.1276467 besucht am 8. Apr. 2026.

[4] *Gabriel Zachmann's Dissertation*, https://user.informatik.uni-bremen.de/zach/papers/diss.html. besucht am 9. Apr. 2026.

[5] M. Kallmann und D. Thalmann, „Modeling Behaviors of Interactive Objects for Real-Time Virtual Environments,“ *Journal of Visual Languages & Computing*, Jg. 13, Nr. 2, S. 177–195, Apr. 2002, ISSN: 1045926X. DOI: 10.1006/jvlc.2001.0229 besucht am 4. Apr. 2026.

[6] J. Steuer, „Defining Virtual Reality: Dimensions Determining Telepresence,“ *Journal of Communication*, Jg. 42, Nr. 4, S. 73–93, 1992, ISSN: 1460-2466. DOI: 10.1111/j.1460-2466.1992.tb00812.x besucht am 9. Apr. 2026.

[7] K. Mo u. a., *PartNet: A Large-scale Benchmark for Fine-grained and Hierarchical Part-level 3D Object Understanding*, Dez. 2018. DOI: 10.48550/arXiv.1812.02713 arXiv: 1812.02713 [cs]. besucht am 4. Apr. 2026.

[8] M. Hassanin, S. Khan und M. Tahtali, „Visual Affordance and Function Understanding: A Survey,“ *ACM Comput. Surv.*, Jg. 54, Nr. 3, 47:1–47:35, Apr. 2021, ISSN: 0360-0300. DOI: 10.1145/3446370 besucht am 4. Apr. 2026.

[9] J. D. Gould und C. Lewis, „Designing for Usability: Key Principles and What Designers Think,“ *Commun. ACM*, Jg. 28, Nr. 3, S. 300–311, März 1985, ISSN: 0001-0782. DOI: 10.1145/3166.3170 besucht am 11. Apr. 2026.

[10] S. J. Lazer, K. Aryal, M. Gupta und E. Bertino, *A Survey of Agentic AI and Cybersecurity: Challenges, Opportunities and Use-case Prototypes*, Jan. 2026. DOI: 10.48550/arXiv.2601.05293 arXiv: 2601.05293 [cs]. besucht am 10. Apr. 2026.

[11] R. Bommasani u. a., *On the Opportunities and Risks of Foundation Models*, Juli 2022. DOI: 10.48550/arXiv.2108.07258 arXiv: 2108.07258 [cs]. besucht am 9. Apr. 2026.

[12] Y. Shoham, „Agent-Oriented Programming," *Artificial Intelligence*, Jg. 60, Nr. 1, S. 51–92, März 1993, ISSN: 0004-3702. DOI: 10.1016/0004-3702(93)90034-9 besucht am 8. Apr. 2026.

[13] Z. Xi u. a., *The Rise and Potential of Large Language Model Based Agents: A Survey*, Sep. 2023. DOI: 10.48550/arXiv.2309.07864 arXiv: 2309.07864 [cs]. besucht am 8. Apr. 2026.

[14] Y. Shen, K. Song, X. Tan, D. Li, W. Lu und Y. Zhuang, *HuggingGPT: Solving AI Tasks with ChatGPT and Its Friends in Hugging Face*, Dez. 2023. DOI: 10.48550/arXiv.2303.17580 arXiv: 2303.17580 [cs]. besucht am 8. Apr. 2026.

[15] S. Yin u. a., „A Survey on Multimodal Large Language Models," *National Science Review*, Jg. 11, Nr. 12, nwae403, Dez. 2024, ISSN: 2095-5138. DOI: 10.1093/nsr/nwae403 besucht am 13. Apr. 2026.

[16] D. Caffagni u. a., „The Revolution of Multimodal Large Language Models: A Survey," in *Findings of the Association for Computational Linguistics: ACL 2024*, L.-W. Ku, A. Martins und V. Srikumar, Hrsg., Bangkok, Thailand: Association for Computational Linguistics, Aug. 2024, S. 13 590–13 618. DOI: 10.18653/v1/2024.findings-acl.807 besucht am 13. Apr. 2026.

[17] Z. Yang u. a., *MM-REACT: Prompting ChatGPT for Multimodal Reasoning and Action*, März 2023. DOI: 10.48550/arXiv.2303.11381 arXiv: 2303.11381 [cs]. besucht am 13. Apr. 2026.

[18] D. Zhu, J. Chen, X. Shen, X. Li und M. Elhoseiny, *MiniGPT-4: Enhancing Vision-Language Understanding with Advanced Large Language Models*, Okt. 2023. DOI: 10.48550/arXiv.2304.10592 arXiv: 2304.10592 [cs]. besucht am 13. Apr. 2026.